KI und Entscheidung

Wie Mensch und KI gemeinsam Entscheidungen treffen

Philipp Zmijewski
Hochschule Osnabrück · 2026

Webansicht



image: ai-generated (gpt-image-2.5-flare)

Wann würdet ihr einer KI
eine Entscheidung überlassen?

Wo nutzt ihr KI heute schon?



Erzeugen

Wofür nutzt ihr generative KI?



Empfehlen

Wo lasst ihr euch Empfehlungen geben?

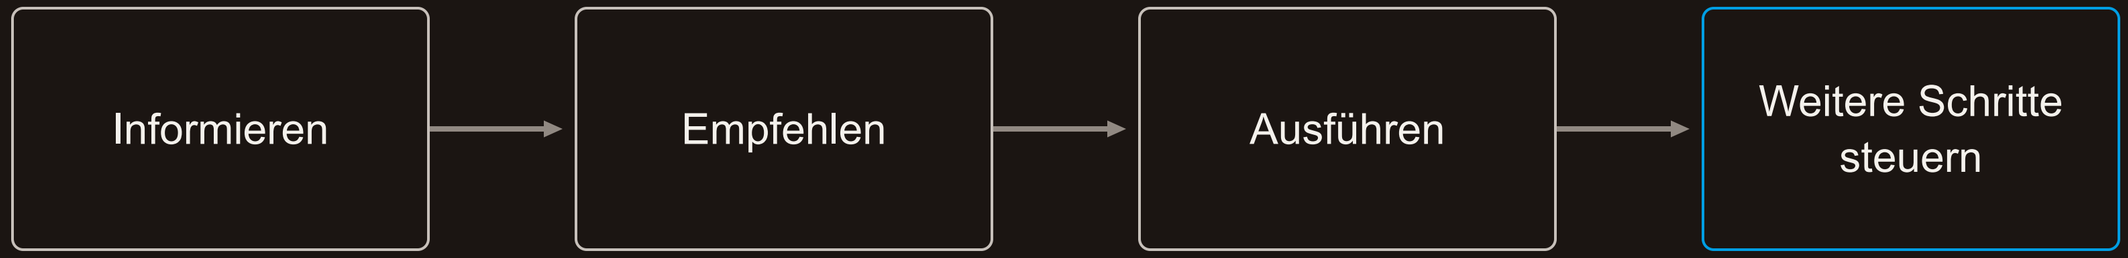


Prüfen

Wo prüft ihr die Antwort besonders kritisch?

Vom Text zur Handlung

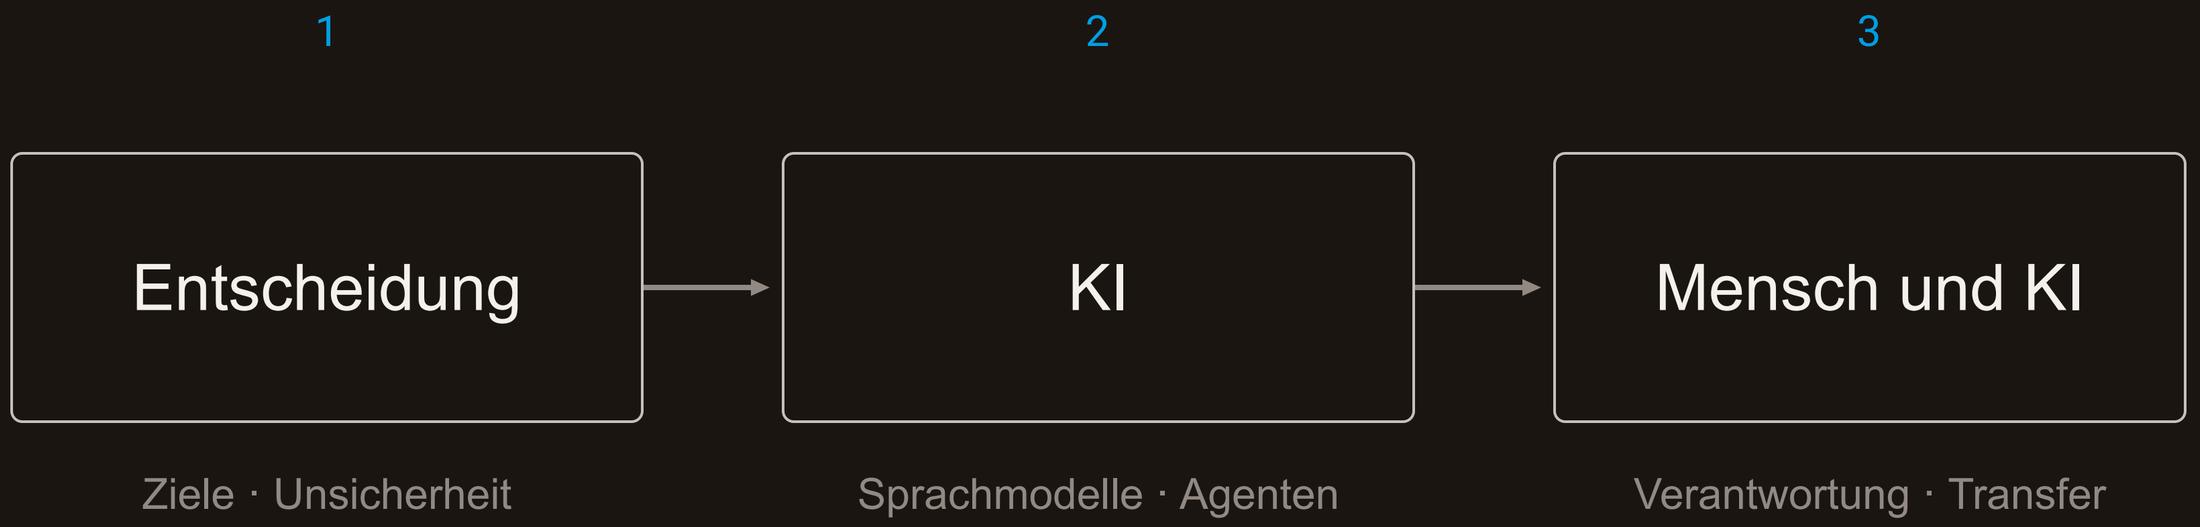
Handlungsspielraum des Systems



Je mehr ein System selbst tut, desto klarer müssen Grenzen und Eingriffspunkte sein.

Nach Parasuraman, Sheridan & Wickens (2000); Anthropic (2024)

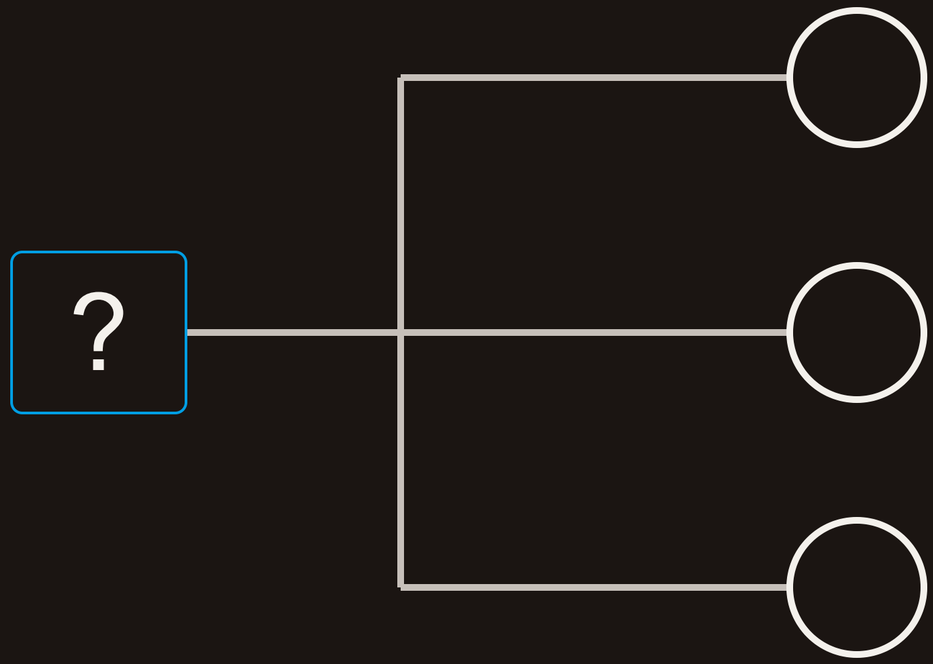
Unser Weg durch den Tag



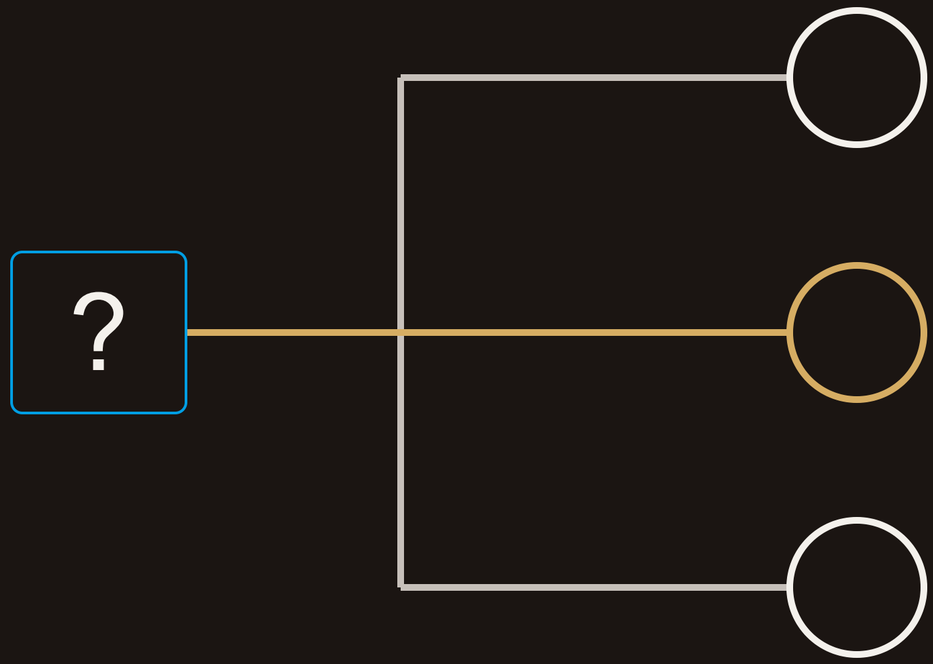
Block 1

Was ist eigentlich eine Entscheidung?

Warum eine gute Prognose noch keine gute Entscheidung ist.



Eine Entscheidung wählt eine von mehreren möglichen Handlungen.



Entscheidungen brauchen ein Ziel



Ohne Ziel lässt sich keine Alternative sinnvoll bewerten.

Entscheidungen brauchen Alternativen

A

Freigeben

B

Nachprüfen

C

Sperren

Information ist noch keine Entscheidung

Beobachtung

Der Messwert liegt knapp außerhalb des internen Zielbereichs.

Handlung

?

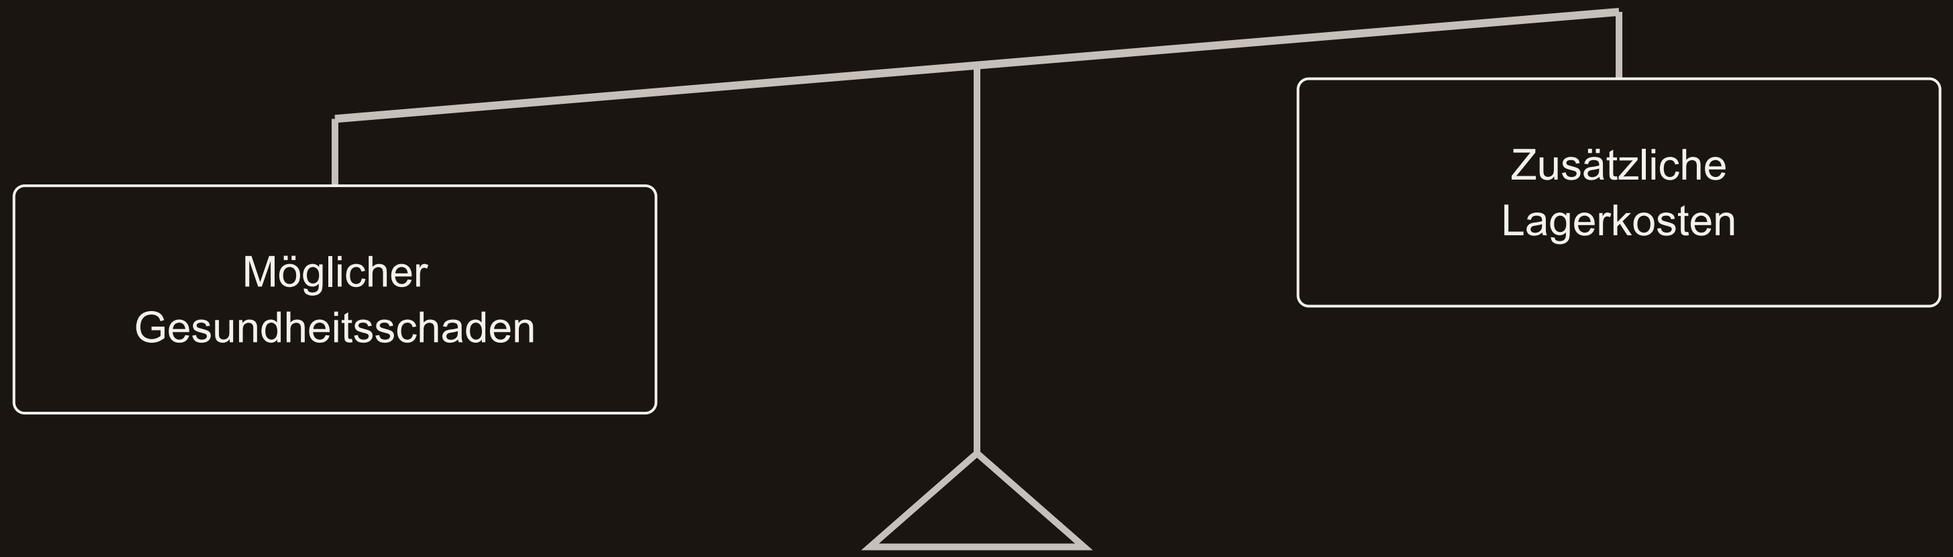
Eine Prognose schätzt, was wir noch nicht wissen.

Fiktives Beispiel



Das Modell schätzt: 20 % Wahrscheinlichkeit für einen Qualitätsmangel.

Was ist Bewertung?



Ein möglicher Gesundheitsschaden wiegt schwerer als zusätzliche Lagerkosten.

Was ist die Entscheidung?

A

Freigeben

B

Nachprüfen

C

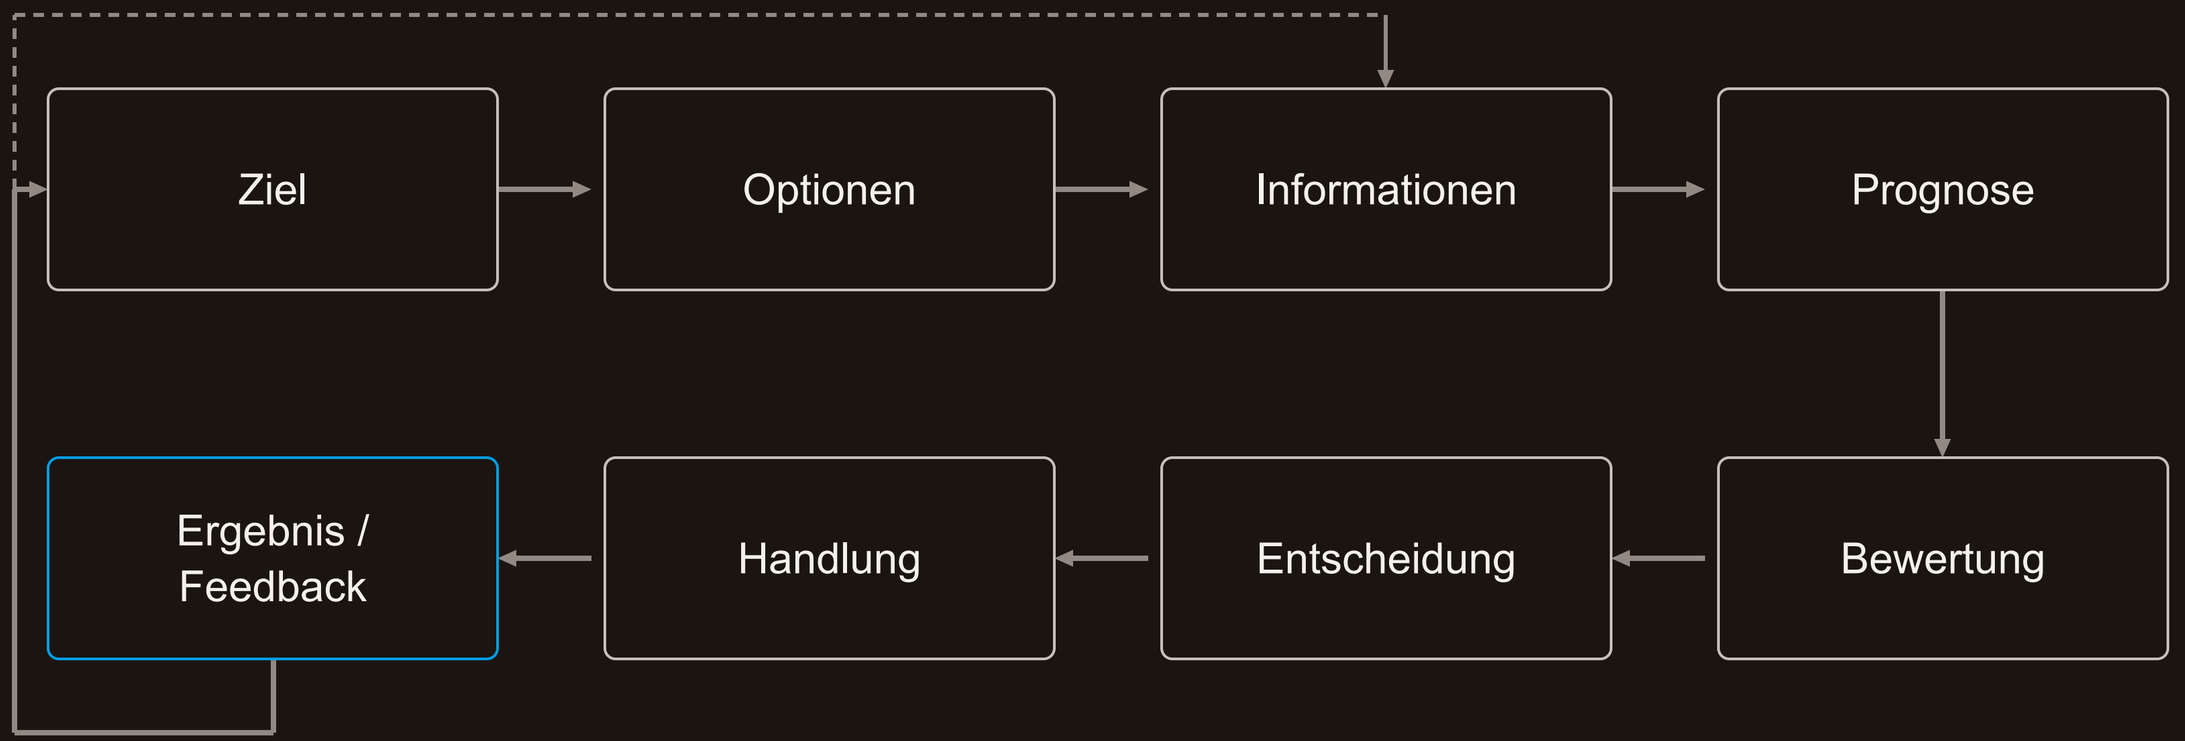
Sperren

Die Charge wird bis zur Wiederholungsmessung gesperrt.

Prognose ≠ Bewertung ≠ Entscheidung

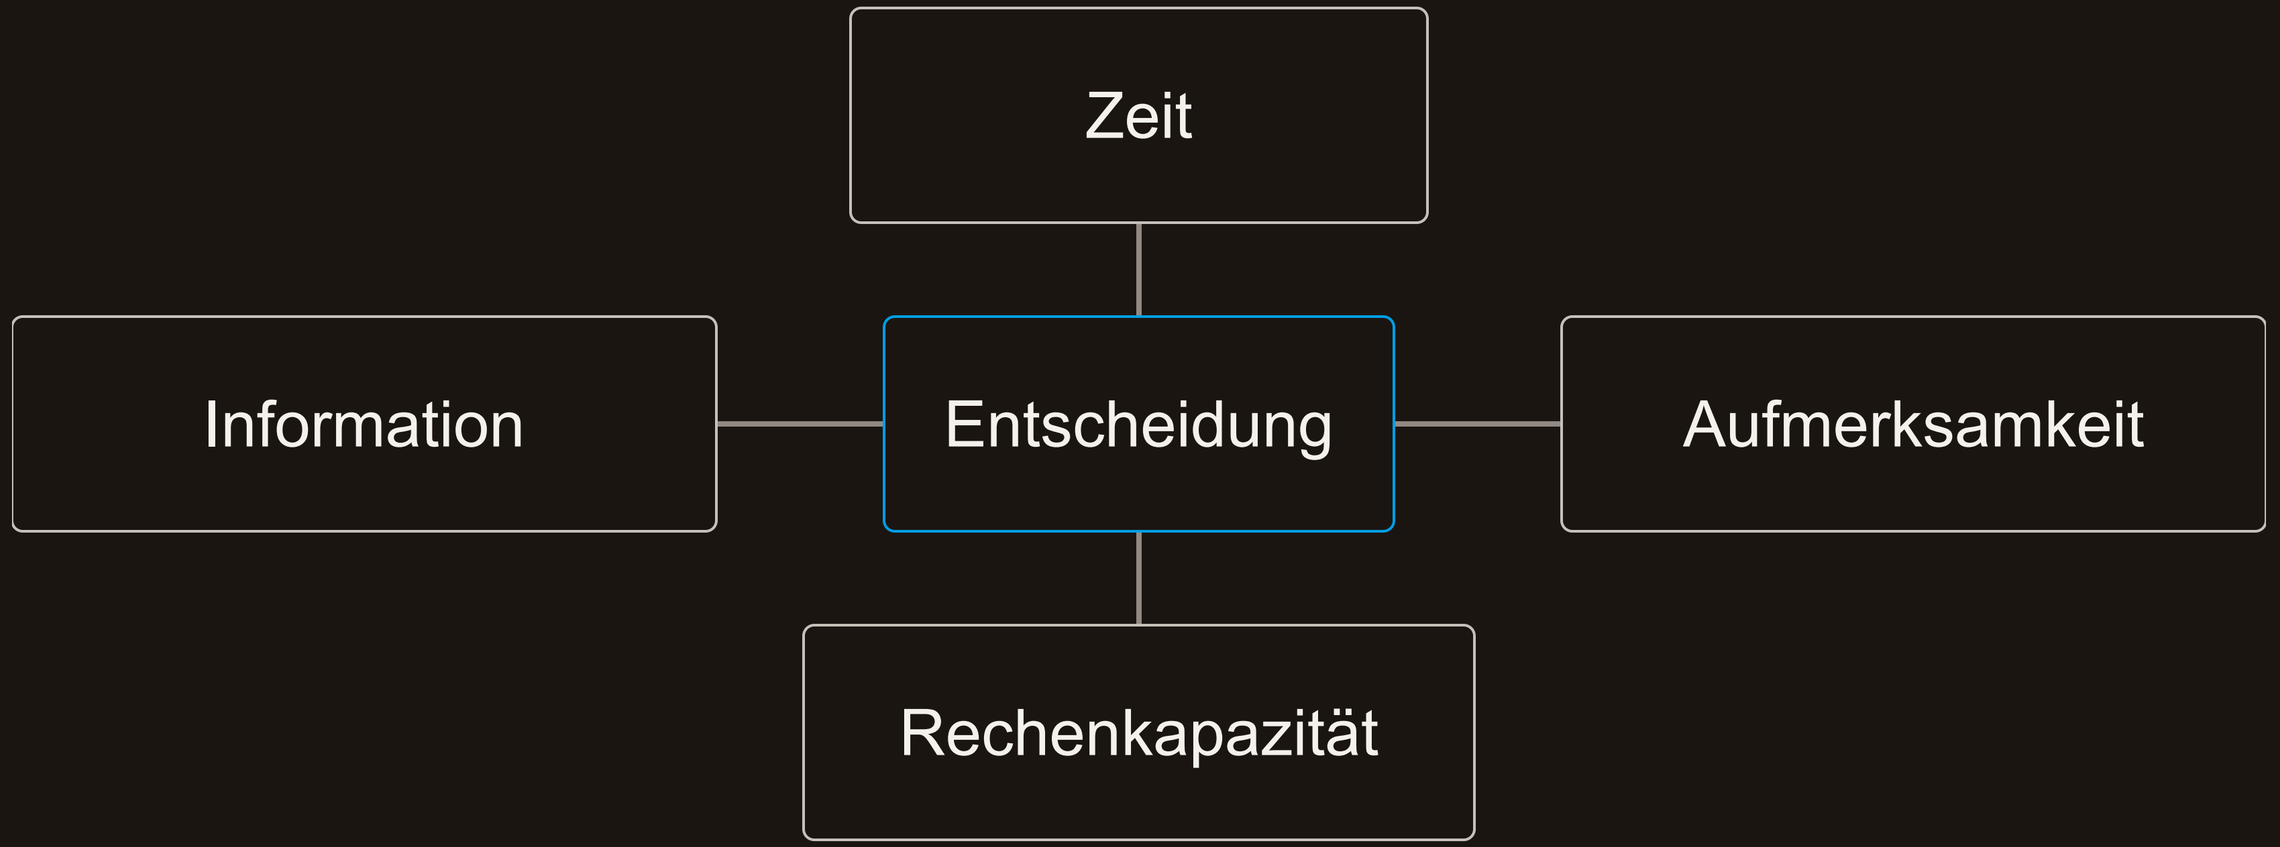


Die Anatomie einer Entscheidung

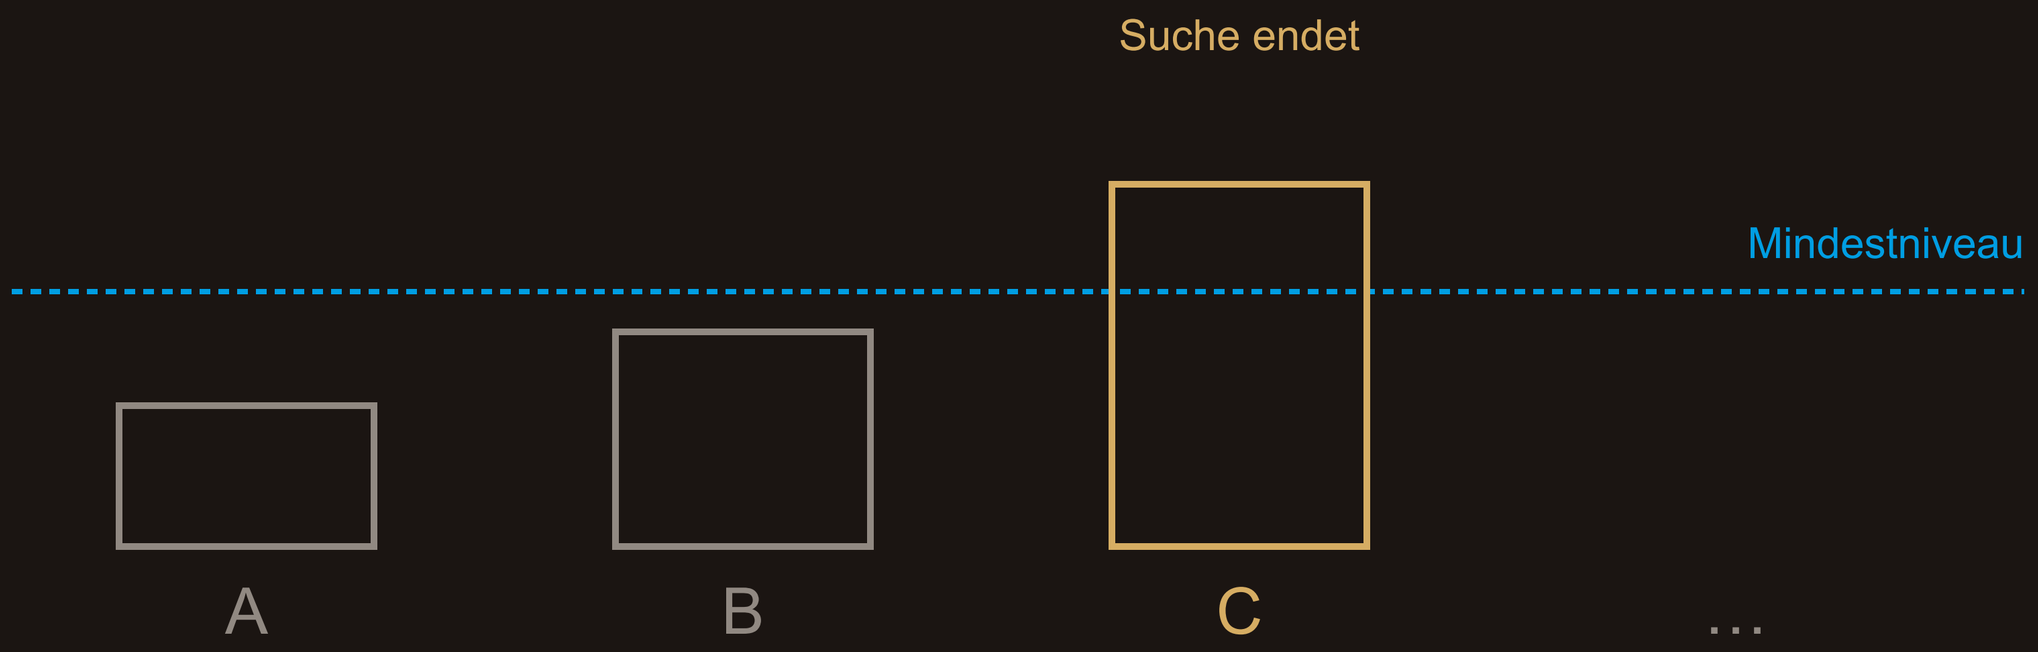


Sicherheit	Risiko	Unsicherheit
Ausgang bekannt	Wahrscheinlichkeiten abschätzbar	Wahrscheinlichkeiten nicht verlässlich bekannt

Begrenzte Rationalität

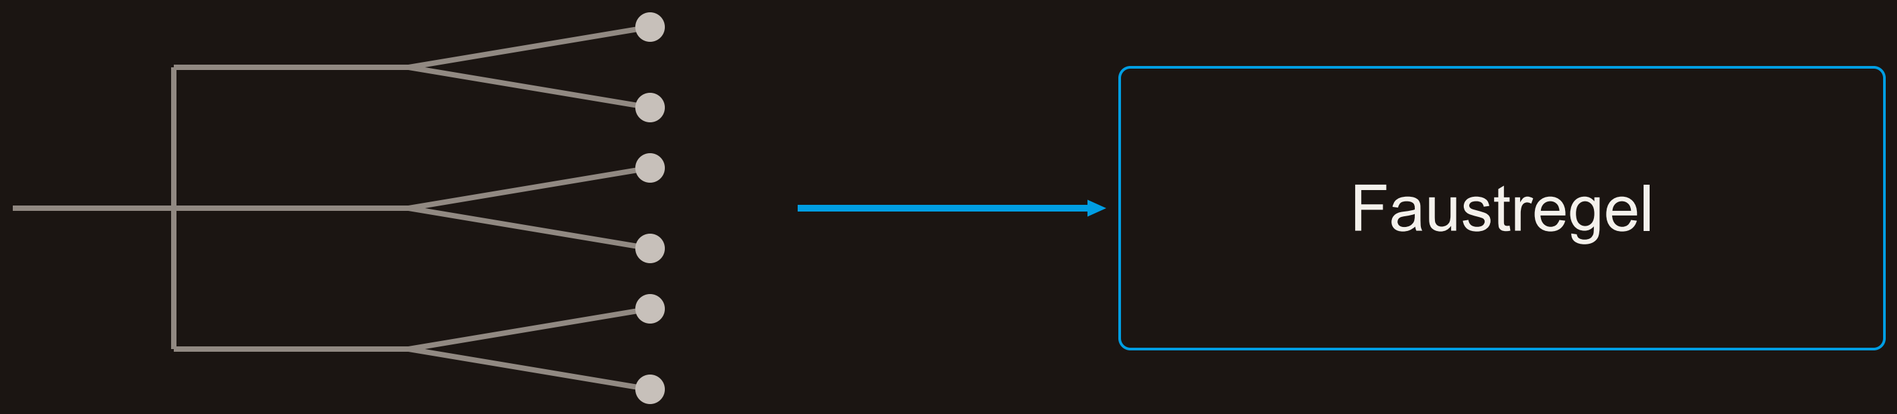


Satisficing



Die Suche endet bei einer ausreichend guten Option.

Was ist eine Heuristik?

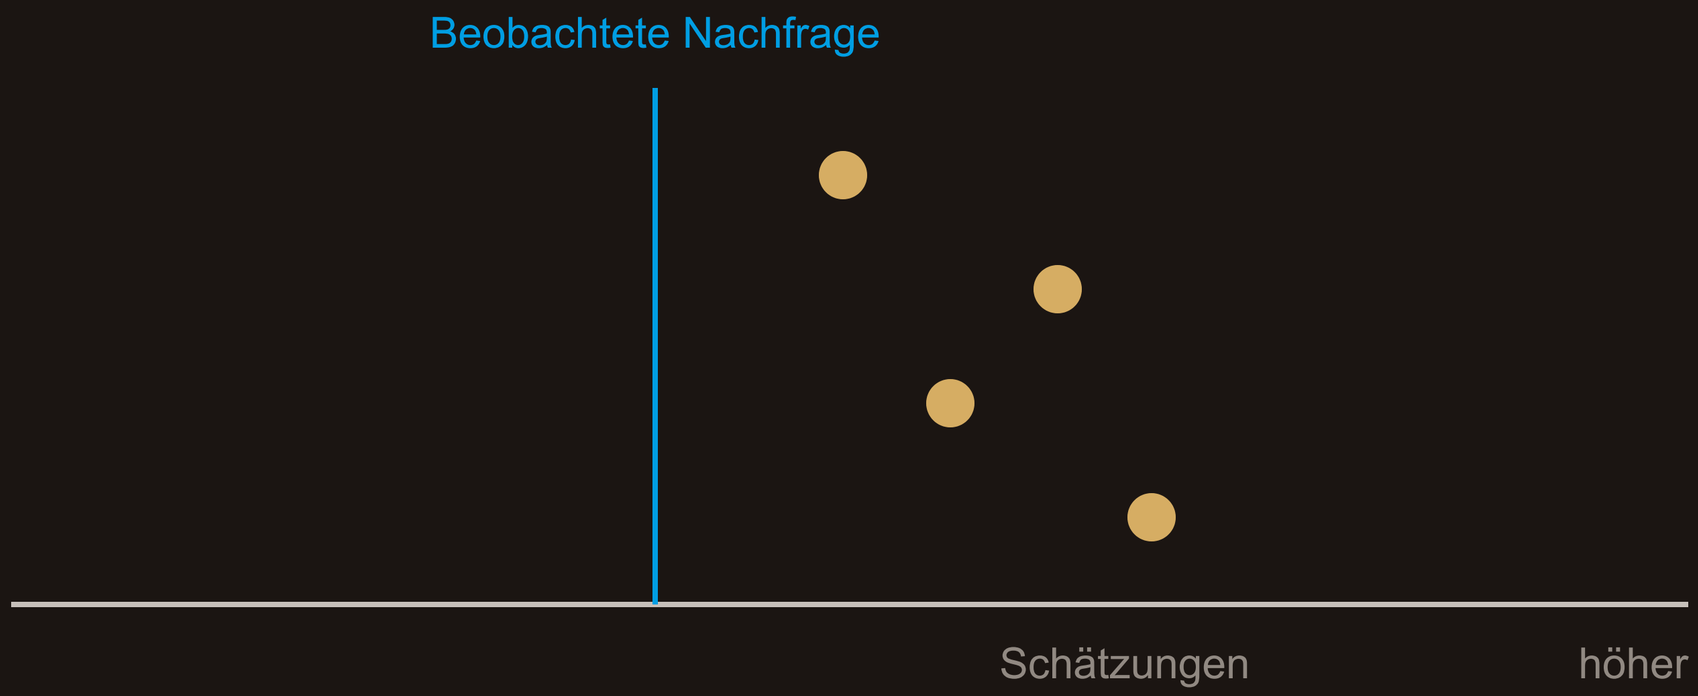


Viele Prüfpfade

Eine einfache Regel

Eine Heuristik ist eine vereinfachende Urteilsregel.

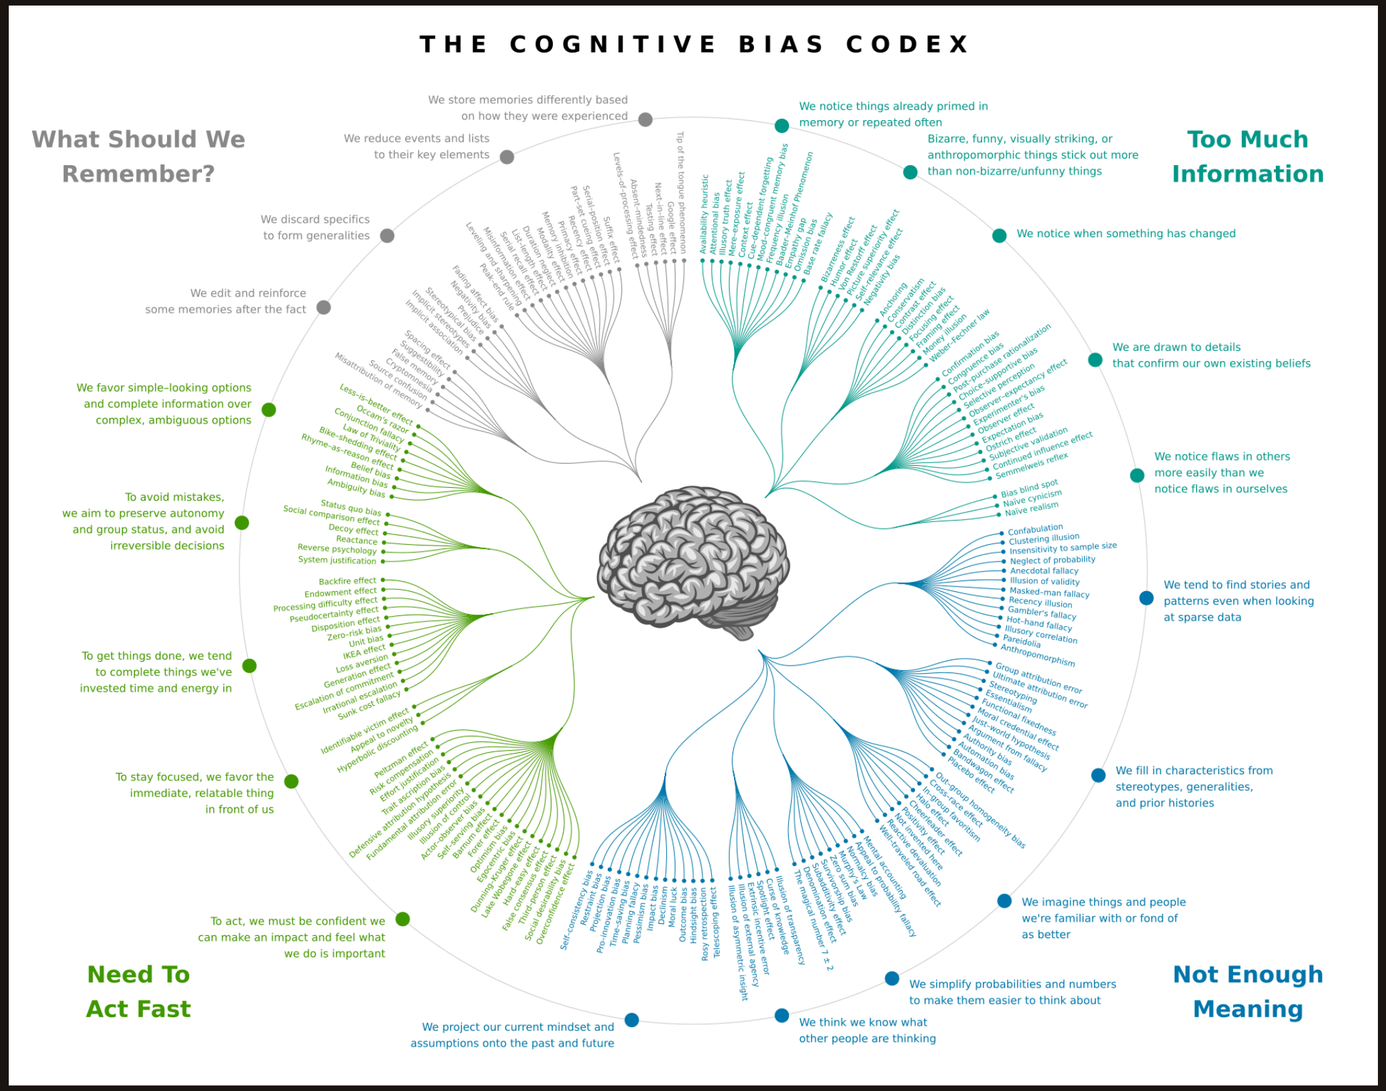
Was ist ein Bias?



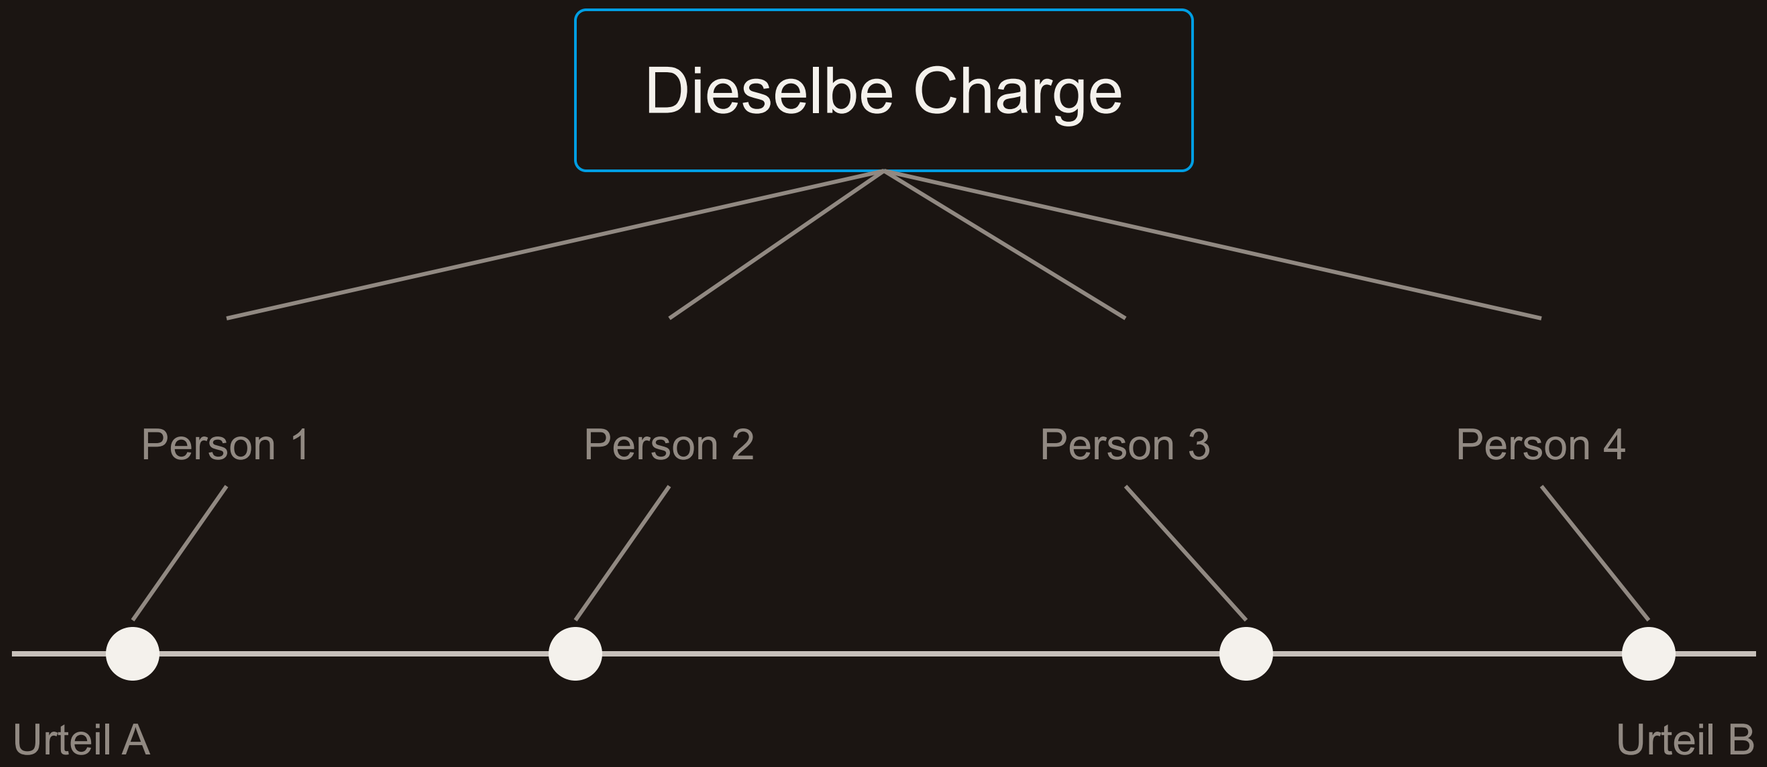
Nachfrage wird wiederholt zu optimistisch eingeschätzt.

Viele Arten von Bias

Original erkunden ↗



J. Manoogian III · B. Benson · TilmannR · CC BY-SA 4.0 · unverändert, lokal als PNG eingebunden



Dieselbe Charge – unterschiedliche Urteile.

Begriff	Bedeutung	Einordnung
Heuristik	Vereinfachende Regel	Kann nützlich sein
Bias	Systematische Verzerrung	Problematisch
Noise	Unerwünschte Streuung	Problematisch

Verfügbarkeit: Was fällt uns leicht ein?



Sichtbarkeit ist nicht dasselbe wie Häufigkeit.

Leicht erinnerbare Ereignisse können wahrscheinlicher wirken.

Ankern: Die erste Zahl bleibt hängen

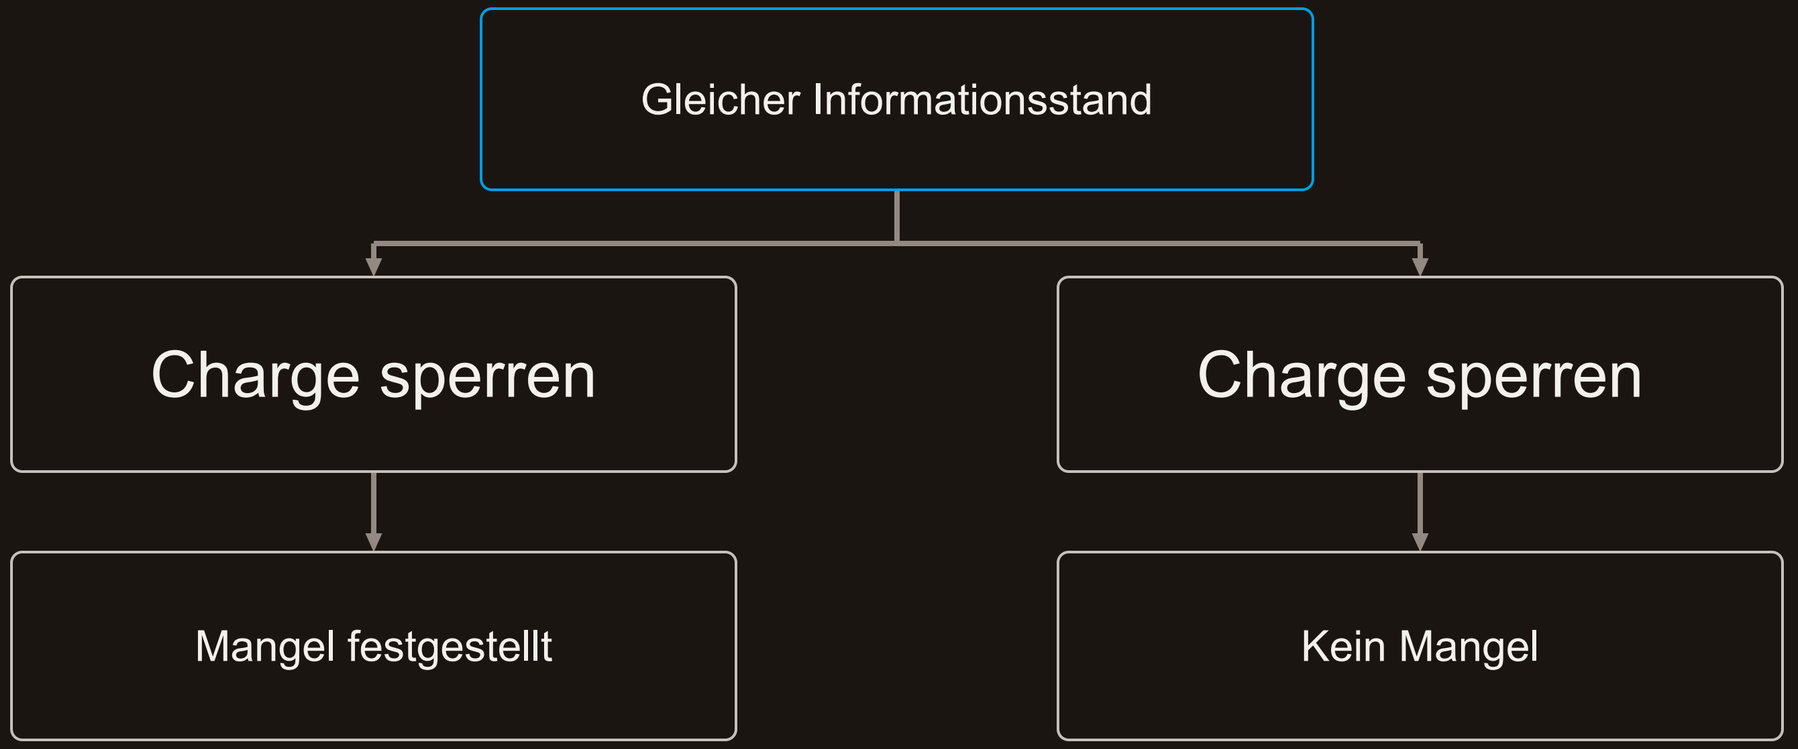
Erste Preisnennung

Spätere Einschätzung



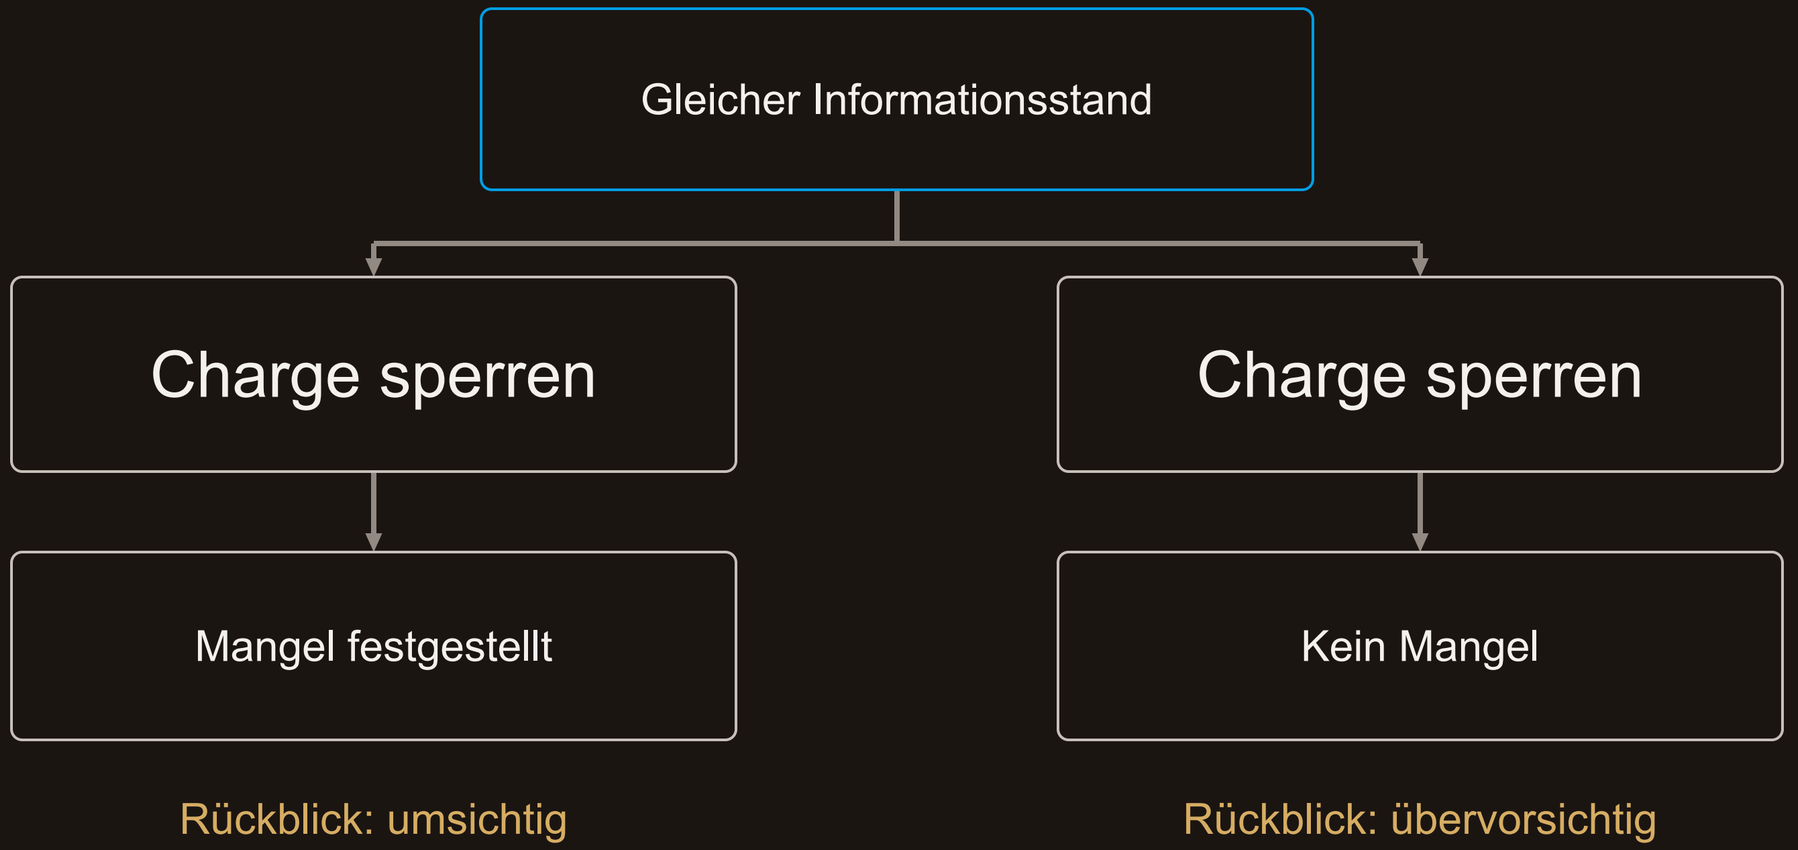
Ein Ausgangswert kann spätere Einschätzungen beeinflussen.

Gute Entscheidung oder gutes Ergebnis?



Ein gutes Ergebnis beweist keinen guten Entscheidungsprozess.

Outcome Bias



Das spätere Ergebnis färbt das Urteil über die frühere Entscheidung.

Fallstudie: Die auffällige Joghurtcharge

Ihr seid die Produktionsleitung eines mittelständischen Molkereiunternehmens. Am Vormittag wurden 40.000 Becher Naturjoghurt produziert. Die Ware soll noch am selben Nachmittag an mehrere Handelsunternehmen ausgeliefert werden.

Bei einer routinemäßigen Qualitätskontrolle liegt ein Messwert knapp außerhalb des unternehmensinternen Zielbereichs. Der gesetzliche Grenzwert wird nicht überschritten. Die Abweichung könnte auf ein Qualitätsproblem hindeuten, kann aber auch durch einen Messfehler entstanden sein.

Eine Wiederholungsmessung würde voraussichtlich vier Stunden dauern. Dadurch könnte die geplante Auslieferung nicht mehr rechtzeitig erfolgen. Eine Verzögerung würde zusätzliche Lager- und Transportkosten verursachen. Außerdem könnten einzelne Kunden kurzfristig nicht vollständig beliefert werden.

Ihr müsst innerhalb der nächsten 30 Minuten entscheiden.

Didaktisch konstruierter Fall

Handlungsoptionen

A

Die Charge wird wie geplant ausgeliefert.

B

Die Auslieferung wird gestoppt, bis das Ergebnis der Wiederholungsmessung vorliegt.

C

Es wird sofort eine zusätzliche Schnellprüfung durchgeführt. Diese liefert nach 30 Minuten ein Ergebnis, ist aber weniger zuverlässig als die reguläre Wiederholungsmessung.

Eure Entscheidung in 15 Minuten

1

Was ist euer Ziel?

Was wisst ihr?

2

Was ist unsicher?

Welche Prognosen braucht ihr?

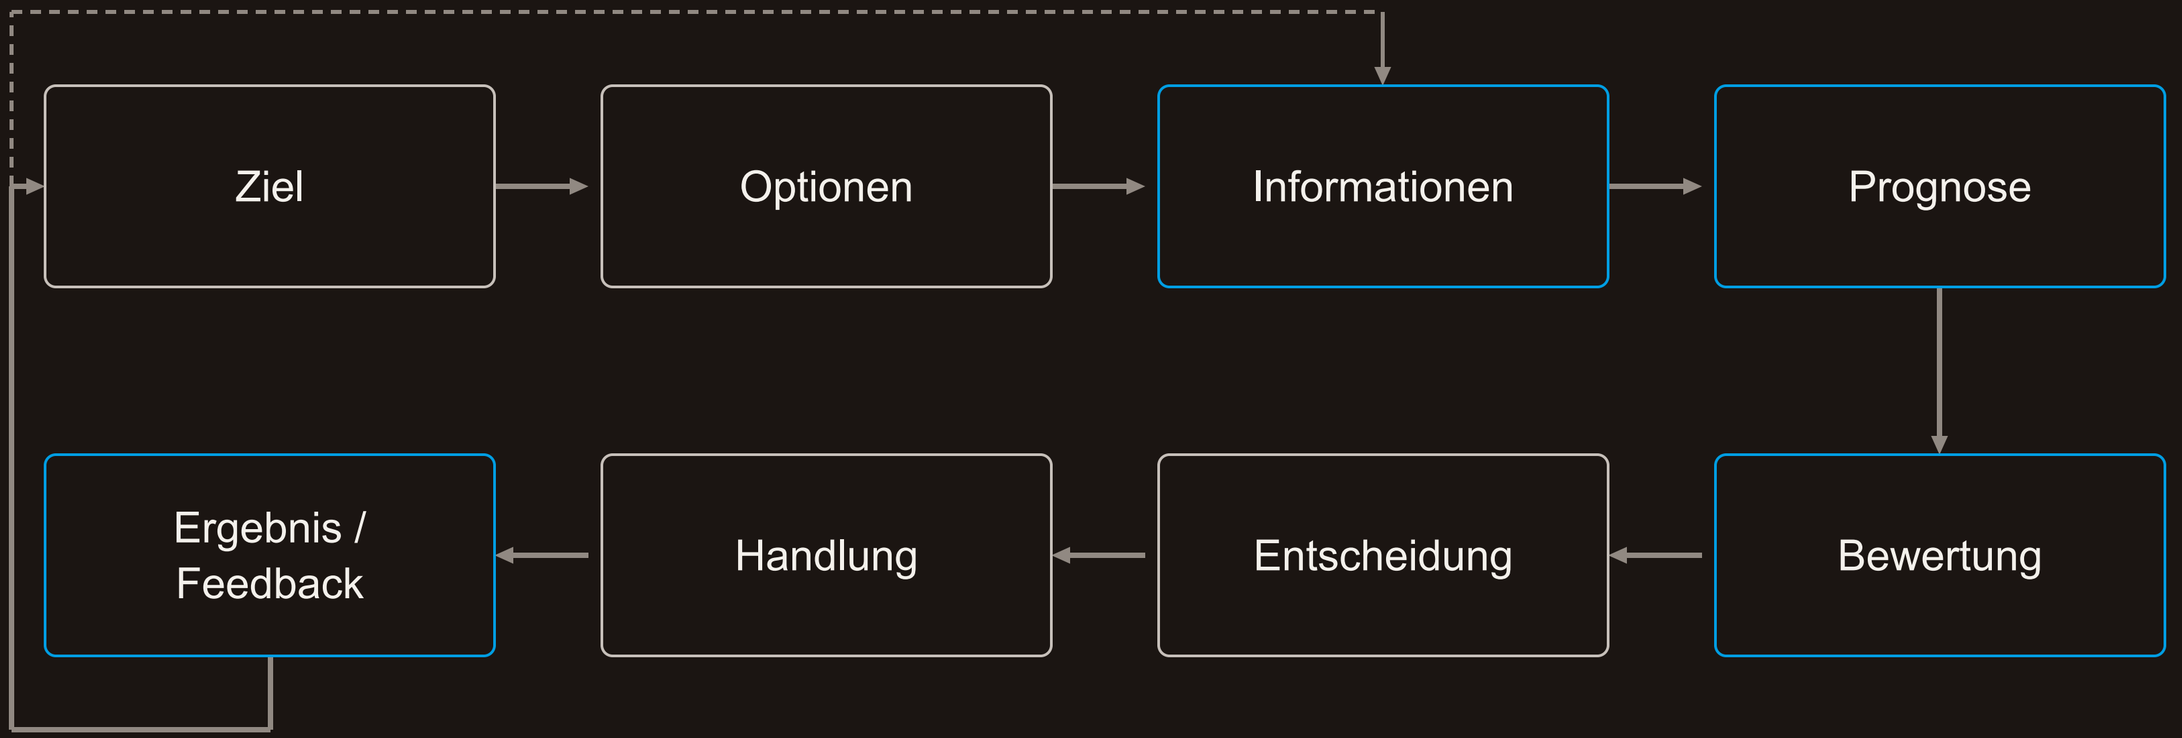
3

Welche Folgen bewertet ihr?

Welche Handlung wählt ihr?

Haltet eure Handlung und die Begründung fest.

Was machte die Entscheidung schwierig?



Entscheidungen sind mehr als Prognosen. Sie verbinden Information mit Zielen, Bewertung, Handlungswahl und Verantwortung.



Weiterlesen: Wie Menschen entscheiden

Einstieg

Simon (1955)
Begrenzte Rationalität und Satisficing

Tversky & Kahneman (1974)
Heuristiken und Biases

Vertiefung

Gigerenzer & Gaissmaier (2011)
Adaptive Heuristiken

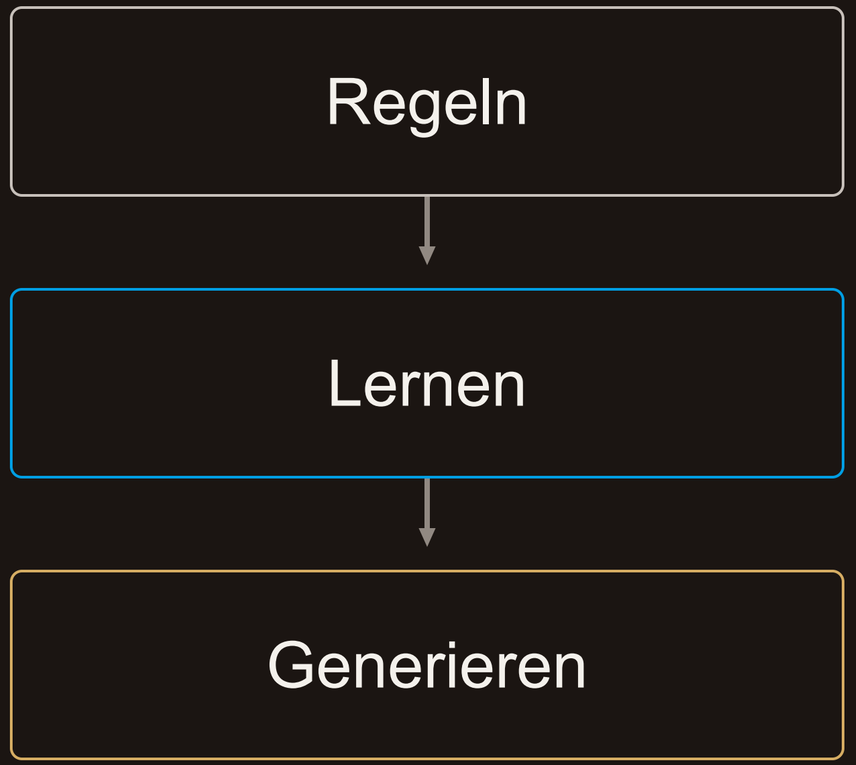
Kahneman, Sibony & Sunstein (2021)
Noise

Baron & Hershey (1988)
Outcome Bias

Block 2

Was kann KI eigentlich?

Von festen Regeln zu generativen Modellen.



Systemperspektive · OECD

Ein KI-System verarbeitet Eingaben und leitet daraus für bestimmte Ziele Prognosen, Inhalte, Empfehlungen oder Entscheidungen ab.

Knappe Paraphrase nach OECD (2024)

Forschungsperspektive · Elaine Rich

KI untersucht, wie wir Computer Dinge tun lassen, die Menschen im Moment besser können.

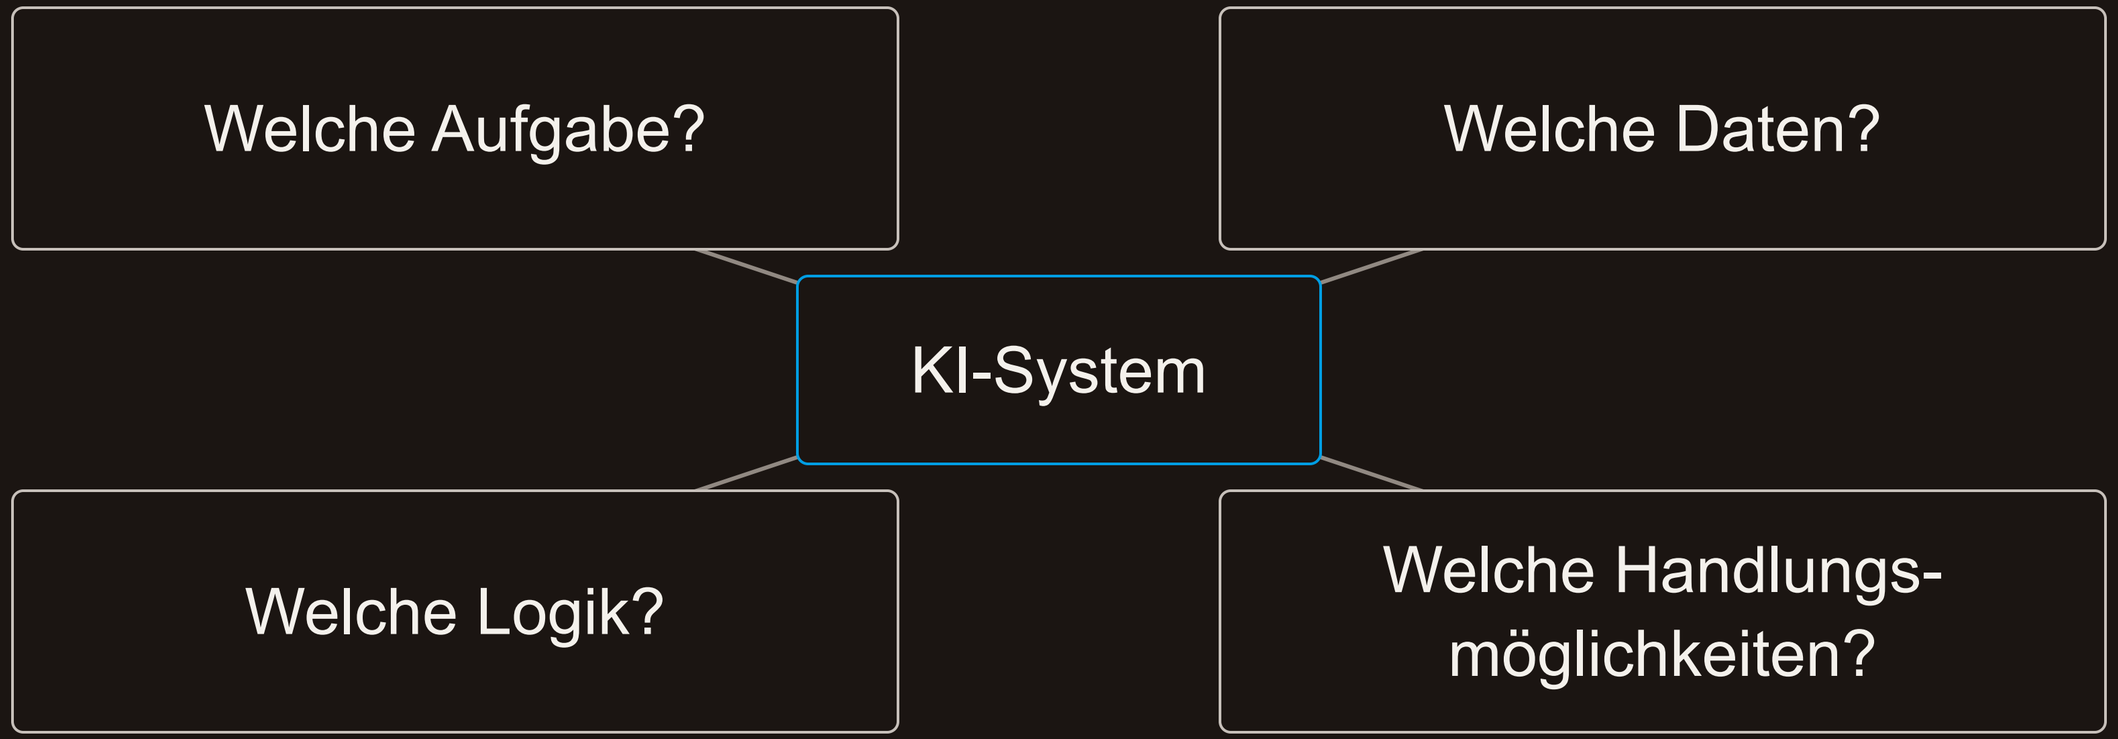
Eigene Übersetzung nach Rich (1983)

Eine beschreibt das System. Die andere zeigt eine zeitabhängige Forschungsaufgabe.

„KI“ bezeichnet keine einzelne Technologie.



Agentische Systeme können Modelle, Regeln, Tools und Abläufe kombinieren.


Welche Aufgabe?
Welche Daten?
KI-System
Welche Logik?
Welche Handlungs-
möglichkeiten?

Menschen legen die Entscheidungslogik ausdrücklich fest.



Wenn der gesetzliche Grenzwert überschritten ist, wird die Charge gesperrt.

Wann Regeln gut funktionieren

01

Bekannte Regeln

02

Stabile Bedingungen

03

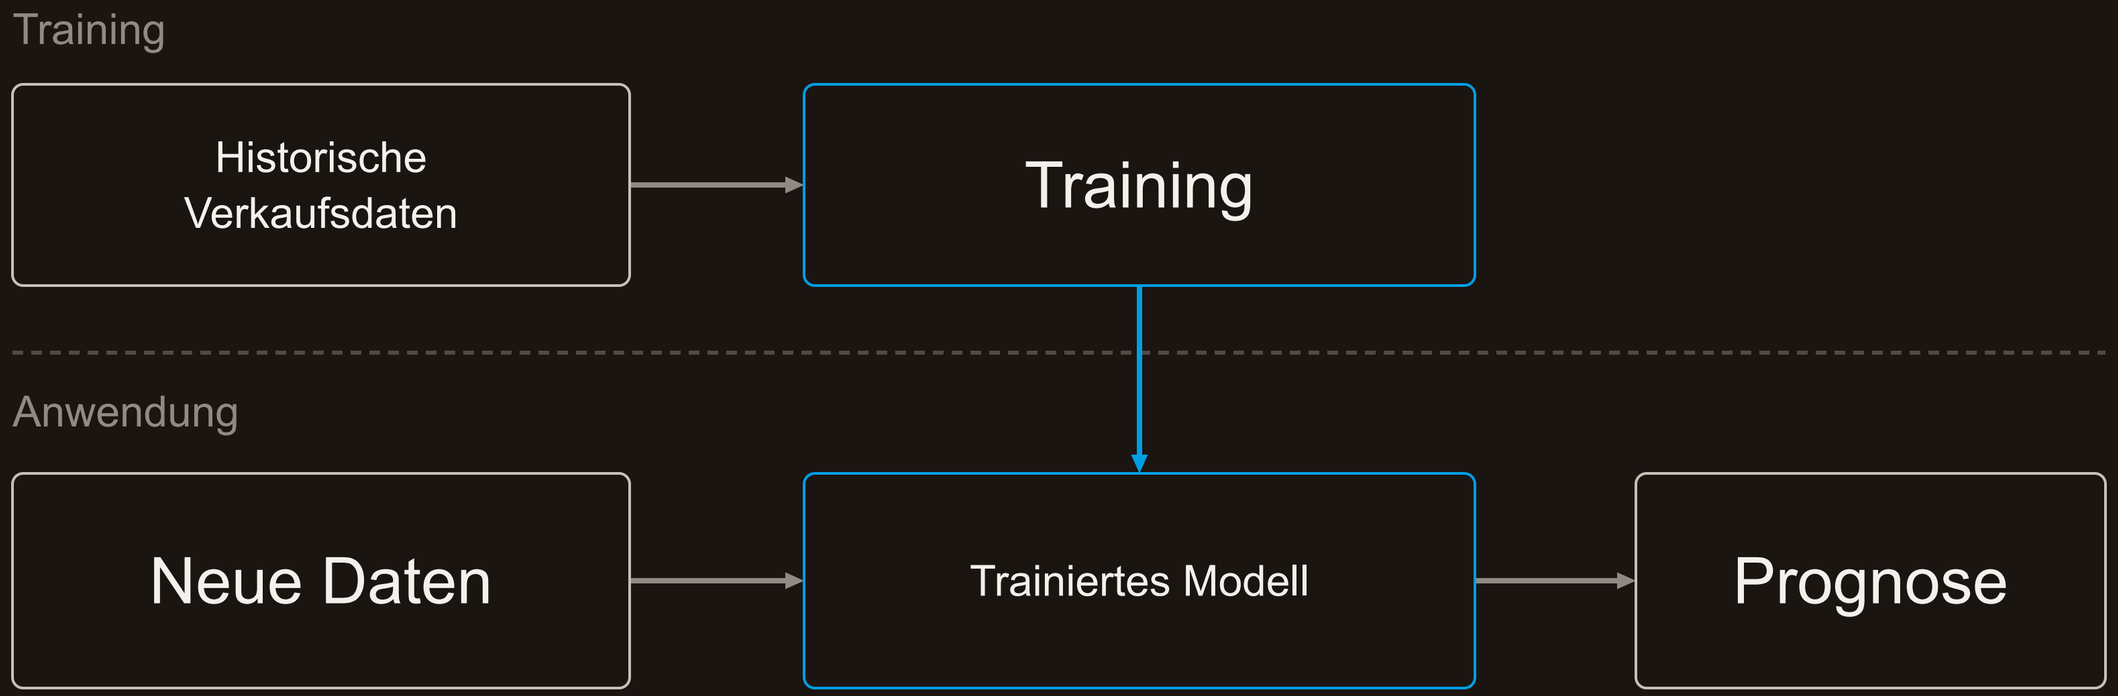
Eindeutige Eingaben

04

Begrenzte Ausnahmen

Klare Bedingungen machen Regeln nachvollziehbar und gut kontrollierbar.

Ein Modell lernt statistische Zusammenhänge aus Beispieldaten.



Beispiel: Absatzprognose aus historischen Verkaufsdaten.

Machine Learning hängt von Daten ab

Qualität

Messfehler verändern das Lernsignal.

Abdeckung

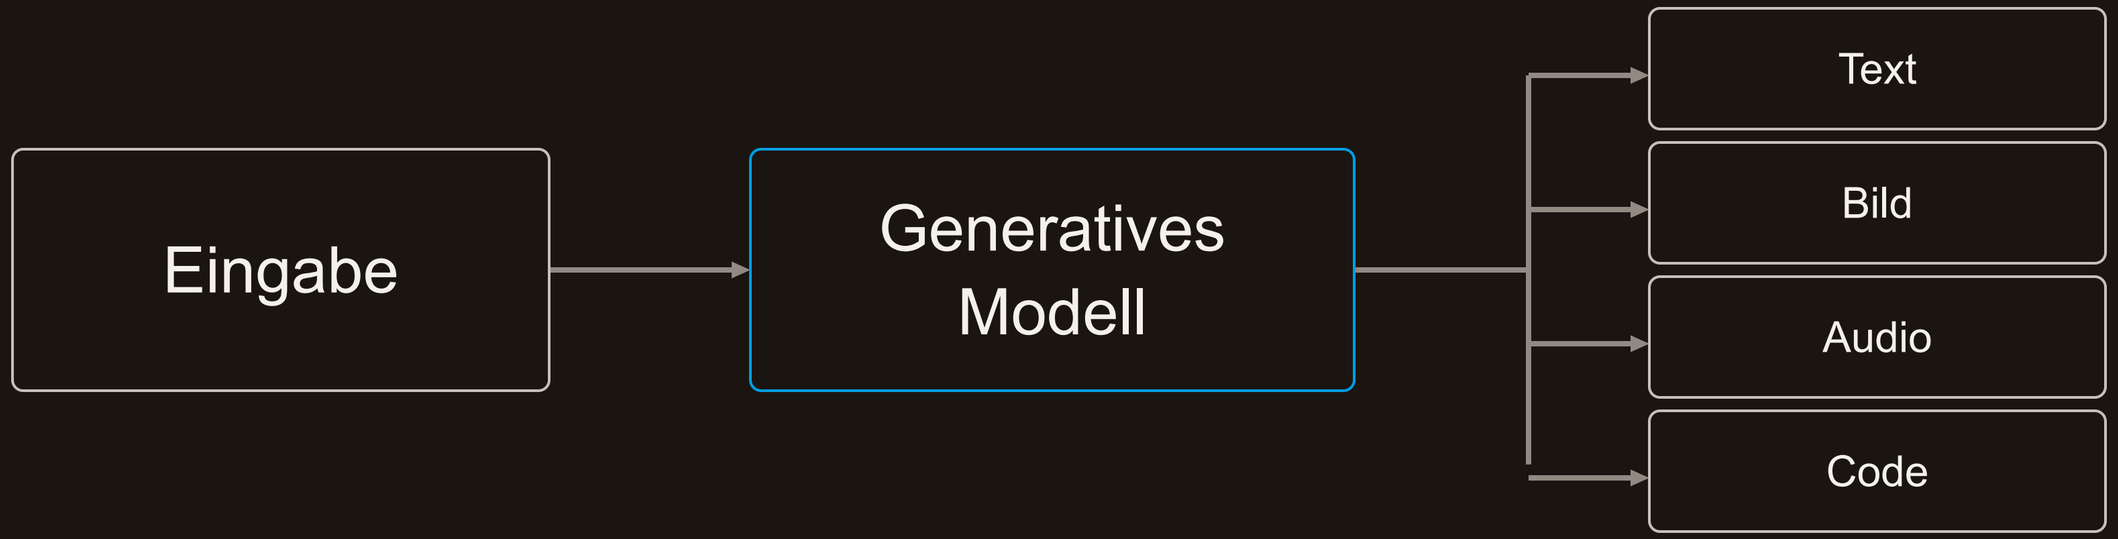
Fehlende Fälle bleiben schwer einschätzbar.

Aktualität

Alte Muster passen nicht immer zu neuen Lagen.

Daten prägen das Modellverhalten; gute Daten garantieren keine richtige Prognose.

Generative Modelle erzeugen neue Inhalte aus gelernten Mustern und aktuellem Kontext.

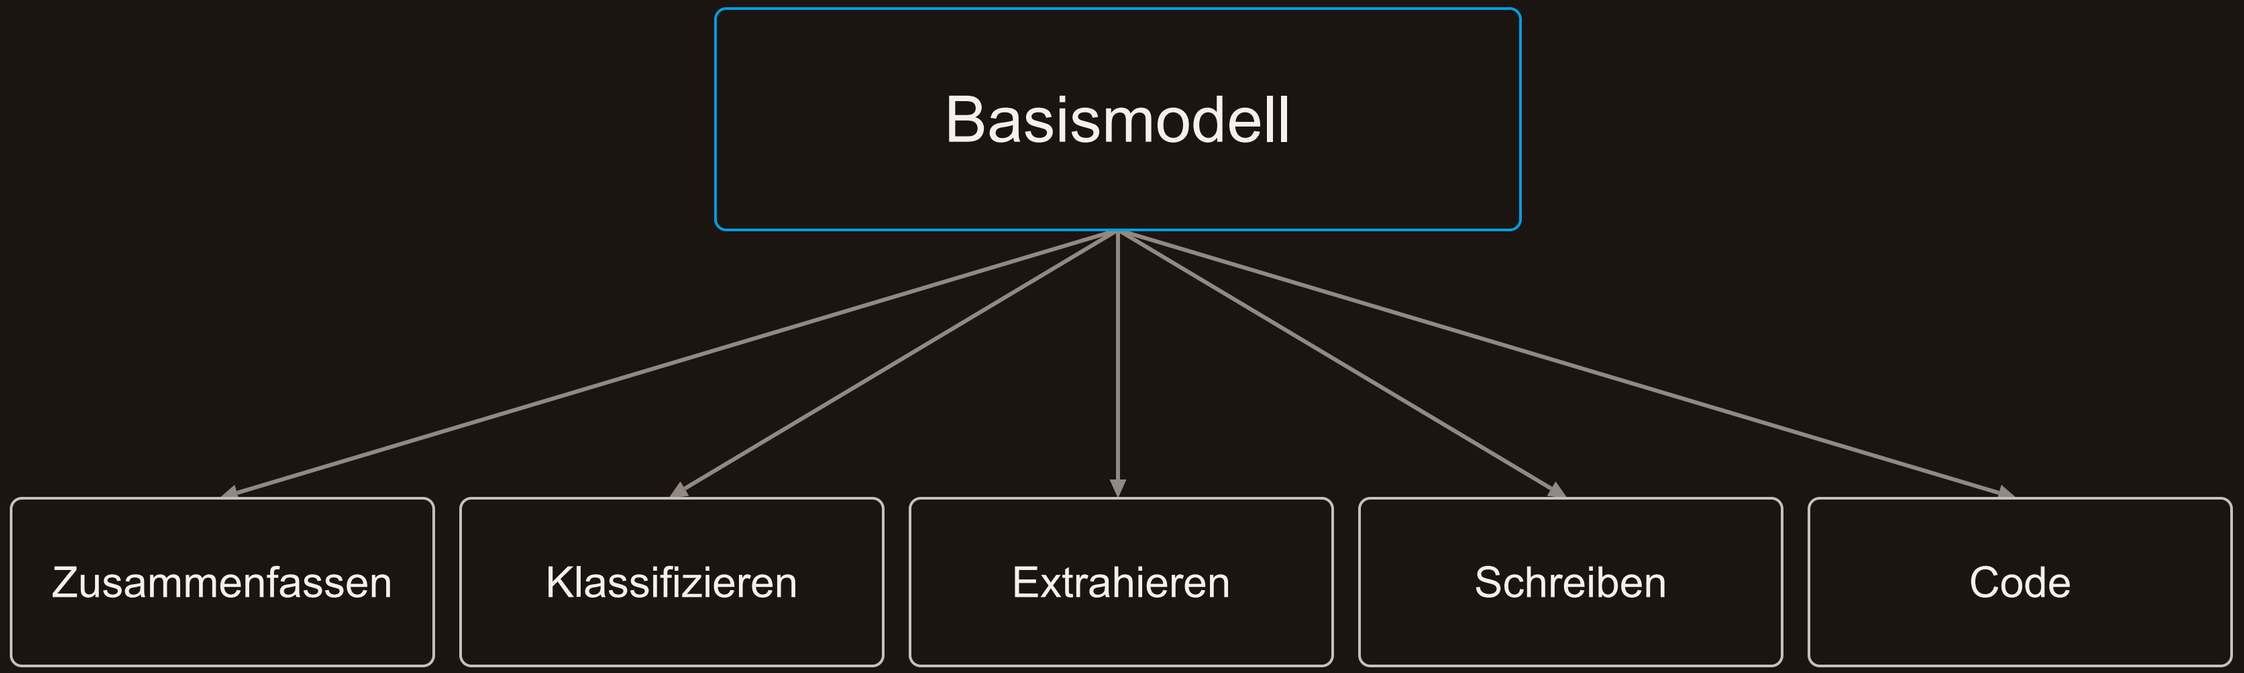


Eine erzeugte Ausgabe ist ein Entwurf, noch kein überprüftes Ergebnis.

Prinzip	Grundidee	Beispiel
Regelbasiert	Logik wird vorgegeben	Grenzwertregel
Machine Learning	Zusammenhänge werden gelernt	Nachfrageprognose
Generativ	Neue Inhalte werden erzeugt	Berichtsentwurf

Reale Anwendungen können mehrere Prinzipien kombinieren.

Ein breit trainiertes Basismodell kann für viele Aufgaben genutzt oder angepasst werden.



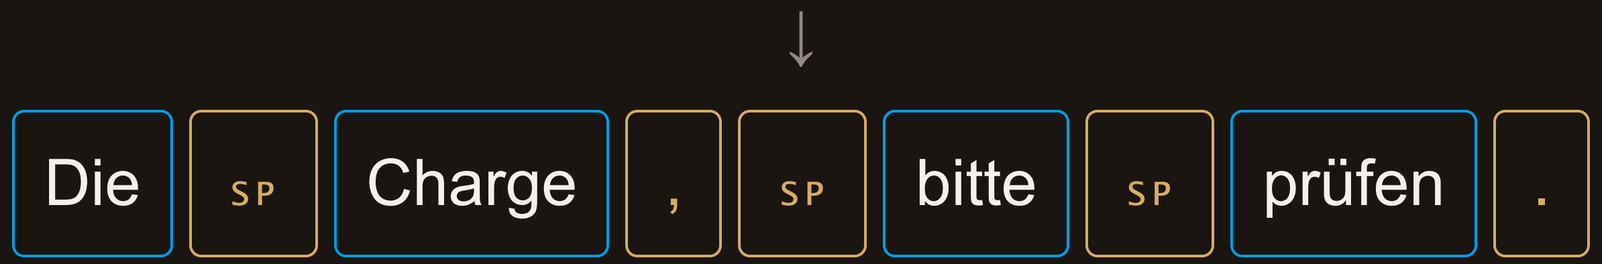
Ein großes, datengetriebenes Modell für Sprachverarbeitung und Spracherzeugung.



Das Modell wurde anhand vieler Beispiele trainiert.

Das Modell verarbeitet eine Folge kleiner Einheiten.

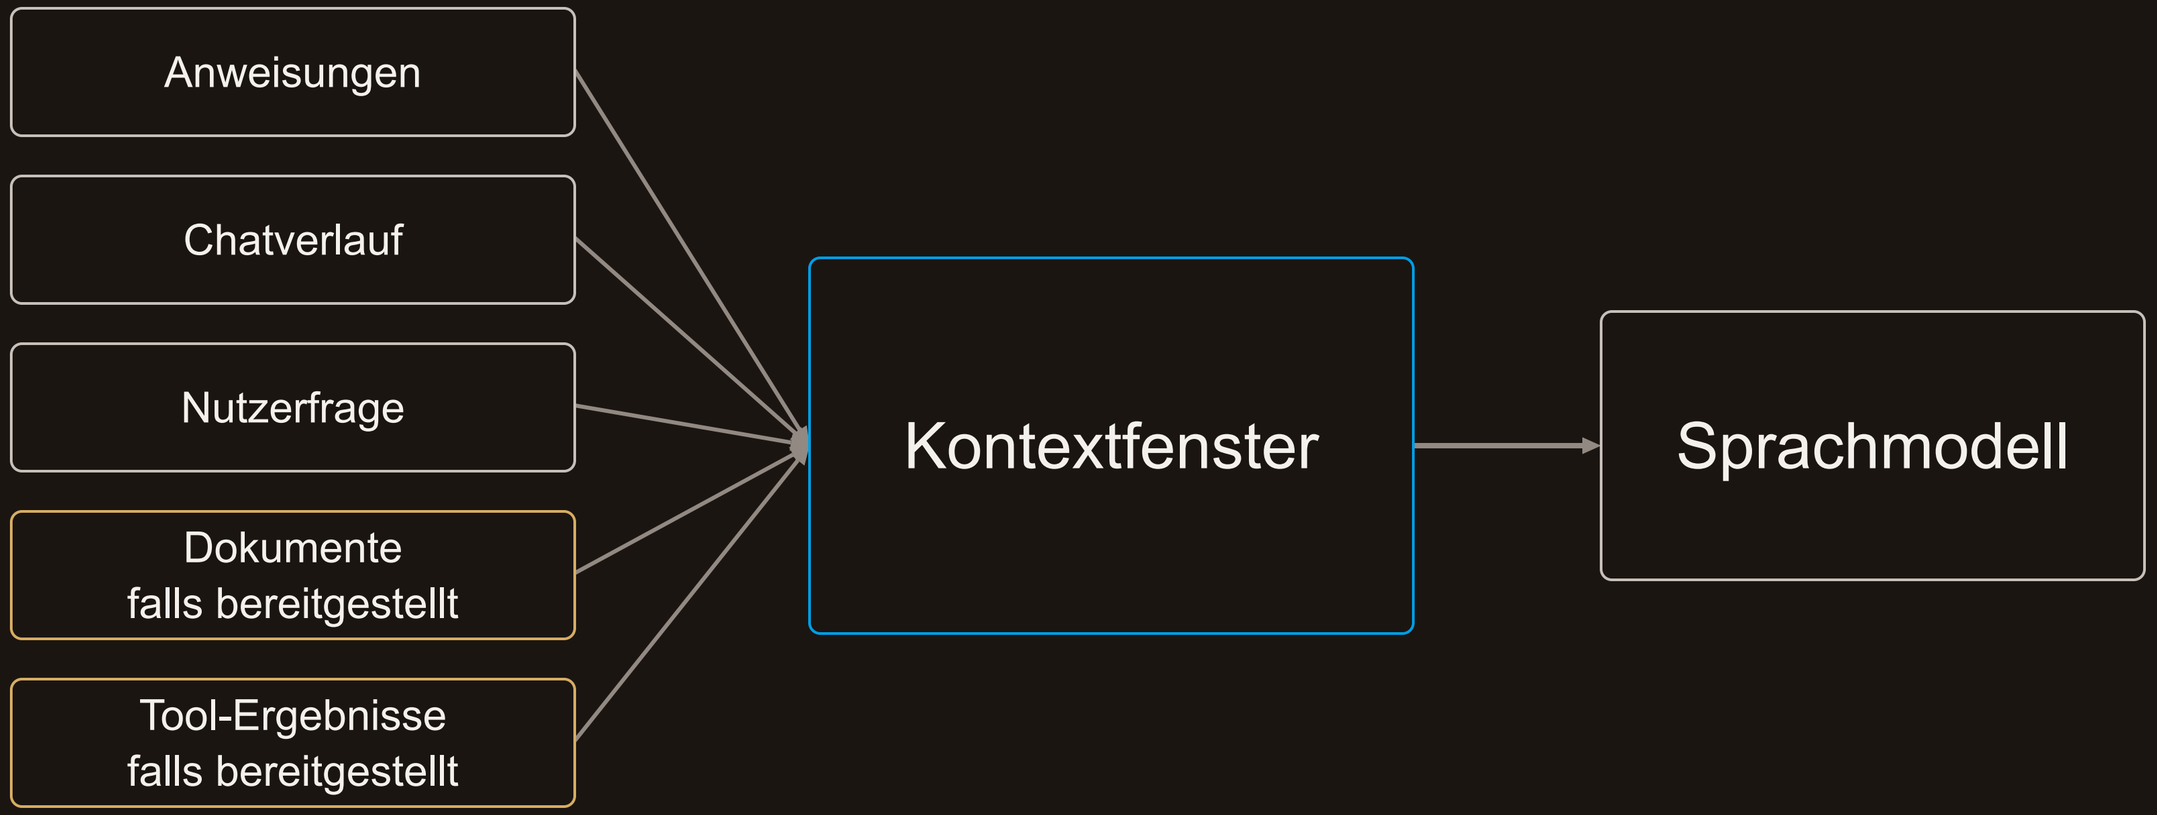
Die Charge, bitte prüfen.



SP = Leerzeichen

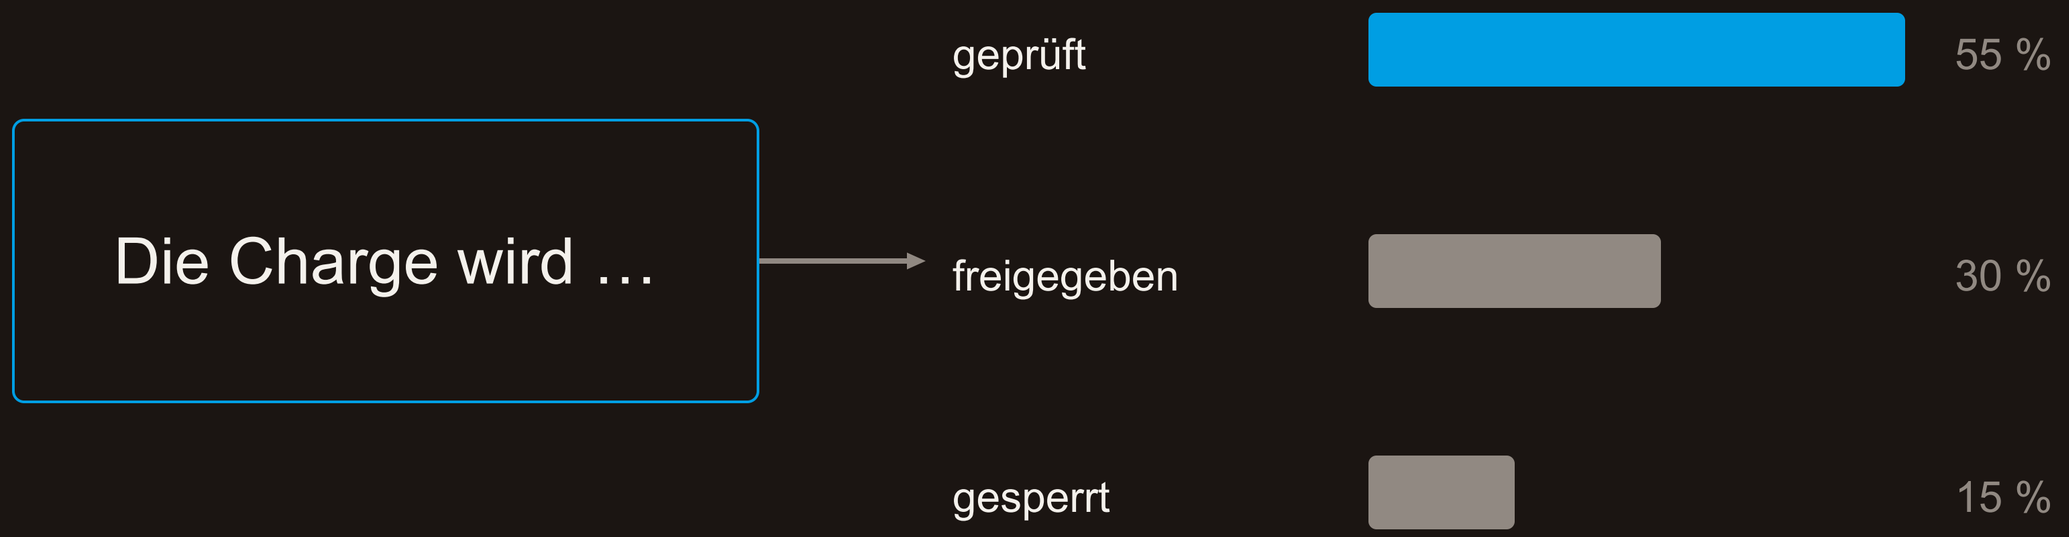
Schematische Zerlegung: Tatsächliche Token-Grenzen hängen vom Tokenizer ab.

Der Kontext ist der aktuelle Arbeitsraum



Eine Antwort entsteht aus dem Kontext, der beim aktuellen Aufruf vorliegt.

Das Modell berechnet Wahrscheinlichkeiten für mögliche Fortsetzungen.



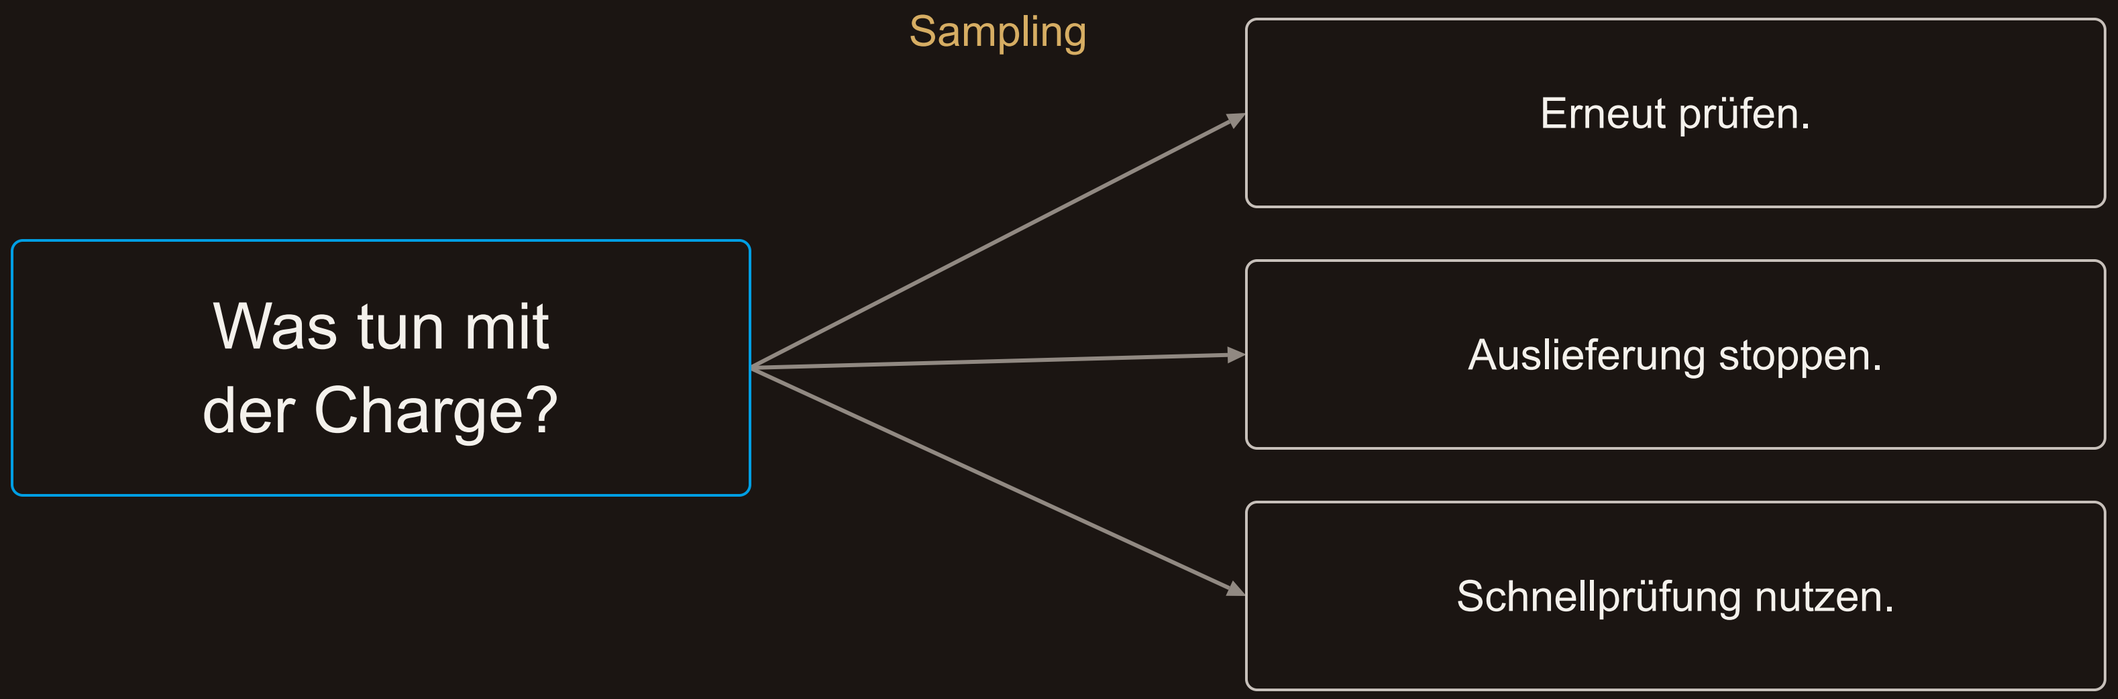
Fiktive Werte; sichtbare Wörter können aus mehreren Tokens bestehen.

Text entsteht Schritt für Schritt



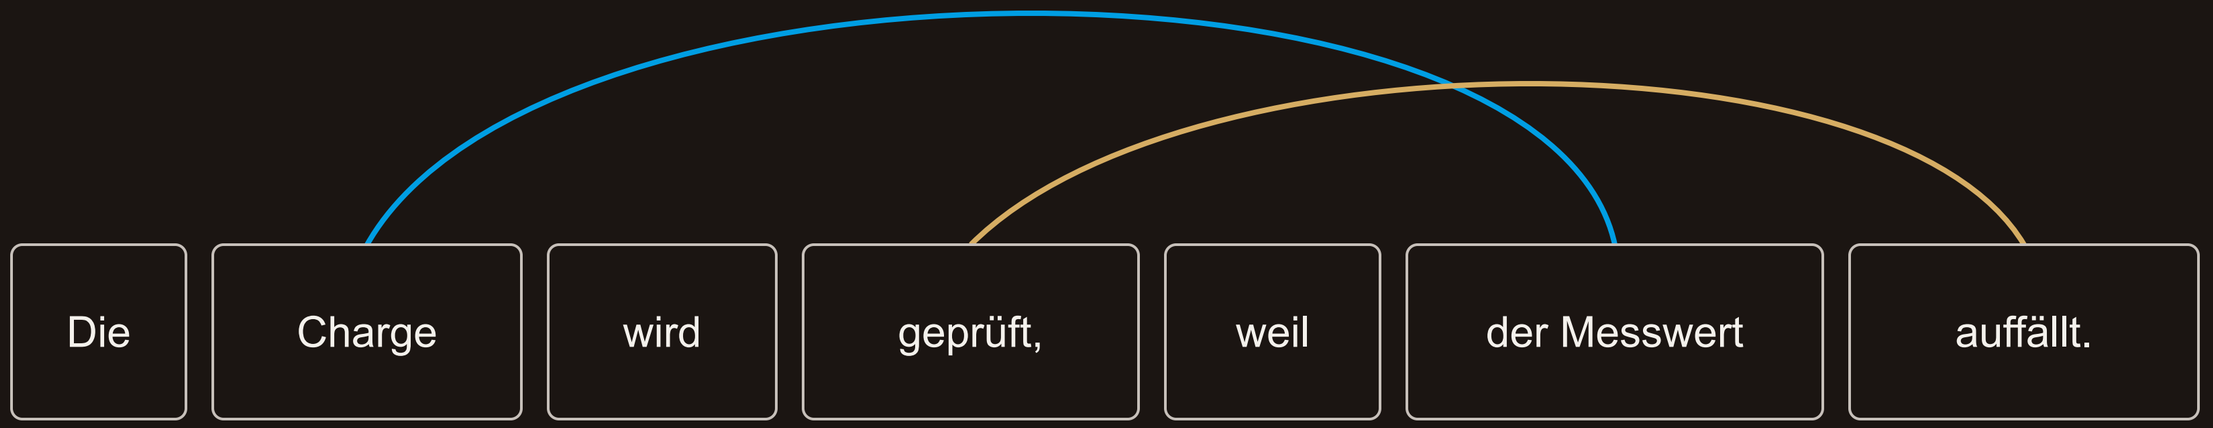
Nach jedem erzeugten Token wird die Folge erweitert und der Prozess wiederholt.

Je nach Auswahlverfahren sind verschiedene Fortsetzungen möglich.



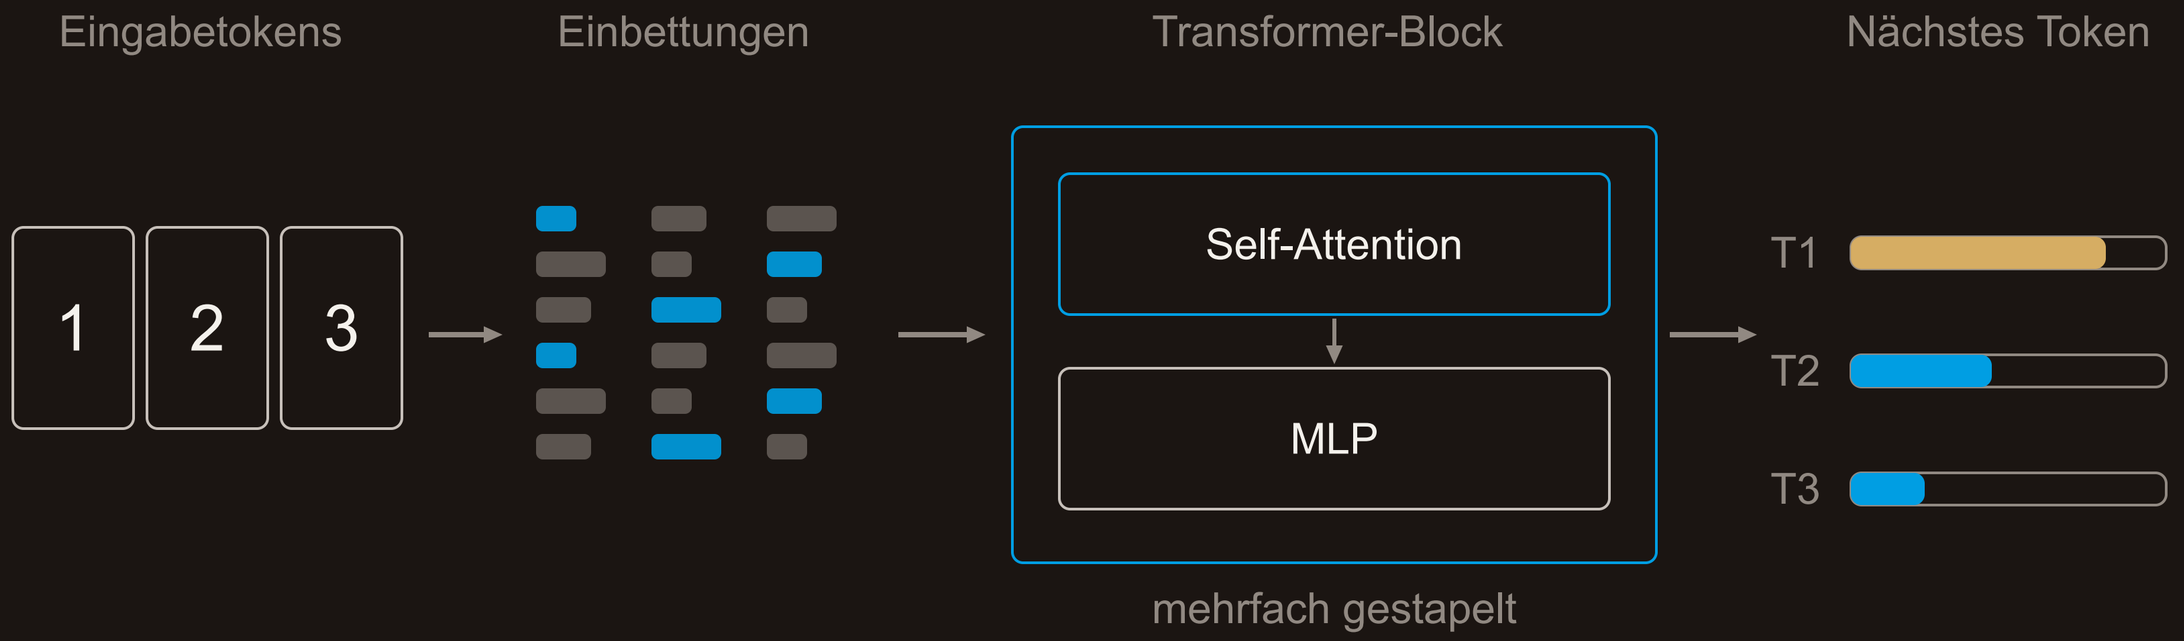
Sampling kann Variation erzeugen.

Transformer modellieren Beziehungen zwischen Positionen einer Eingabe.



Schematische Verbindungen, keine gemessenen Attention-Gewichte.

Vom Eingabetoken zur Vorhersage des nächsten Tokens.



Transformer Explainer öffnen ↗

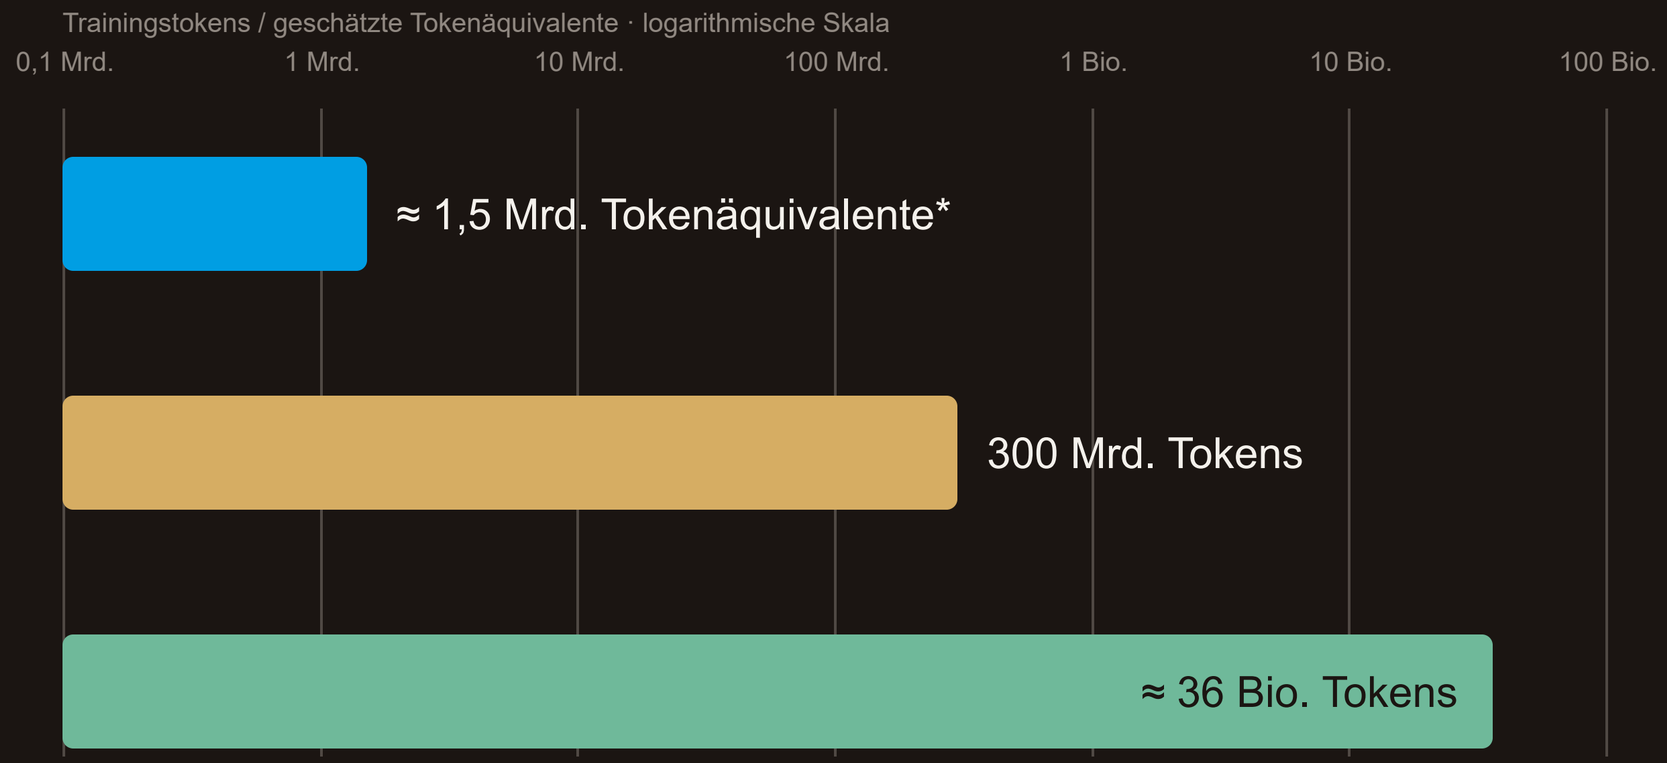
Schematische Darstellung · interaktive Demo mit GPT-2 small · Polo Club, Georgia Tech

Das Modell lernt statistische Muster aus großen Datenmengen.



Mensch und Sprachmodelle: verarbeitete Sprachmenge

≈ 200×
GPT-3 gegenüber Mensch · grob



* Mensch: geschätzte 1,15 Mrd. englische Wörter bis 60 J. ≈ 1,5 Mrd. Tokenäquivalente (grobe Umrechnung).
Tokenisierer unterscheiden sich. Der Vergleich zeigt Größenordnungen, nicht Lernweise oder Qualität.

Quellen: Wingfield & Connell (2022) · Brown et al. (2020) · Qwen-Team (2025) · OpenAI Token Guide

Welche Daten nutzen ChatGPT-Modelle?

OpenAI nennt drei Hauptquellen für die Entwicklung seiner Modelle.

01

Öffentlich zugängliche Inhalte

02

Daten aus Partnerschaften

03

Beiträge von Nutzenden, Trainern und Forschenden

Historisches Beispiel GPT-3

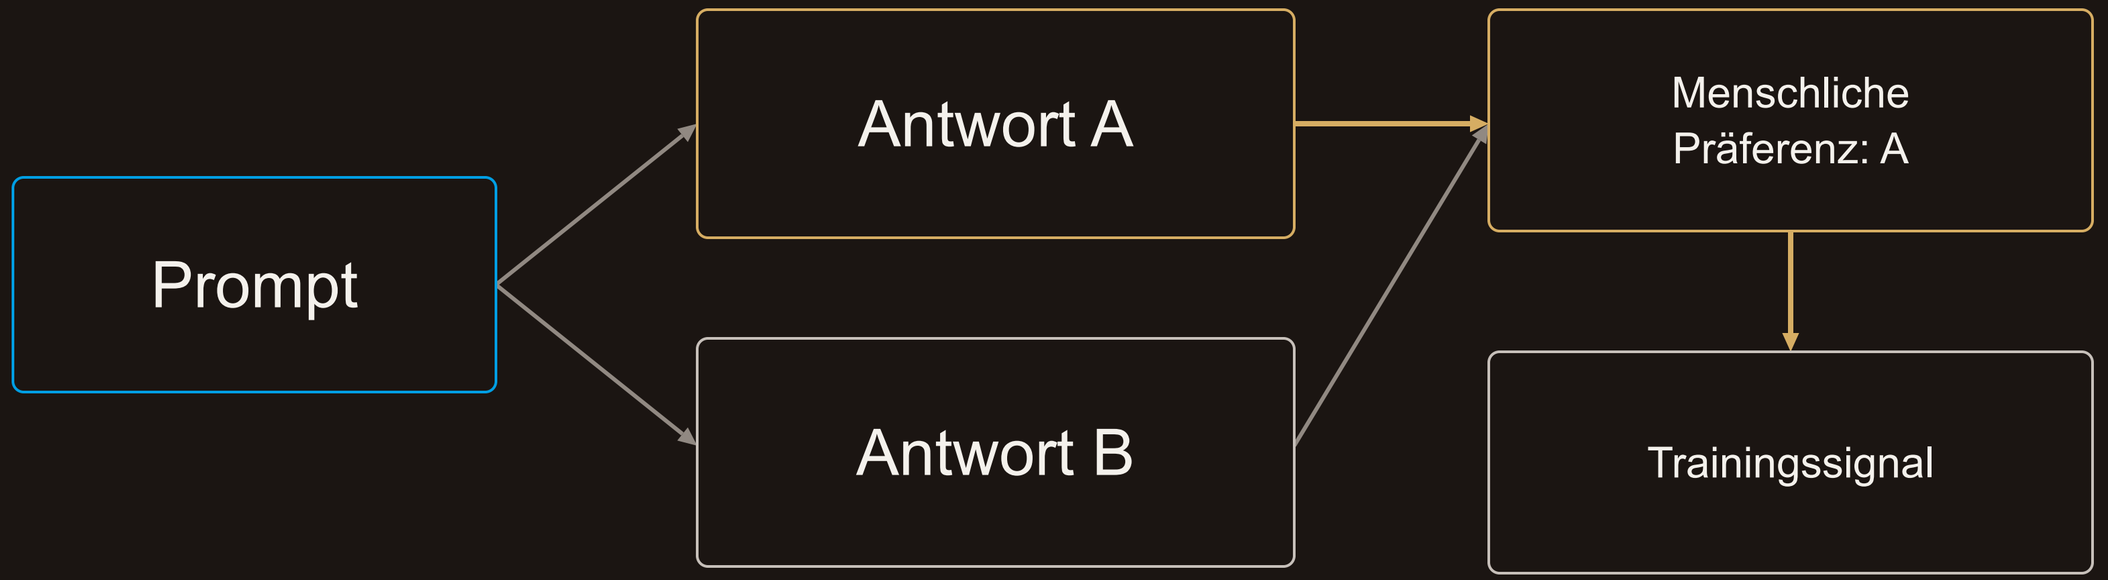
Common Crawl · WebText2 · Bücher · Wikipedia

Keine vollständige Aufschlüsselung für jedes aktuelle ChatGPT-Modell veröffentlicht.

Beispielantworten helfen dem Modell, Anweisungen besser zu befolgen.

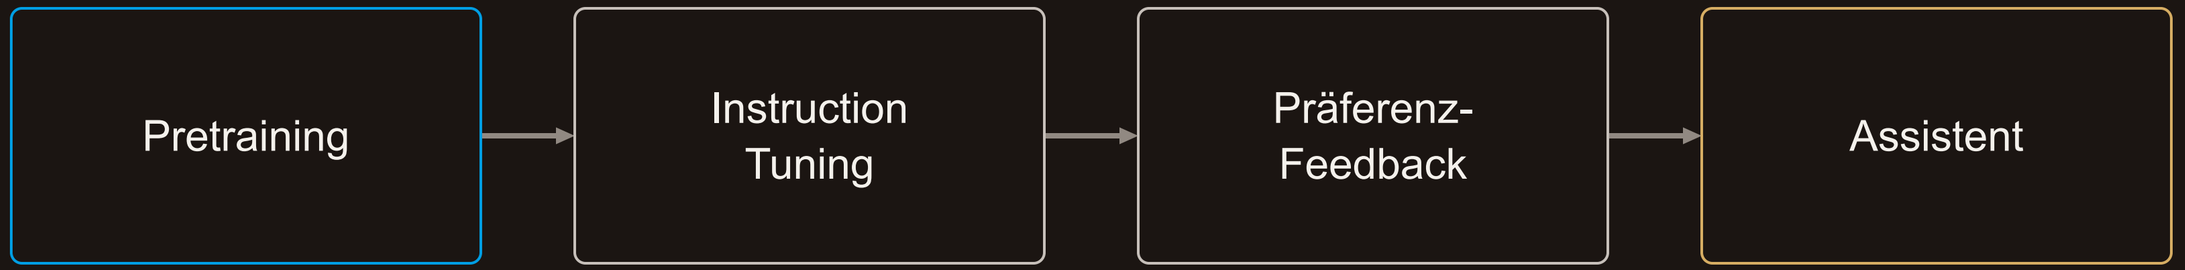


Bewertete Antworten liefern ein weiteres Trainingssignal.



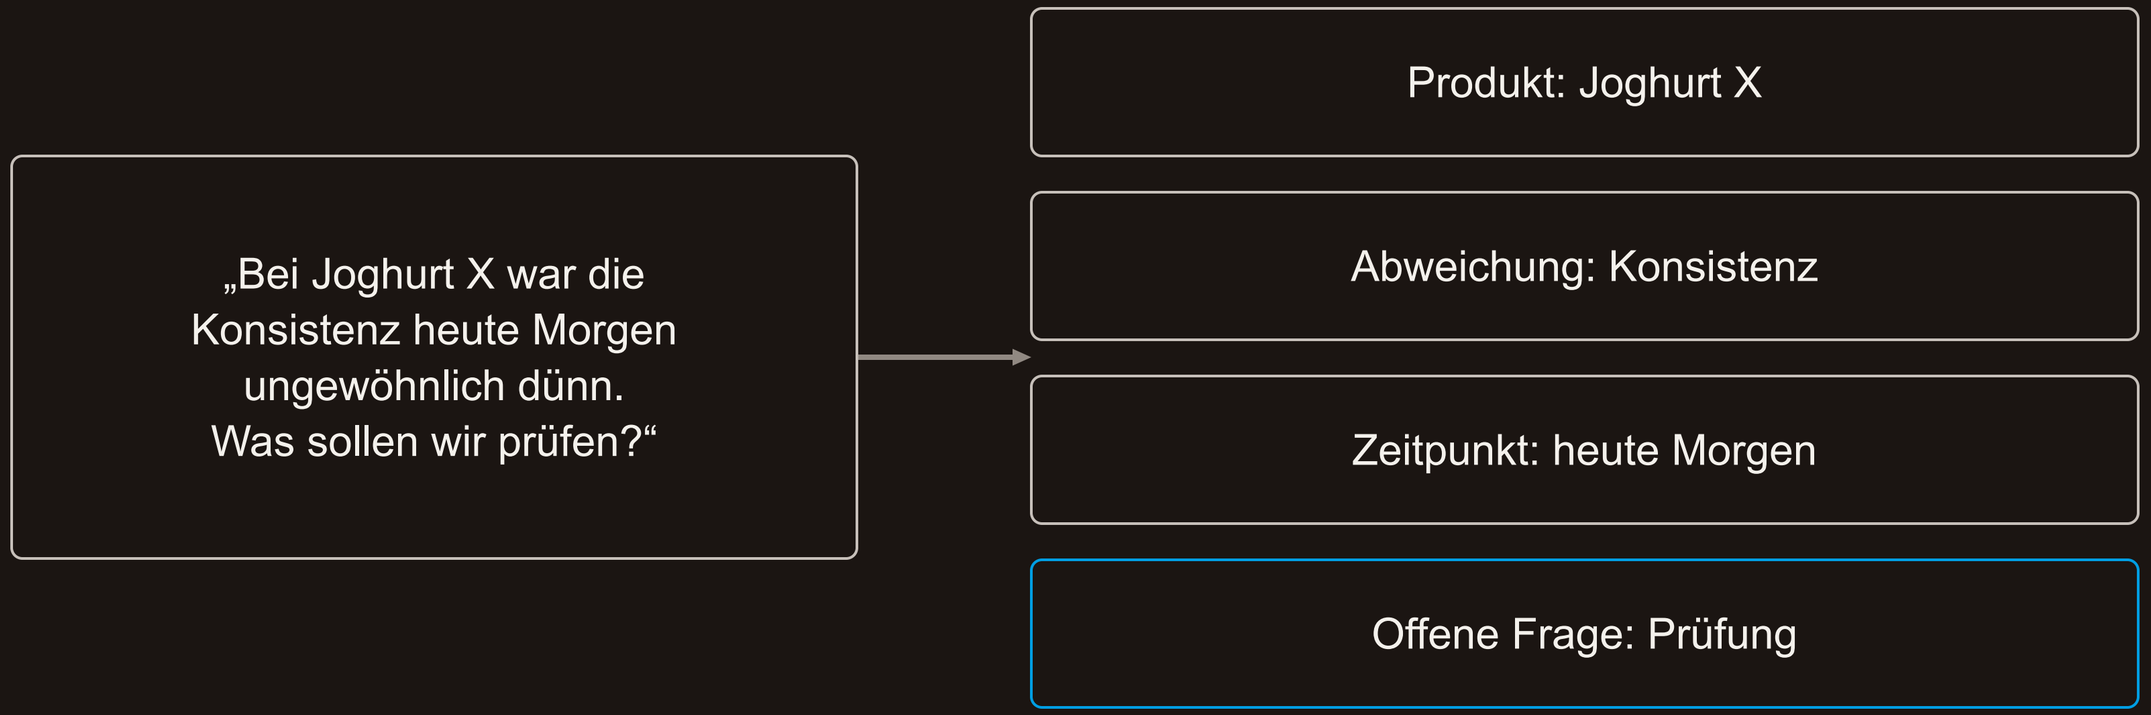
Eine Präferenz ist eine Bewertung, keine fachliche Wahrheitsprüfung.

Vom Basismodell zum Assistenten



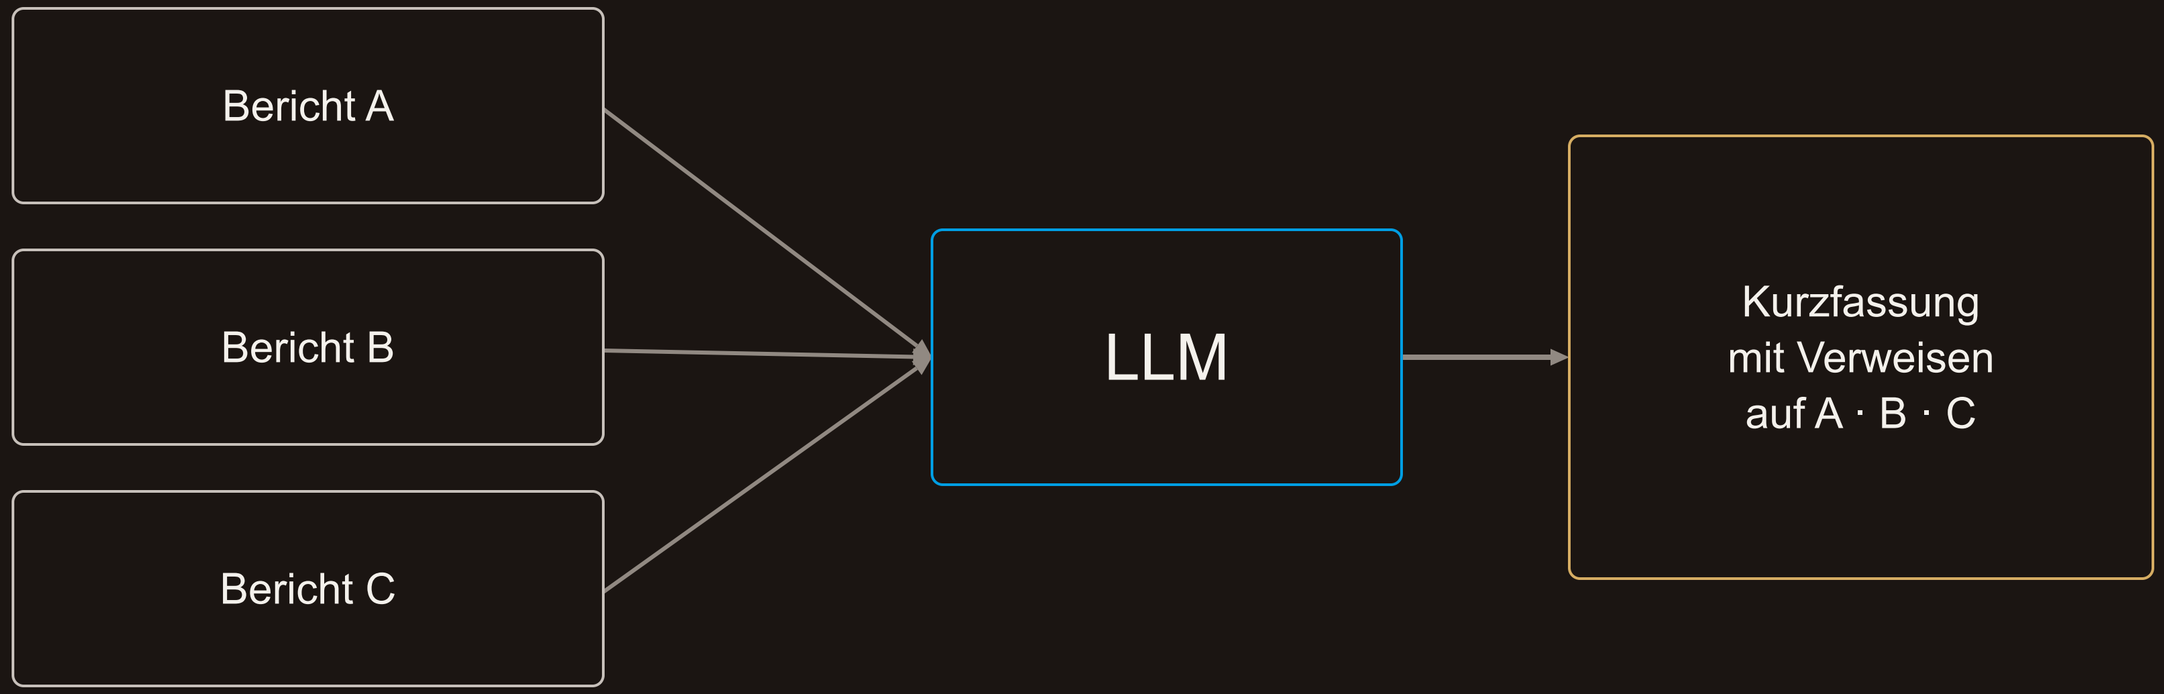
Post-Training verbessert die Nutzbarkeit, garantiert aber keine Fehlerfreiheit.

Ein LLM kann unstrukturierte Sprache in eine prüfbare Form bringen.



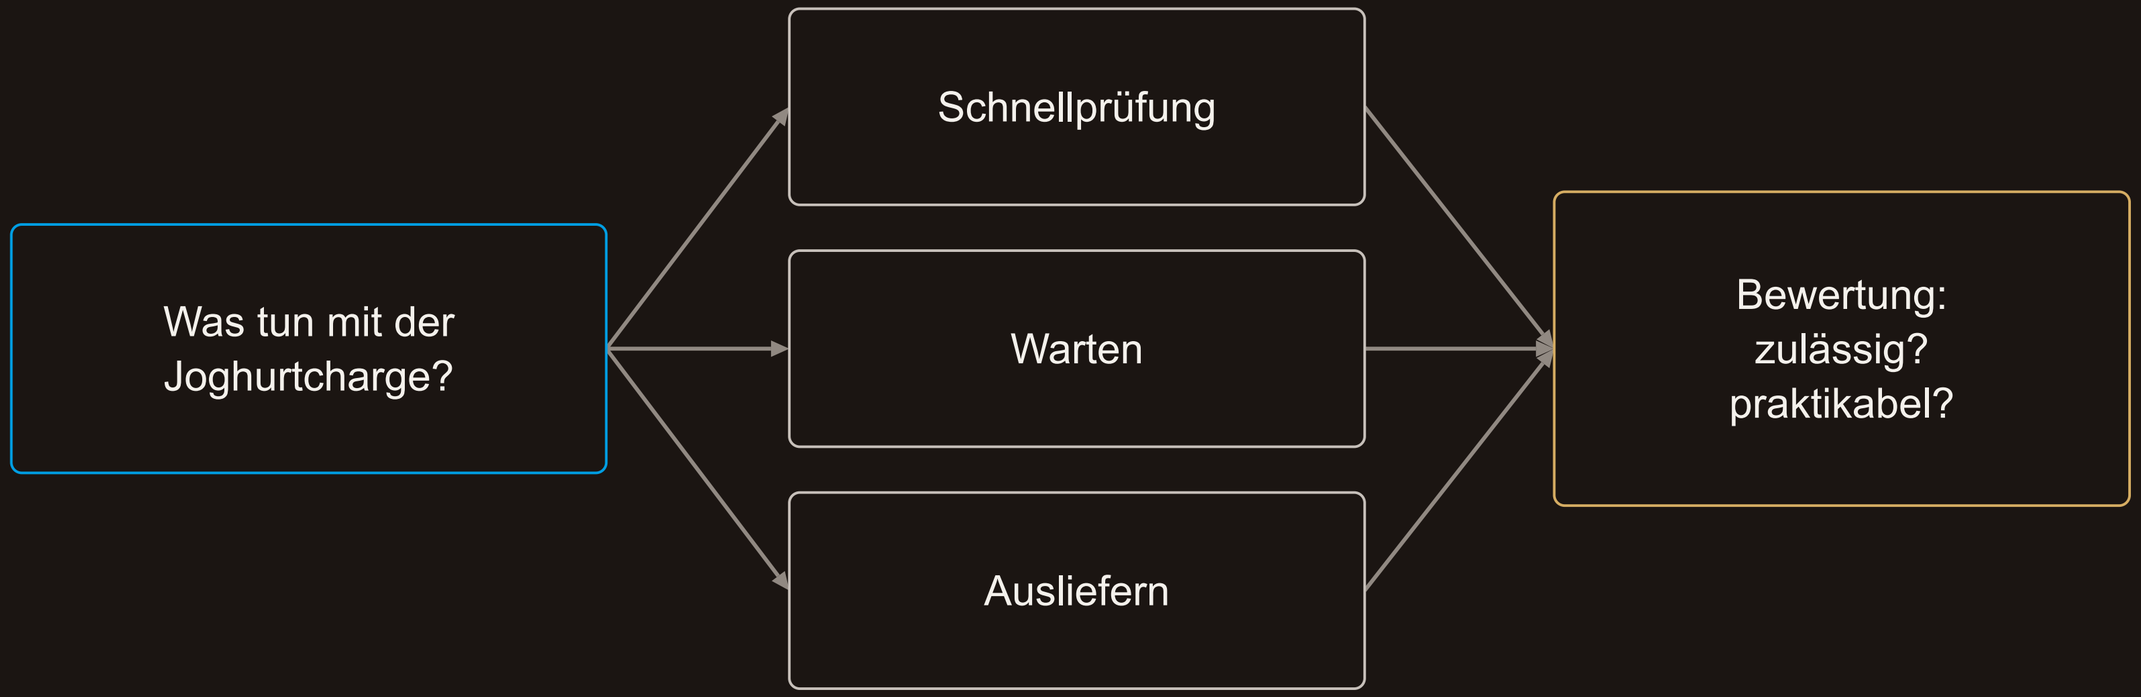
Die Felder müssen bei wichtigen Fällen fachlich kontrolliert werden.

Ein LLM kann mehrere Texte zu einer kurzen Übersicht zusammenführen.



Für Entscheidungen bleiben die Originalquellen wichtig.

Ein LLM kann Alternativen, Hypothesen und Formulierungen vorschlagen.



Vorschlagen und Bewerten sind getrennte Schritte.

Sprachliche Überzeugungskraft und sachliche Richtigkeit sind verschieden.

	überzeugend	wenig überzeugend
belegt	prüfbare Aussage, klar formuliert	prüfbare Aussage, holprig formuliert
nicht belegt	flüssige Behauptung ohne Grundlage	unsichere Behauptung ohne Grundlage

Für Entscheidungen zählt der Beleg, nicht der Sprachstil.

Ein Modell kann plausible Details ergänzen, die im Material nicht stehen.

Gegebener Fall

Ein Messwert liegt knapp außerhalb des internen Zielbereichs. Die Ursache ist unklar.

Fiktive Modellantwort

„Die Abweichung entstand durch eine defekte Kühlanlage. Deshalb sollte die Charge gesperrt werden.“

Die markierte Ursache ist im Fall nicht belegt.

Auch mit Lücken im Kontext kann eine Antwort vollständig klingen.

Fallakte

Messwert: auffällig

Grenzwert: eingehalten

Wiederholungsmessung: offen

→

Antwort

„Die Charge kann nach Bewertung aller Messwerte freigegeben werden.“

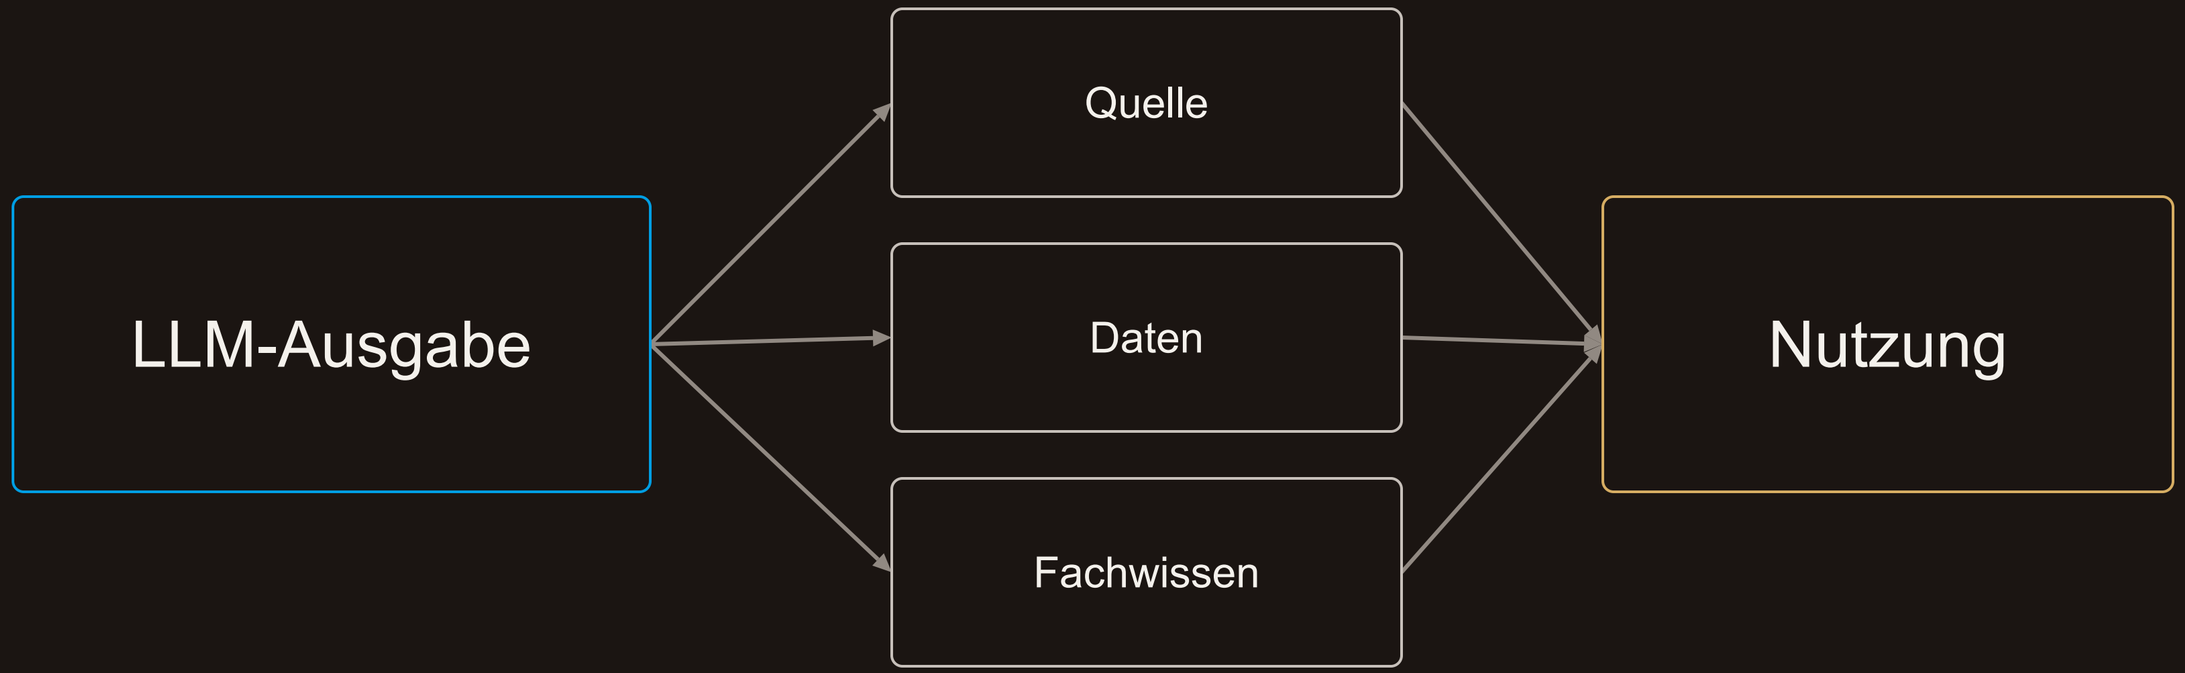
Die Formulierung verrät nicht zuverlässig, welche Angaben fehlen.

Wichtige Information kann trotz Bereitstellung übersehen werden.



Schematische Darstellung; Befund hängt von Modell und Aufgabe ab.

Kritische Aussagen prüfen wir an Quelle, Daten und Fachwissen.



Eine Quellenangabe muss die konkrete Aussage tragen.

Was soll das Modell genau tun?

01	02	03	04	05
Aufgabe	Kontext	Kriterien	Ausgabeformat	Unsicherheit und Prüfung

„Ordne die Handlungsoptionen für die auffällige Joghurtcharge.“

Welche Informationen soll das Modell verwenden?



Messwert knapp außerhalb des Zielbereichs; Grenzwert eingehalten; Wiederholungsmessung dauert vier Stunden.

Ziele und Grenzen gehören in die Aufgabe.



Produktqualität · Lieferfähigkeit · Kosten · rechtliche Anforderungen · Entscheidung in 30 Minuten

Ein Format kann Aussagen leichter prüfbar machen.



„Trenne Fakten, Annahmen, offene Fragen und Handlungsoptionen.“

Frage gezielt nach fehlenden Informationen und unsicheren Annahmen.



„Welche Angaben fehlen für eine belastbare Einschätzung?“

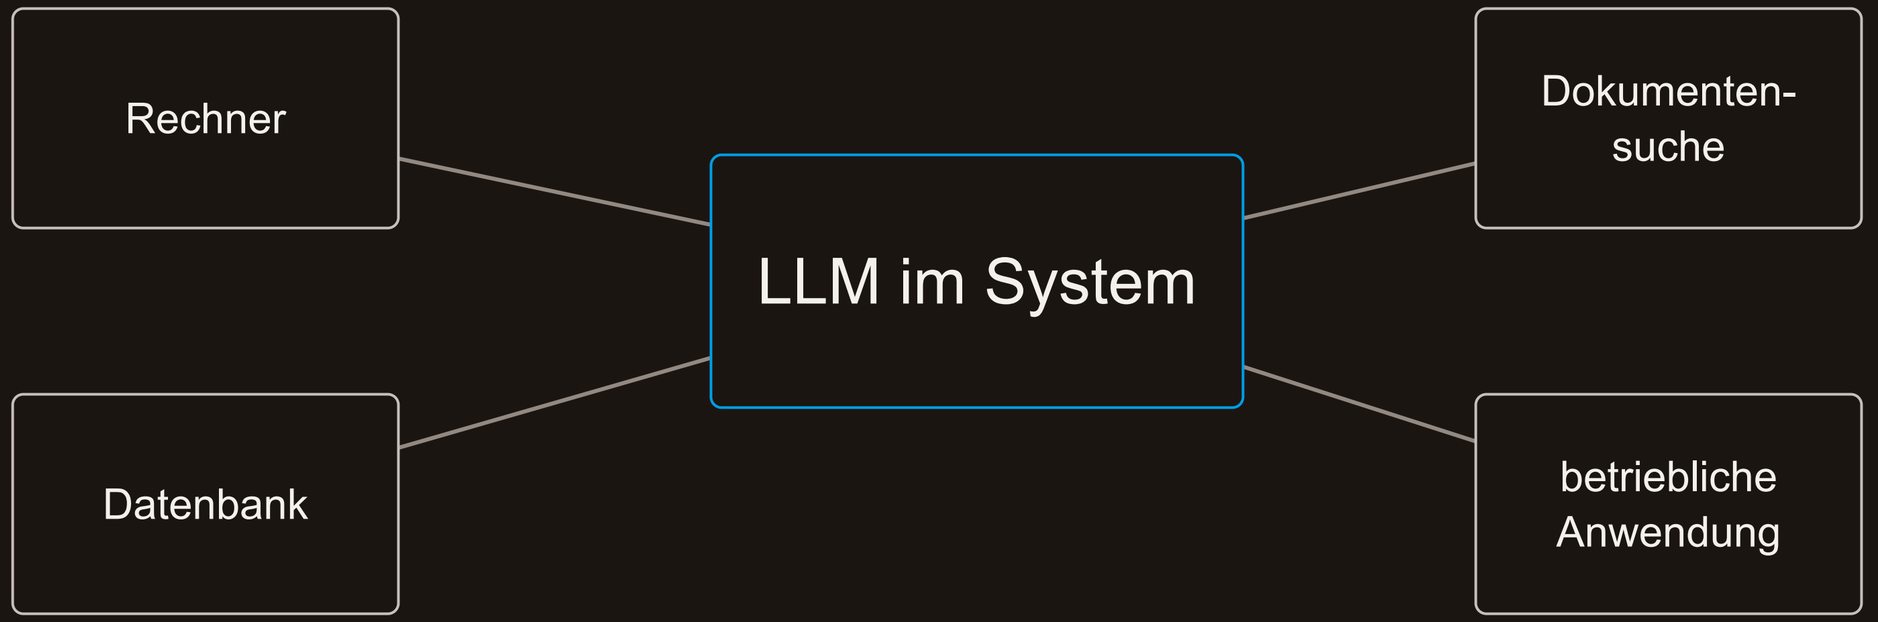
Auch diese Nachfrage garantiert nicht, dass alle Lücken erkannt werden.

Eine Suche kann relevante Passagen in den aktuellen Modellkontext bringen.



Bereitstellen ist kein neues Training.

Ein System kann dem Modell Werkzeuge zur Verfügung stellen.



Zugriffsrechte und erlaubte Aktionen werden im System festgelegt.

Das Modell kann eine richtige Zahl falsch deuten oder für die falsche Frage verwenden.



Die Interpretation bleibt eine Prüfstelle.

Wählt für jedes Problem die am besten geeignete technische Lösung:

- einfacher regelbasierter Workflow
- maschinelles Lernen
- Sprachmodell
- agentisches KI-System
- Kombination mehrerer Ansätze

Begründet eure Wahl jeweils kurz.

Entscheidend ist nicht, welche Lösung am modernsten ist, sondern welche das Problem möglichst einfach, zuverlässig und angemessen löst.

Eine robuste LLM-Arbeitsroutine



Bei Bedarf beginnt die Schleife erneut mit einer präziseren Aufgabe.

Ein LLM ist ein leistungsfähiger
Generator und Strukturierer –
aber kein Wahrheitsautomat
und kein Verantwortlicher.

Weiterlesen: Sprachmodelle in der Praxis

Einstieg

Jurafsky & Martin
Speech and Language Processing

NIST AI 600-1
Generative AI Profile · Risiken und Kontrolle

Vertiefung

Lewis et al. (2020)
Retrieval-Augmented Generation

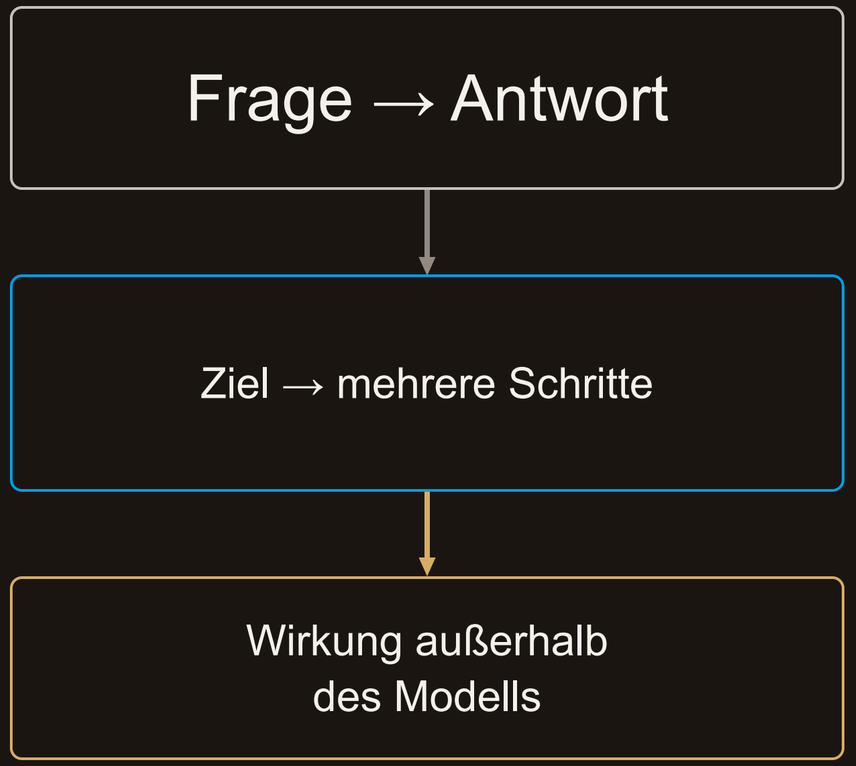
Liu et al. (2024)
Lost in the Middle · langer Kontext

Schick et al. (2023)
Toolformer · Werkzeuge nutzen

Vertiefung · KI

Was ändert sich, wenn KI handeln kann?

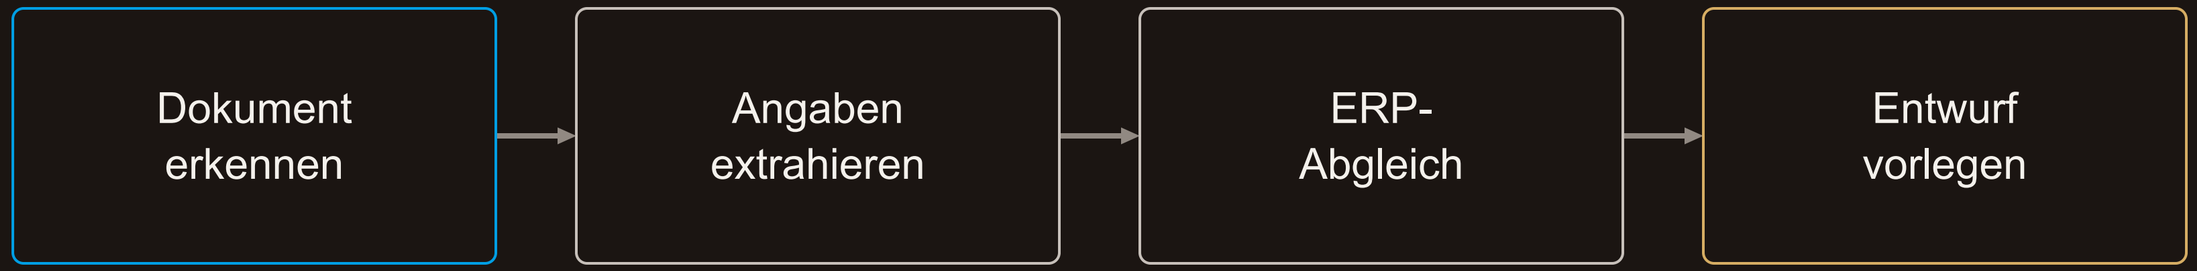
Vom Sprachmodell zum agentischen System.



Eine Eingabe führt zu einer Antwort.

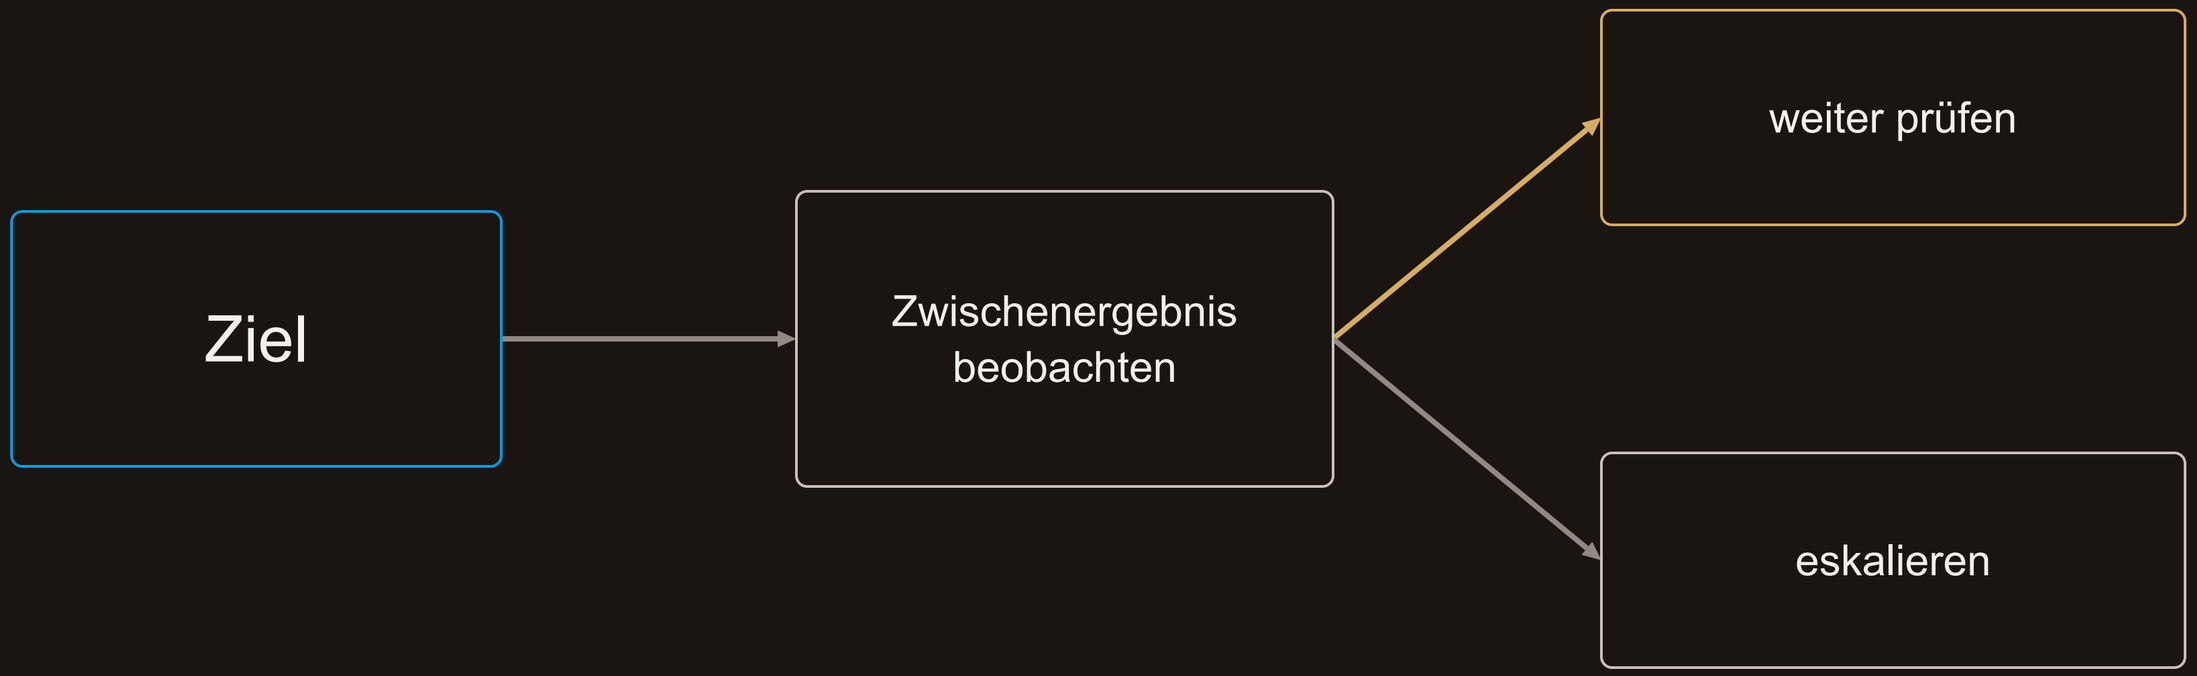


Mehrere Schritte machen ein System noch nicht zum Agenten.



Die Übergänge sind vorab festgelegt.

Der weitere Ablauf hängt von Ziel, Ergebnis und aktuellem Zustand ab.



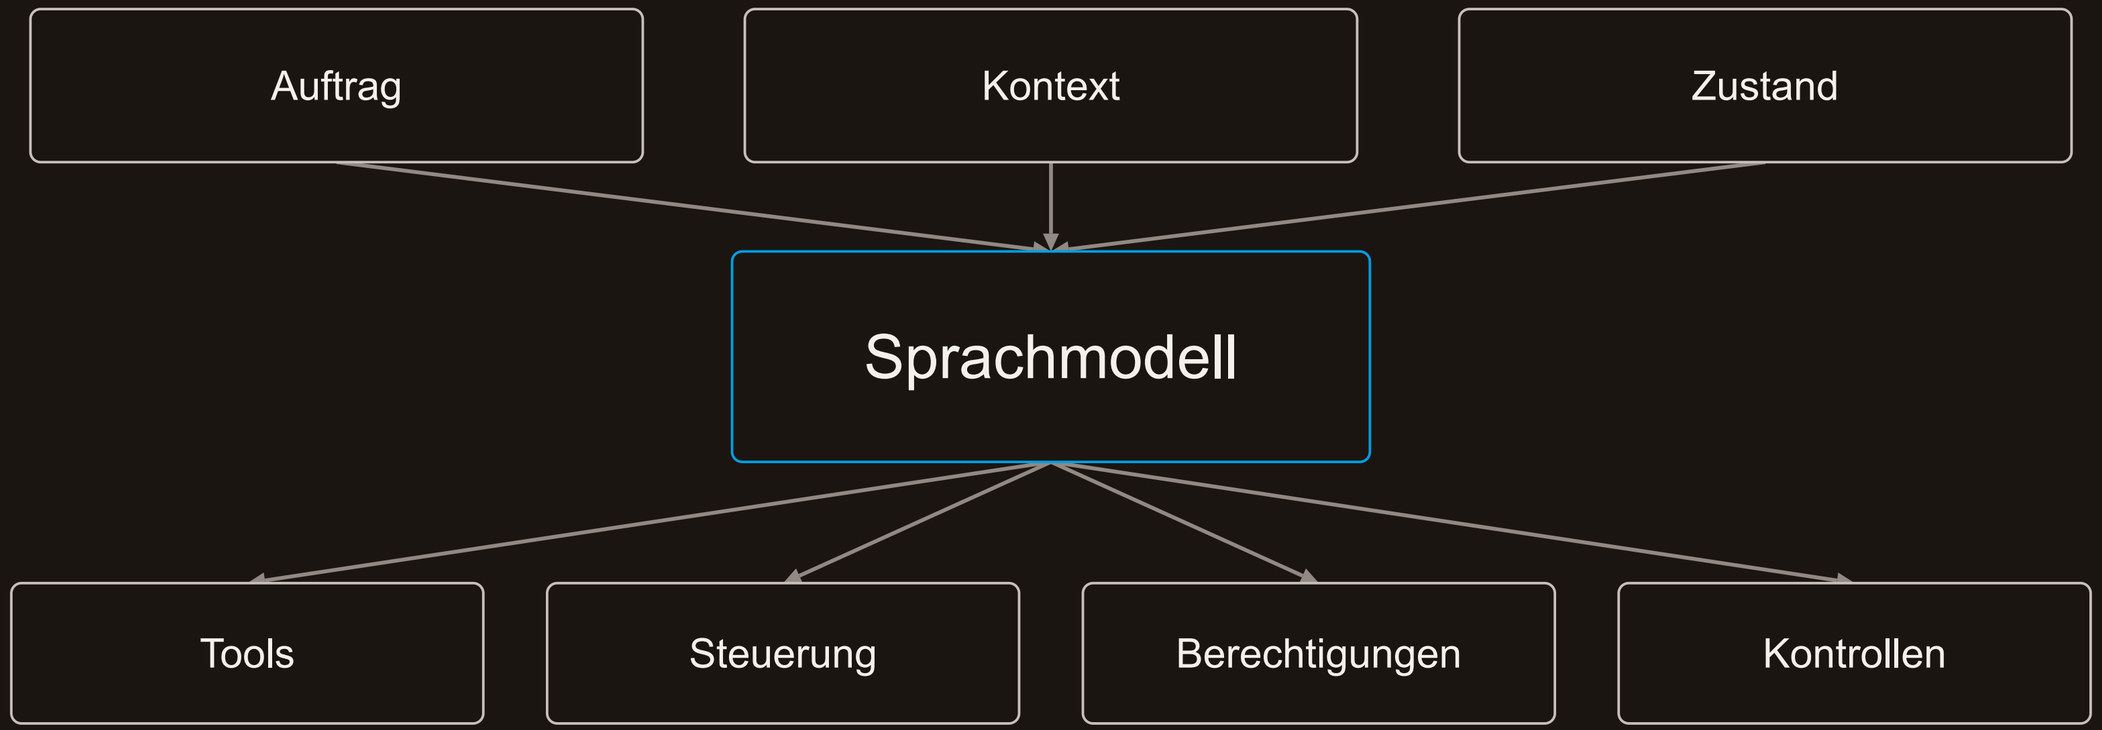
Der nächste Weg wird erst nach dem Zwischenergebnis gewählt.

Chatbot, Workflow und Agent im Vergleich

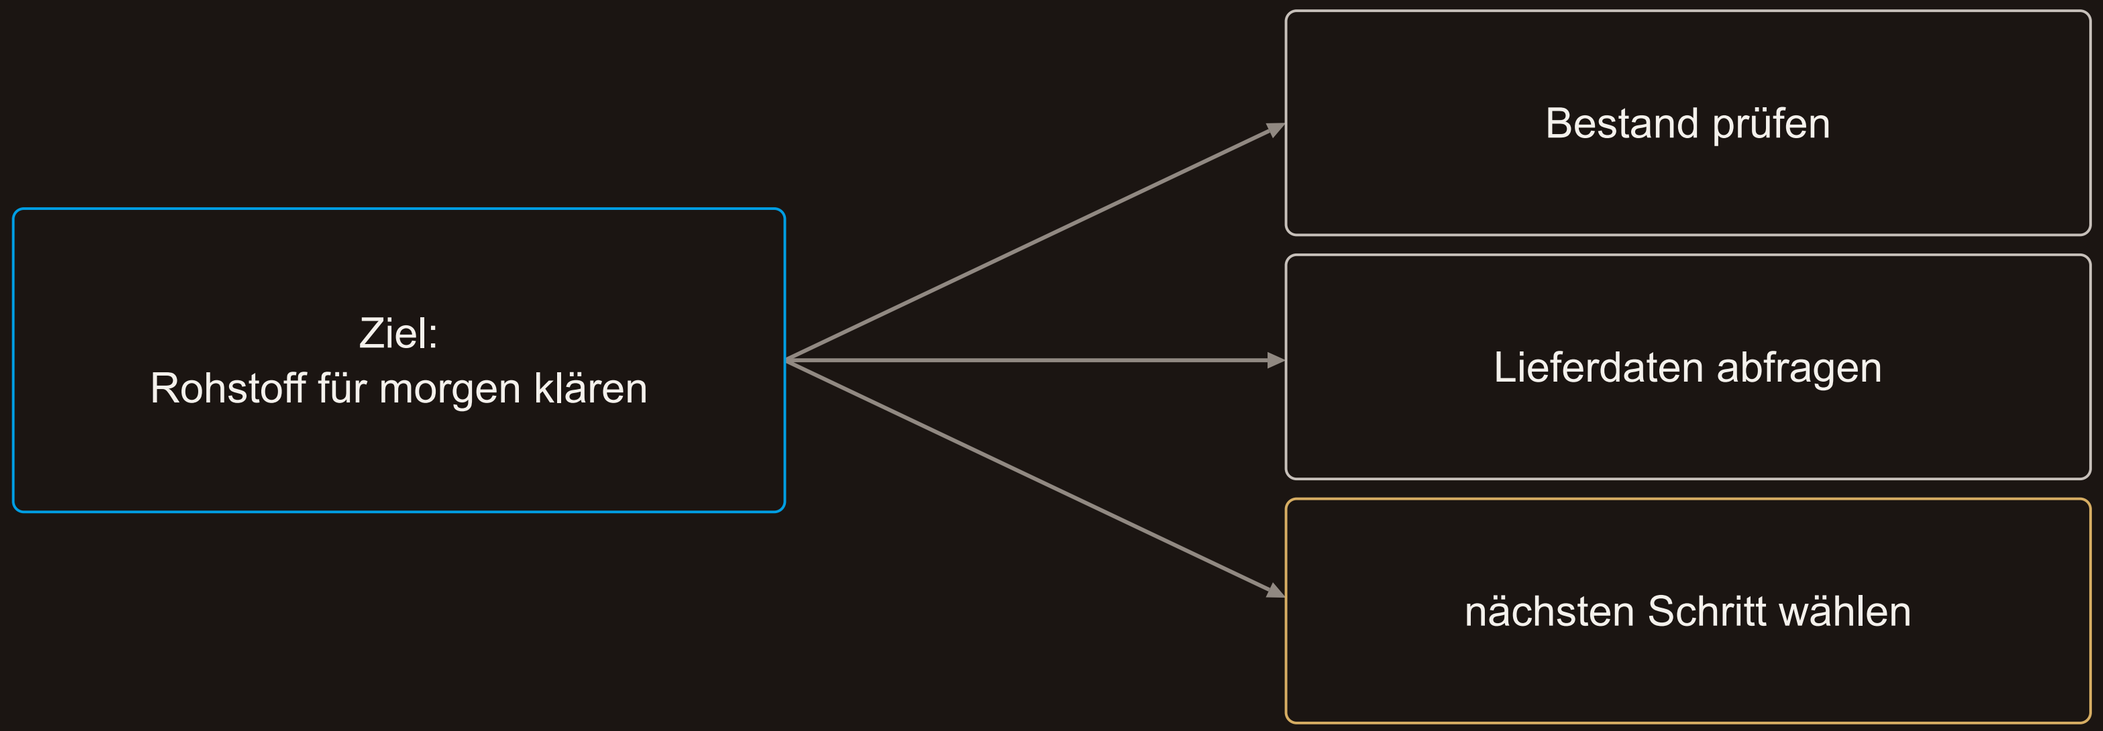
System	Ablauf	Handlungsspielraum
Chatbot	einzelne Anfrage	antwortet
Workflow	vorgegebene Schritte	führt festen Ablauf aus
Agent	dynamische Schritte	wählt nächste Aktion innerhalb von Grenzen

Ein Vergleich der Steuerung, keine Rangliste.

Das Sprachmodell ist eine Komponente.

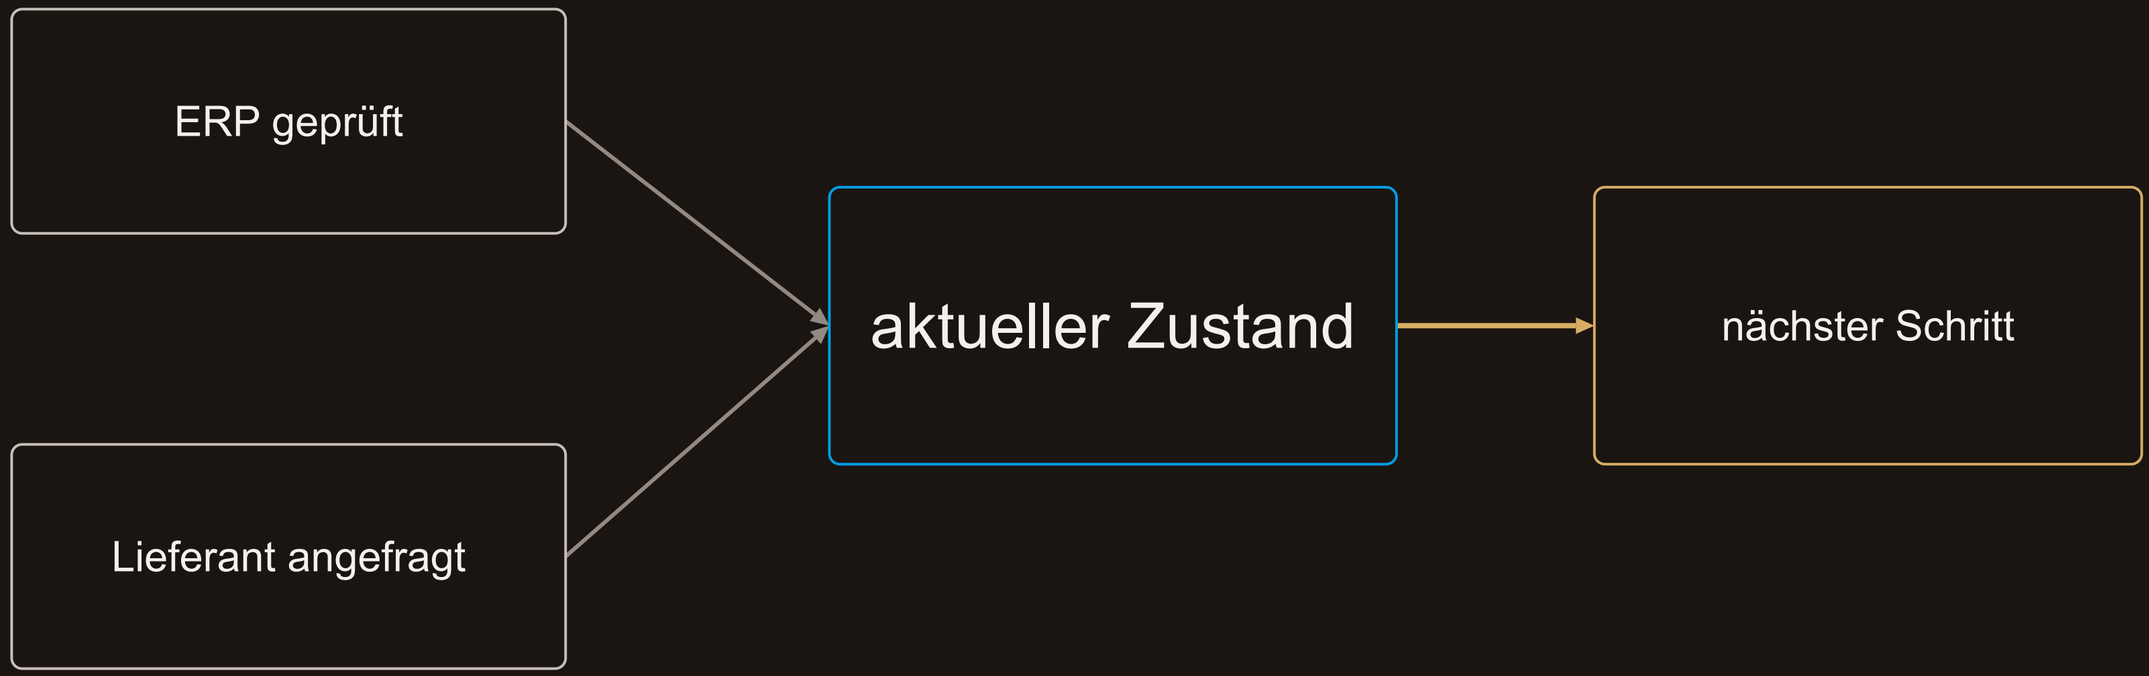


Ein Ziel beschreibt, was erreicht werden soll – nicht jeden einzelnen Schritt.



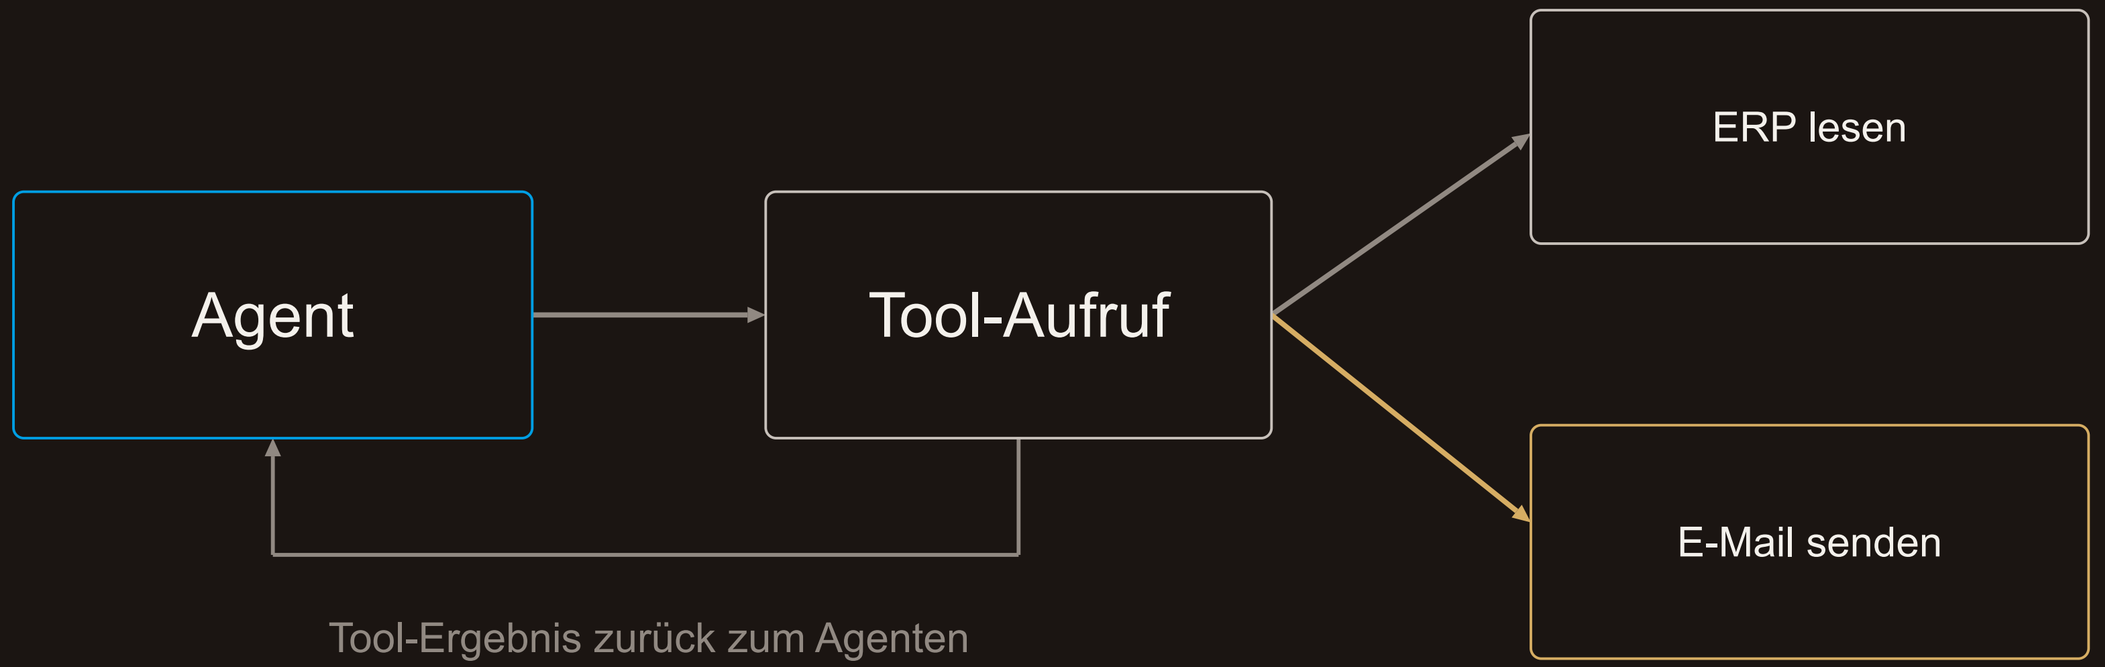
Beispiel: „Kläre, ob der Rohstoff für morgen ausreicht.“

Das System muss wissen, was geprüft wurde und was aktuell gilt.



Gespeicherte Angaben können veraltet oder falsch sein.

Tools können Informationen lesen oder außerhalb des Modells etwas verändern.



Lesen und Ausführen brauchen unterschiedliche Rechte.

Technisch möglich heißt noch nicht erlaubt.

01

Lesen

Bestand und Lieferdaten abfragen

02

Entwurf speichern

Bestellung vorbereiten

03

Nach außen senden

E-Mail an Lieferanten verschicken

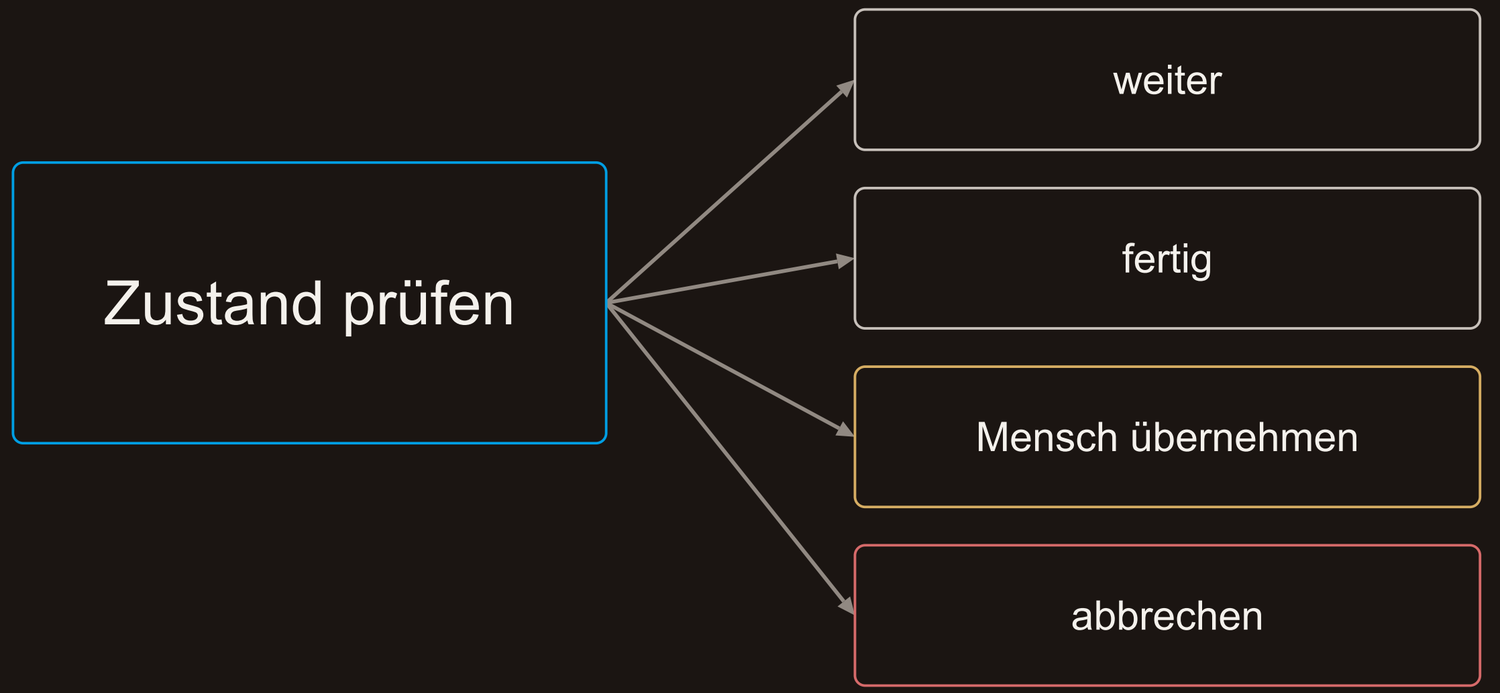
04

Wirkung auslösen

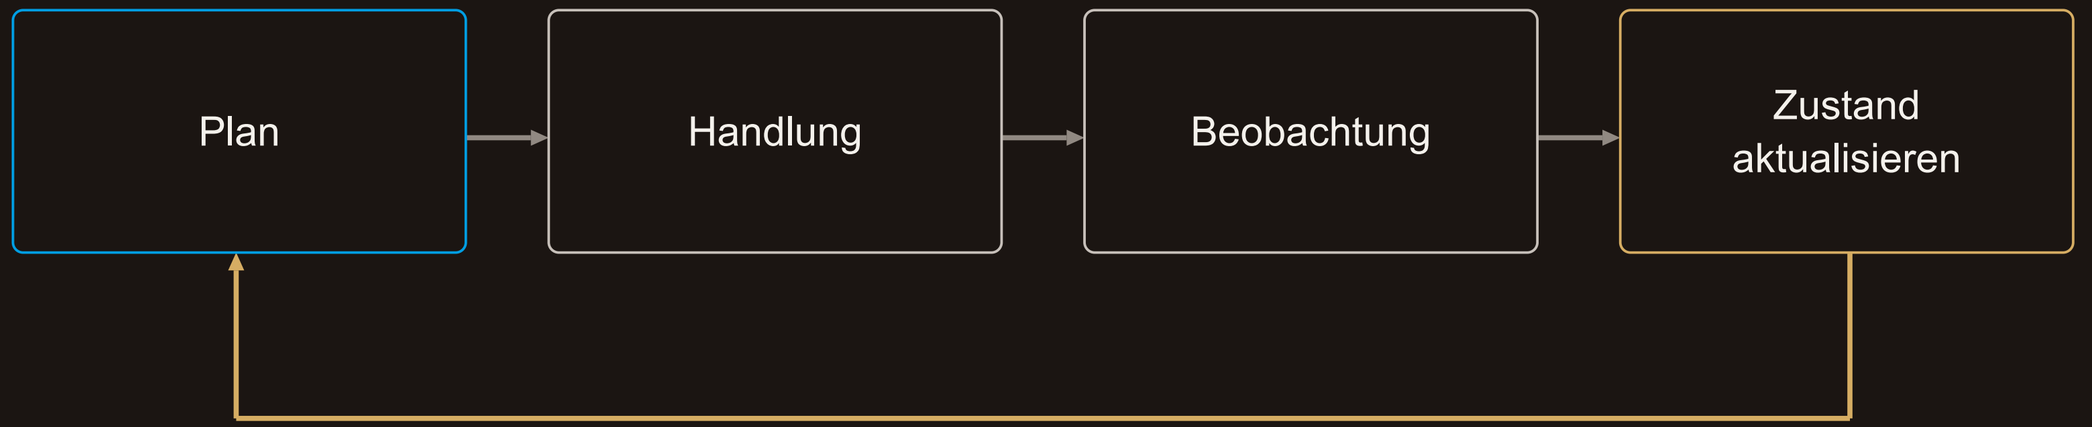
Bestellung oder Löschung ausführen

Rechte für Aufgabe, Tool, Parameter und Wirkung festlegen.

Das System braucht Bedingungen für Weiterarbeiten, Stoppen und Eskalieren.



Nach jeder Aktion verändert ein Ergebnis den nächsten Schritt.



Eine Aktion kann auch nur eine Informationsabfrage sein.

Ein vorgeschlagener Tool-Aufruf muss nicht automatisch ausgeführt werden.



Tool erlaubt? · Parameter erlaubt? · Berechtigung vorhanden? · Freigabe nötig?

Wie weit darf das System eigenständig handeln?

01

empfiehlt

02

bereitet Handlung vor

03

führt begrenzt aus

04

verfolgt Ziel über mehrere Schritte

Die passende Stufe hängt von Aufgabe und Folgen ab.

Rechtebegrenzung, Beobachtung und Eskalation müssen zur Wirkung passen.

Variante A

nur Empfehlung

Ergebnis prüfen

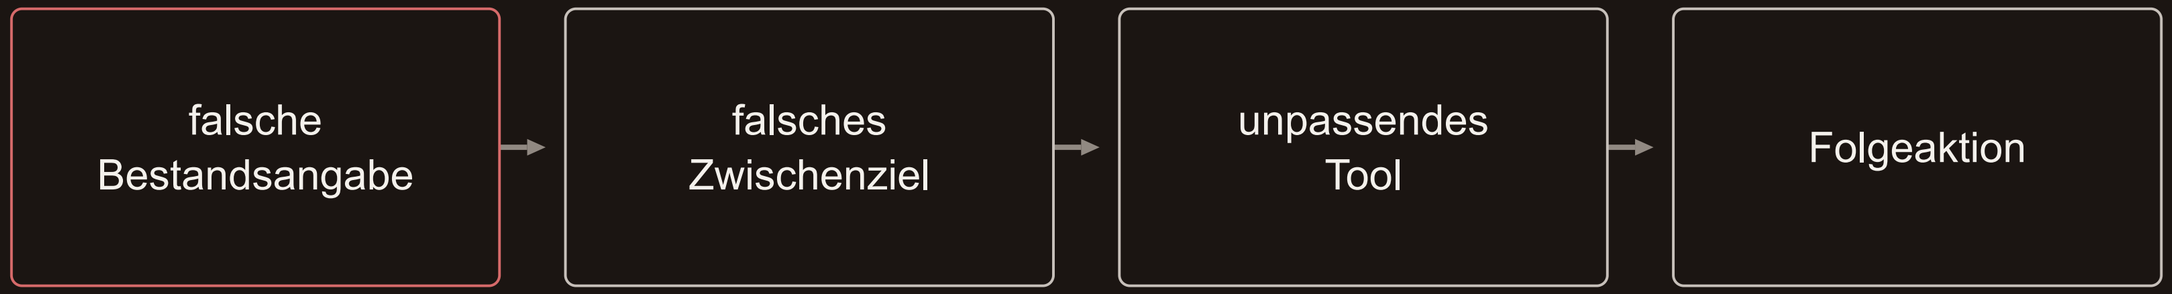
Variante B

Bestellung auslösen

Rechte begrenzen · Betrag prüfen · Freigabe einholen · Ausführung protokollieren

Kontrollbedarf hängt auch von Schaden, Erkennbarkeit und Umkehrbarkeit ab.

Ein falscher Zwischenstand kann spätere Aktionen fehlleiten.



Hier prüfen: Stimmen ERP und Lieferdaten überein?

Ein früher Prüfpunkt kann die Kette unterbrechen.

Ein fester Workflow passt gut, wenn Schritte und Ausnahmen vorhersehbar sind.

Workflow
A → B → C → D

stabiler Prozess

Agent
beobachten → wählen → handeln

offene, wechselnde Schritte

Dynamische Planung hilft bei offenen, wechselnden Schritten.

Fallstudie: Der Rohstoff für morgen

Ein Lebensmittelunternehmen will morgen früh eine Charge produzieren. Dafür wird ein kritischer Rohstoff benötigt. Am späten Nachmittag meldet die Produktionsplanung, dass der verfügbare Bestand möglicherweise nicht reicht. Im ERP ist zwar noch Ware verzeichnet, aber die letzte Lieferung wurde nicht eindeutig verbucht.

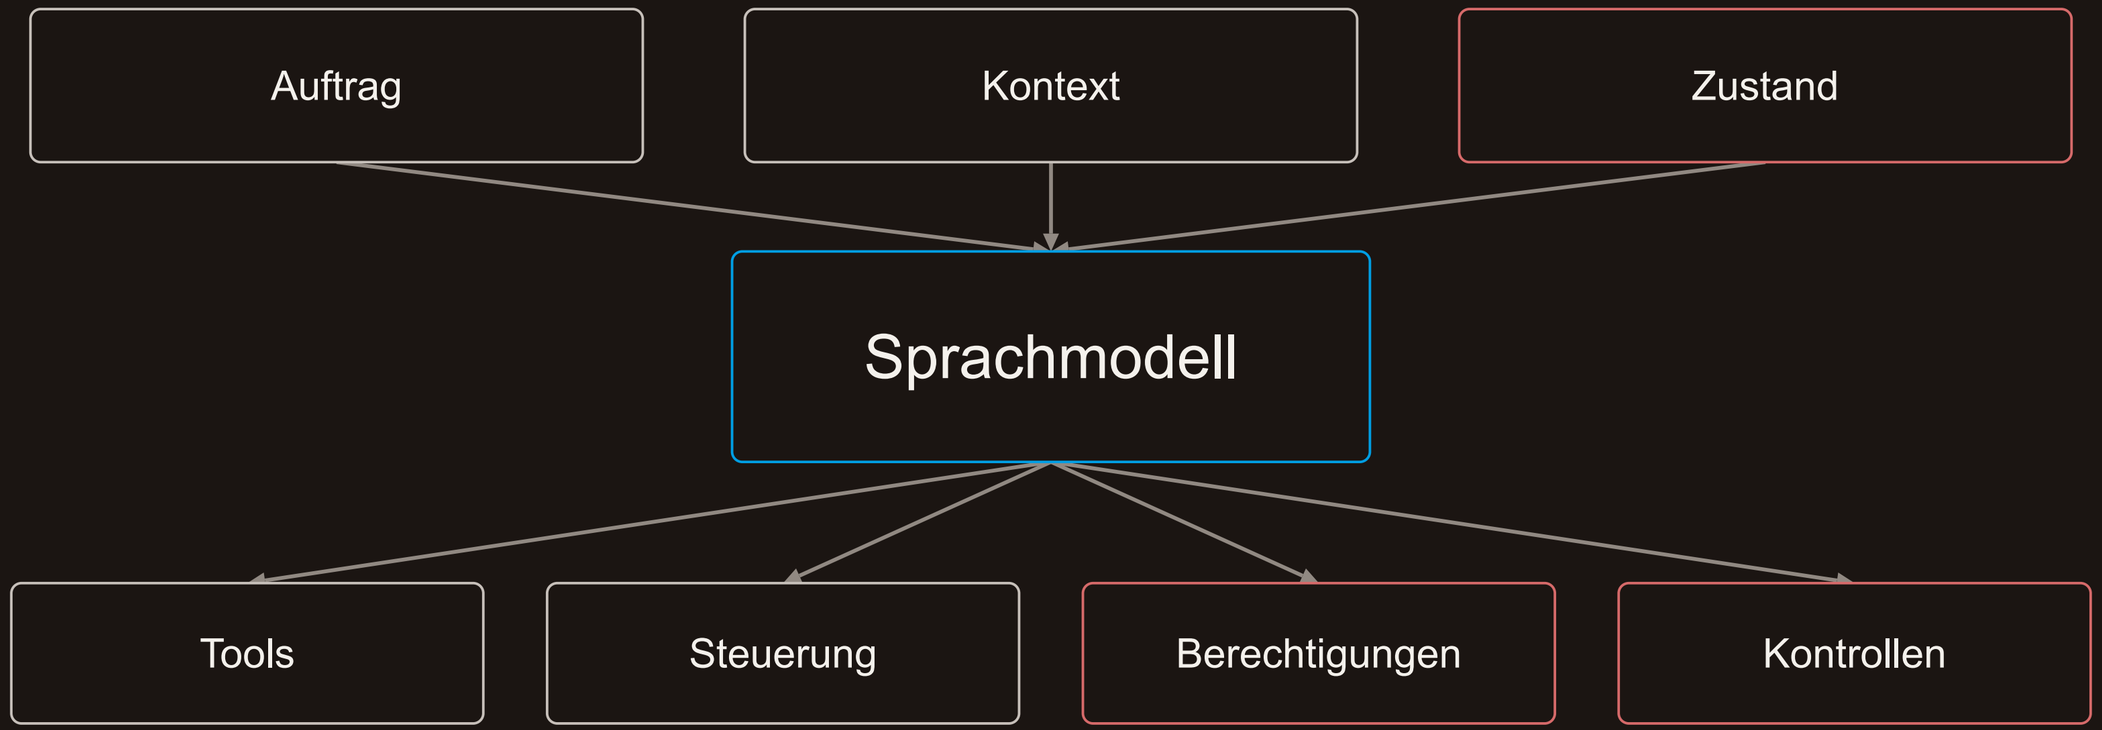
Die Produktionsleitung bittet ein agentisches System, die Versorgungslage zu klären und einen sicheren nächsten Schritt vorzubereiten. Fehlt der Rohstoff, kann die Produktion nicht planmäßig starten. Eine unnötige Eilbestellung würde dagegen zusätzliche Kosten verursachen. Bis Feierabend braucht die Leitung eine begründete Empfehlung.

Verteilt in eurer Gruppe die Rollen Planungssystem, ERP, Lieferantendatenbank, Freigabeverantwortliche Person und Risikobeobachtung. Das Planungssystem entscheidet nach jeder neuen Information, welche Abfrage oder Handlung als Nächstes sinnvoll ist.

Die anderen Rollen antworten nur auf tatsächlich gestellte Anfragen. Haltet für jeden Schritt fest, welche Information vorlag, welche Berechtigung nötig wäre und an welchem Punkt ein Mensch freigeben oder übernehmen muss.

15–20 Minuten

Modell · Daten · Tools · Berechtigungen · Eskalation



Agentisch ist das Gesamtsystem:
Modell, Zustand, Tools,
Berechtigungen, Steuerung
und Kontrollpunkte.

Weiterlesen: Agentische Systeme

Einstieg

Anthropic (2024)
Building Effective Agents

Yao et al. (2022/2023)
ReAct · Planen und Handeln

Sicherheit

NIST AI RMF
Risikomanagement

NIST CAISI (2025)
Agent Hijacking Evaluations

Vertiefung

Wang et al. (2023/2025)
Survey zu LLM-Agenten

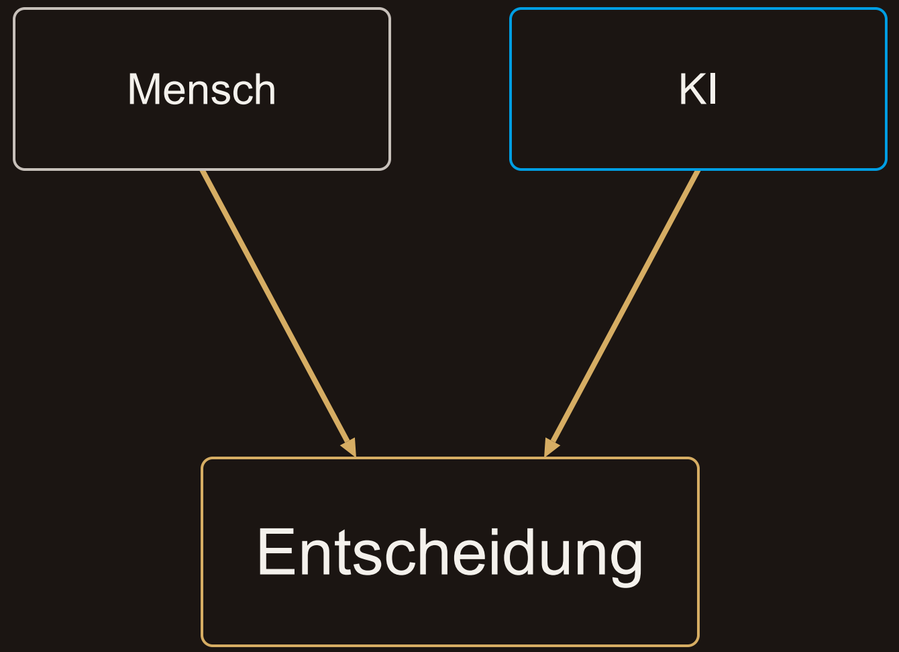
Schick et al. (2023)
Toolformer · Toolnutzung

Parasuraman et al. (2000)
Stufen der Automatisierung

Block 3

Wer sollte was entscheiden?

Aufgabenteilung, Vertrauen, Kontrolle und Verantwortung.

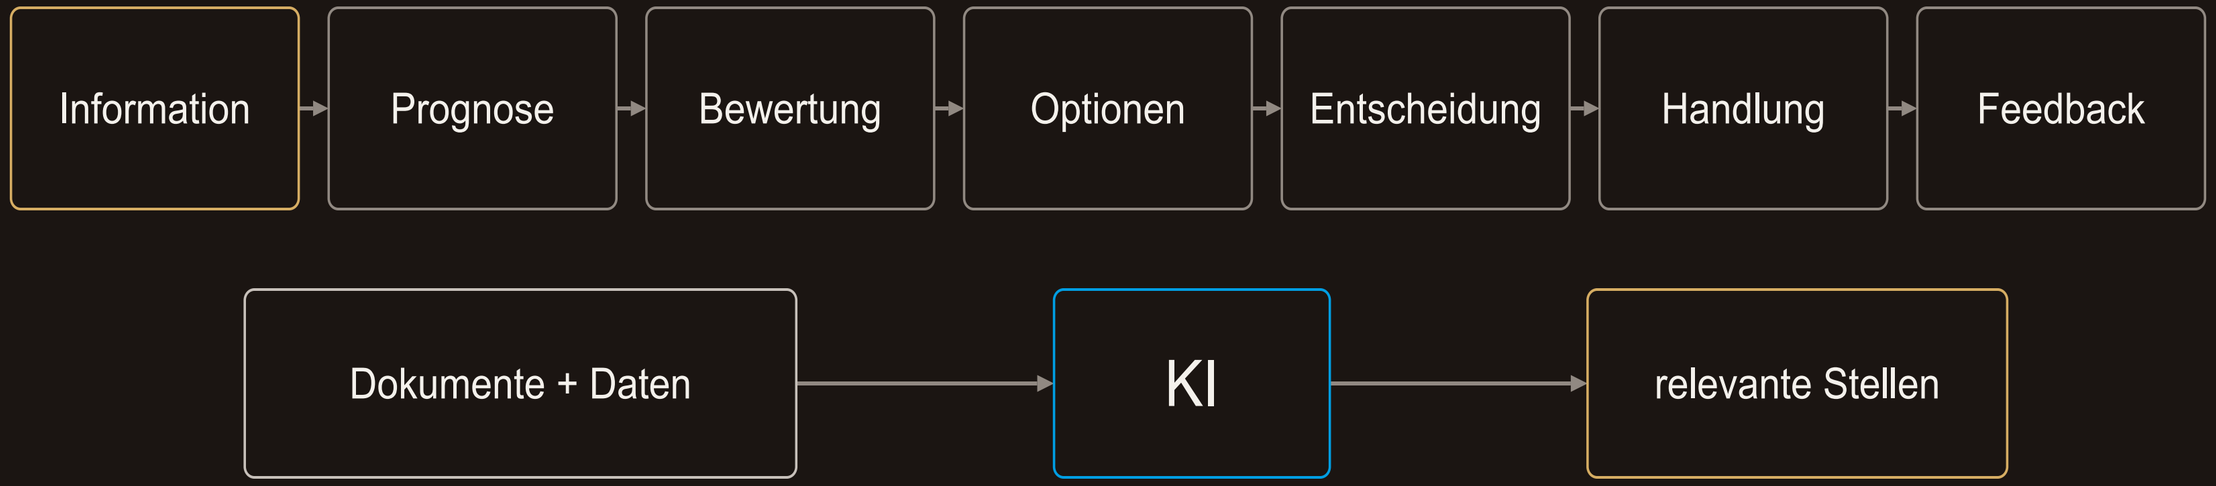


Für jeden Schritt fragen wir: Mensch, KI oder beide?



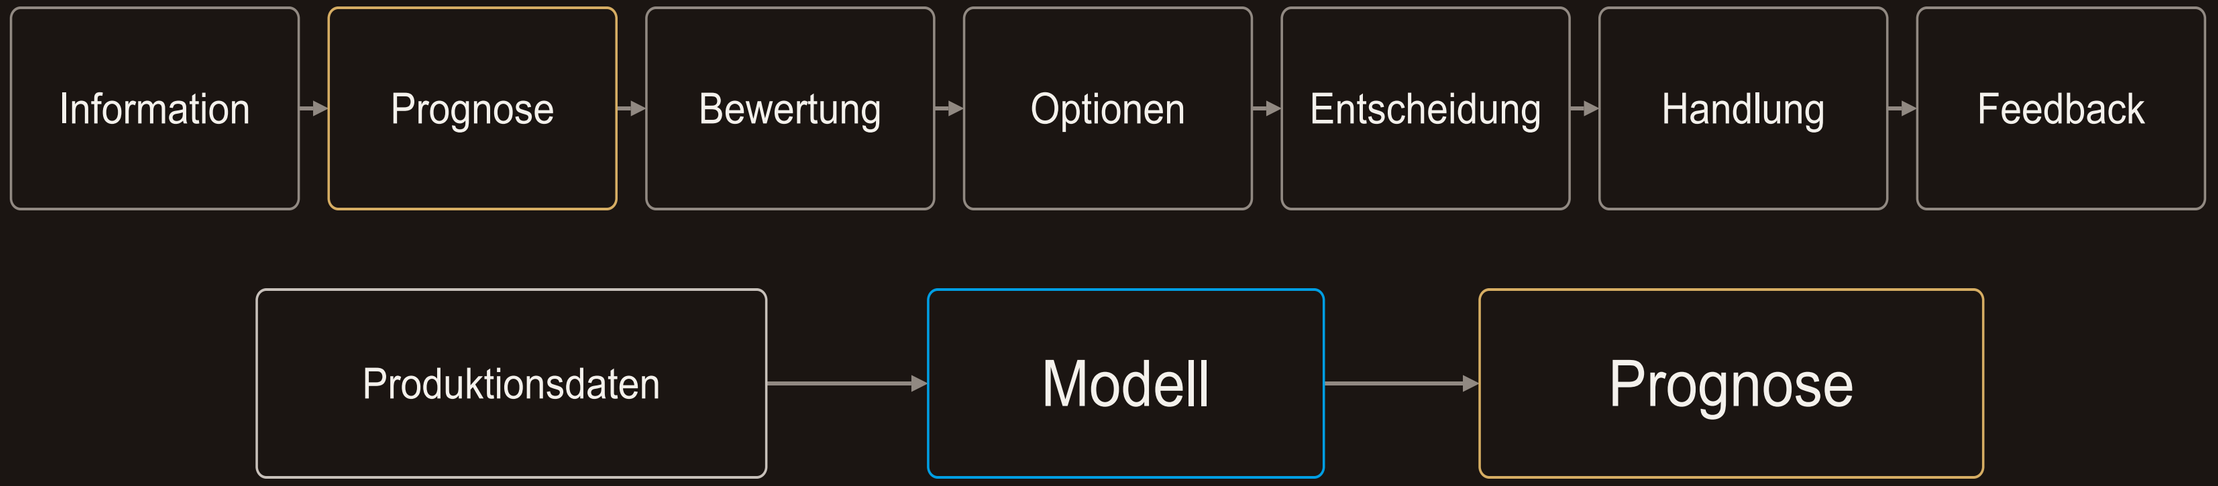
Wer übernimmt welche Funktion – und unter welchen Bedingungen?

Dokumente durchsuchen, Daten bündeln, relevante Stellen finden.



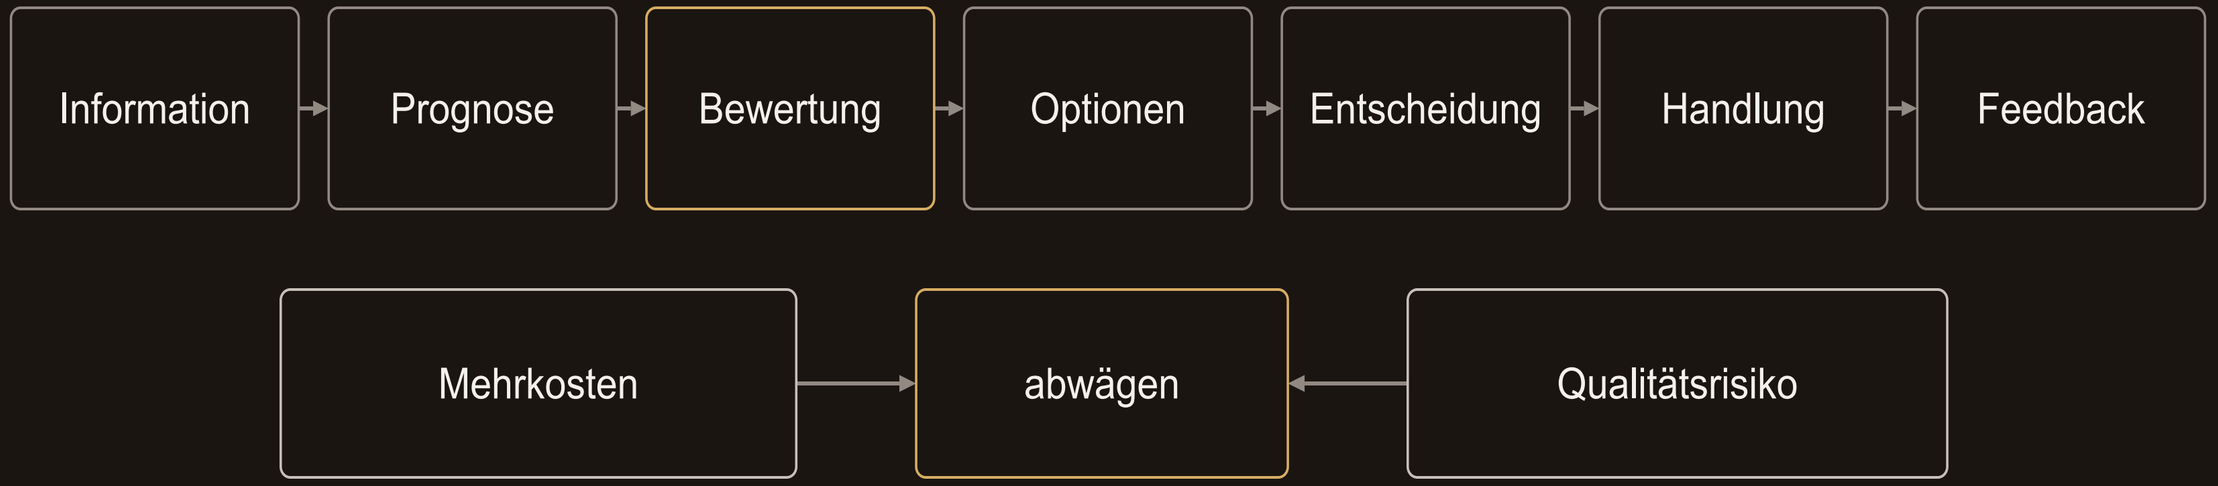
Prüffrage: Sind die Quellen vollständig und aktuell?

Klassifizieren, prognostizieren, Muster erkennen, zusammenfassen.



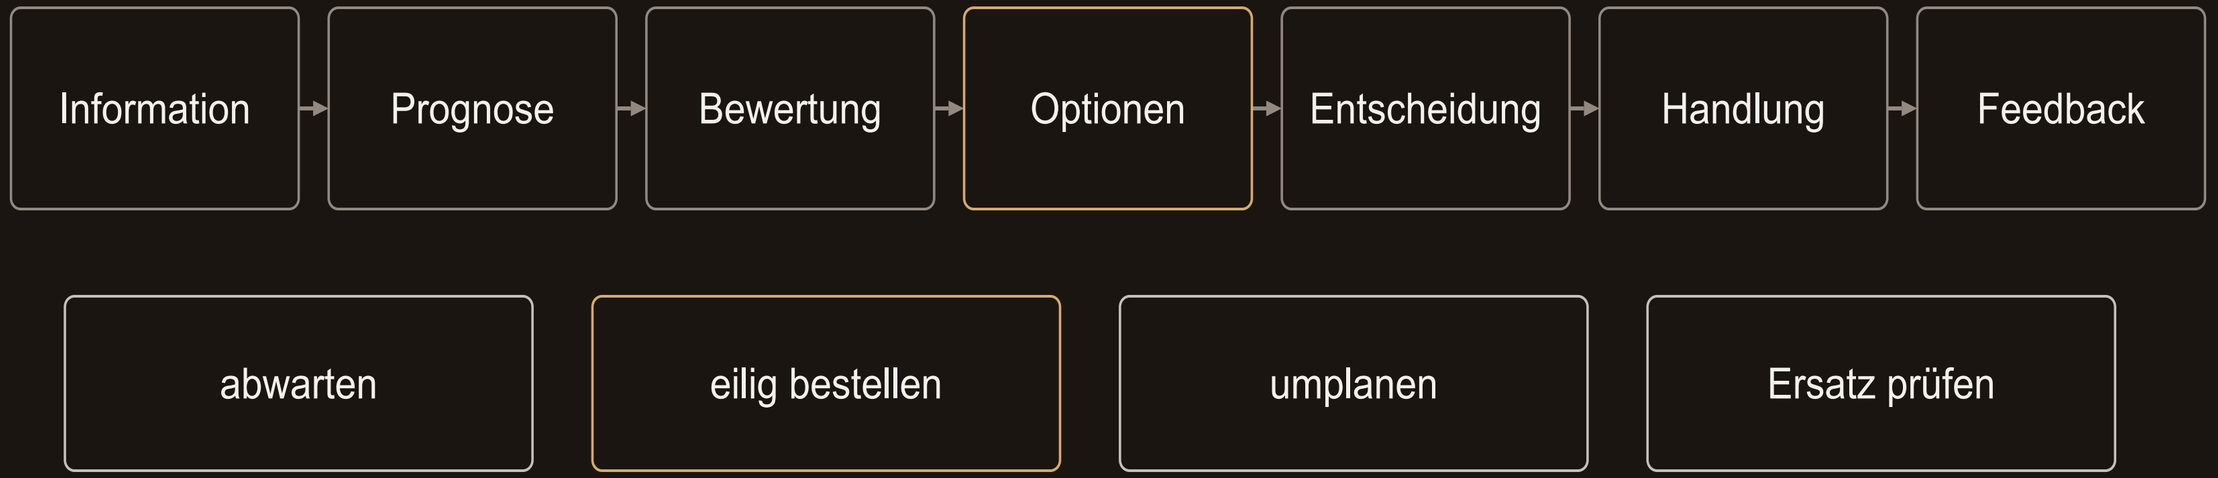
Prüffrage: Wie verlässlich ist die Analyse in diesem Kontext?

Wie viel Mehrkosten sind akzeptabel, um ein Qualitätsrisiko zu senken?



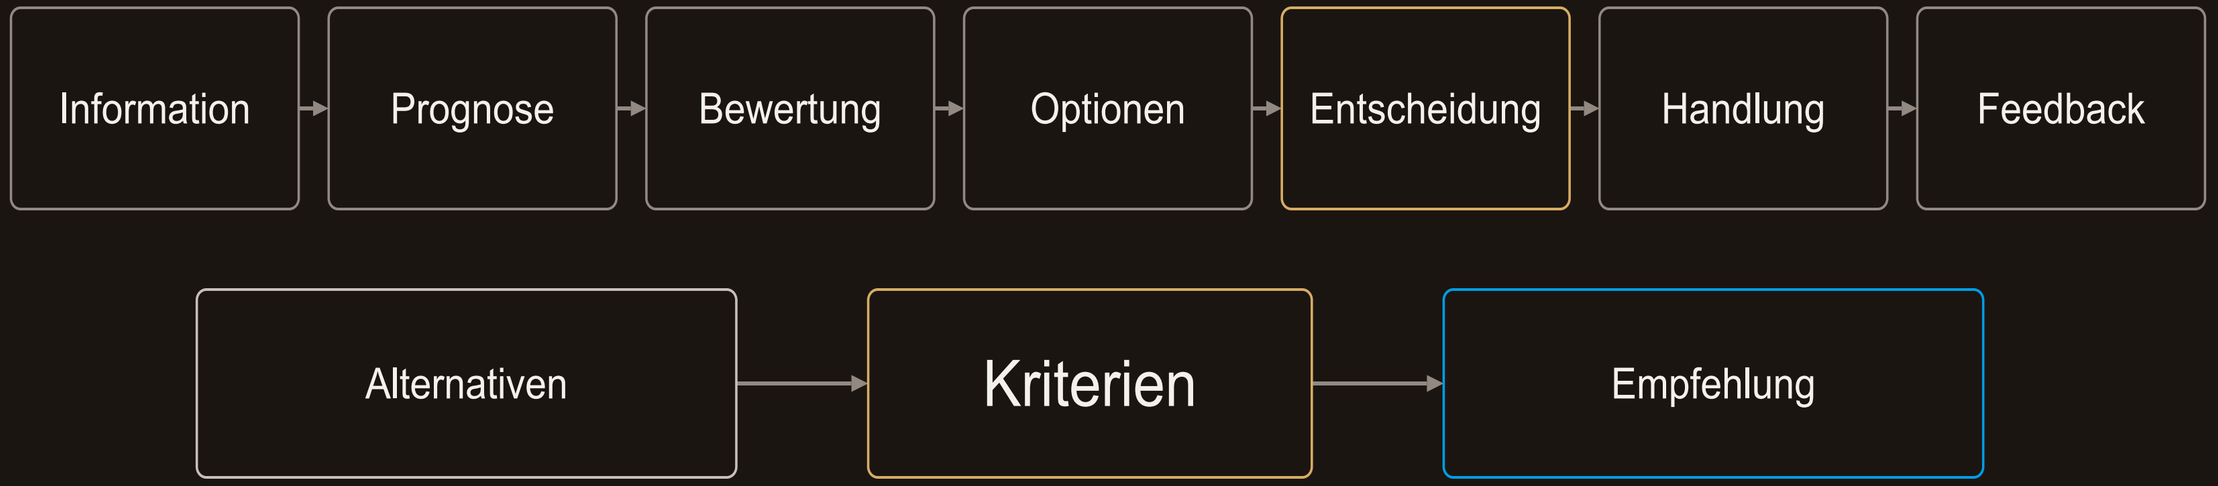
Eine Prognose allein legt die Gewichtung der Folgen nicht fest.

Mehr Vorschläge erweitern den Blick – ihre Tauglichkeit muss geprüft werden.



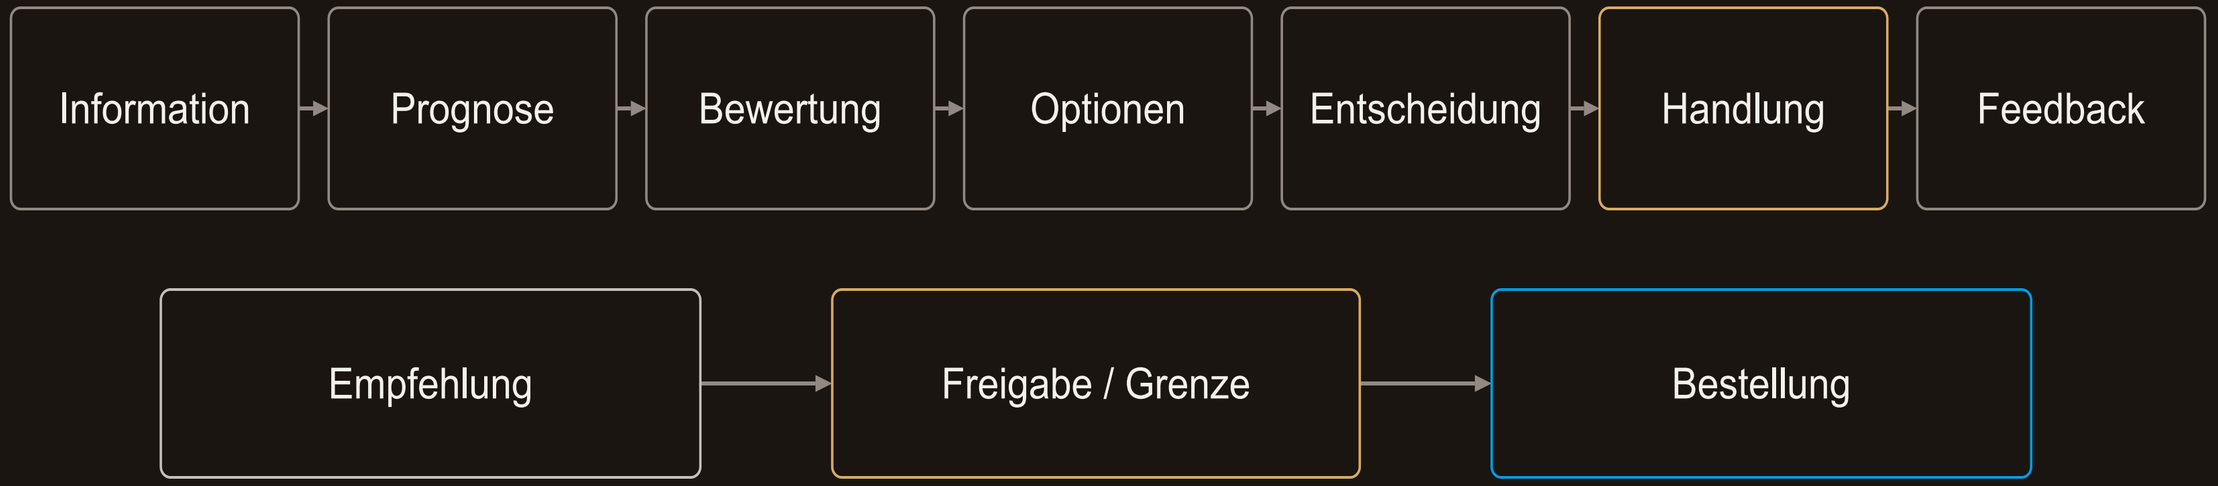
Beispiel: warten · eilig bestellen · umplanen · Ersatz prüfen

Sortieren und empfehlen setzt Kriterien voraus.



Wer legt Kriterien und Gewichtungen fest?

Aus einer Empfehlung wird eine Wirkung außerhalb des Systems.



Beispiel: Empfehlung → Freigabe oder Grenze → Bestellung

In jeder Funktion kann unterschiedlich viel automatisiert werden.

01

Information beschaffen

Lieferdaten finden

02

Information analysieren

Verspätung prognostizieren

03

Auswahl unterstützen

Alternativen ordnen

04

Handlung ausführen

Bestellung auslösen

Nach Parasuraman, Sheridan & Wickens (2000).

Das Team muss sich mit dem jeweils besseren Einzelbeitrag messen.

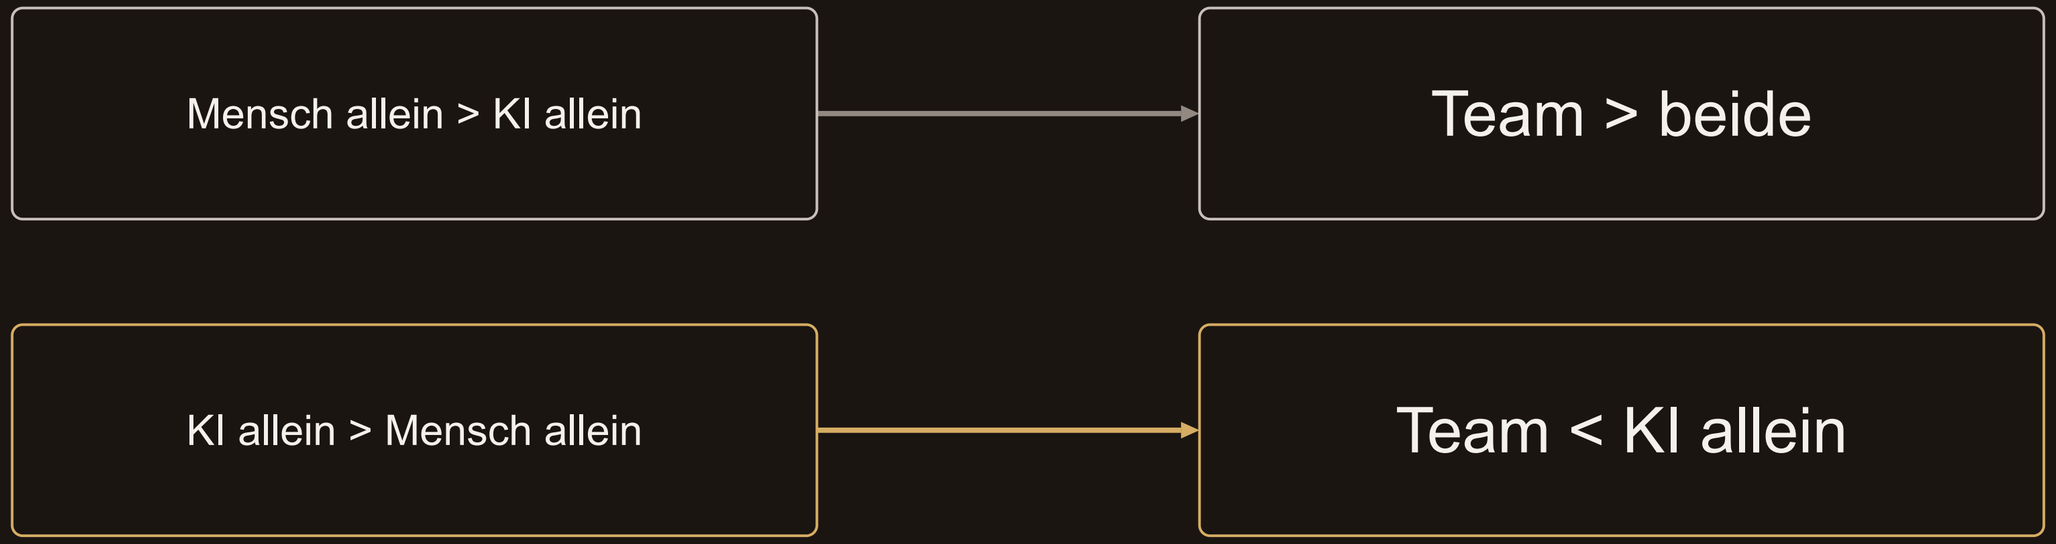
Mensch allein	KI allein	Mensch + KI

Messlatte: der jeweils bessere Einzelbeitrag

Vaccaro, Almaatouq & Malone (2024) · 106 Experimente

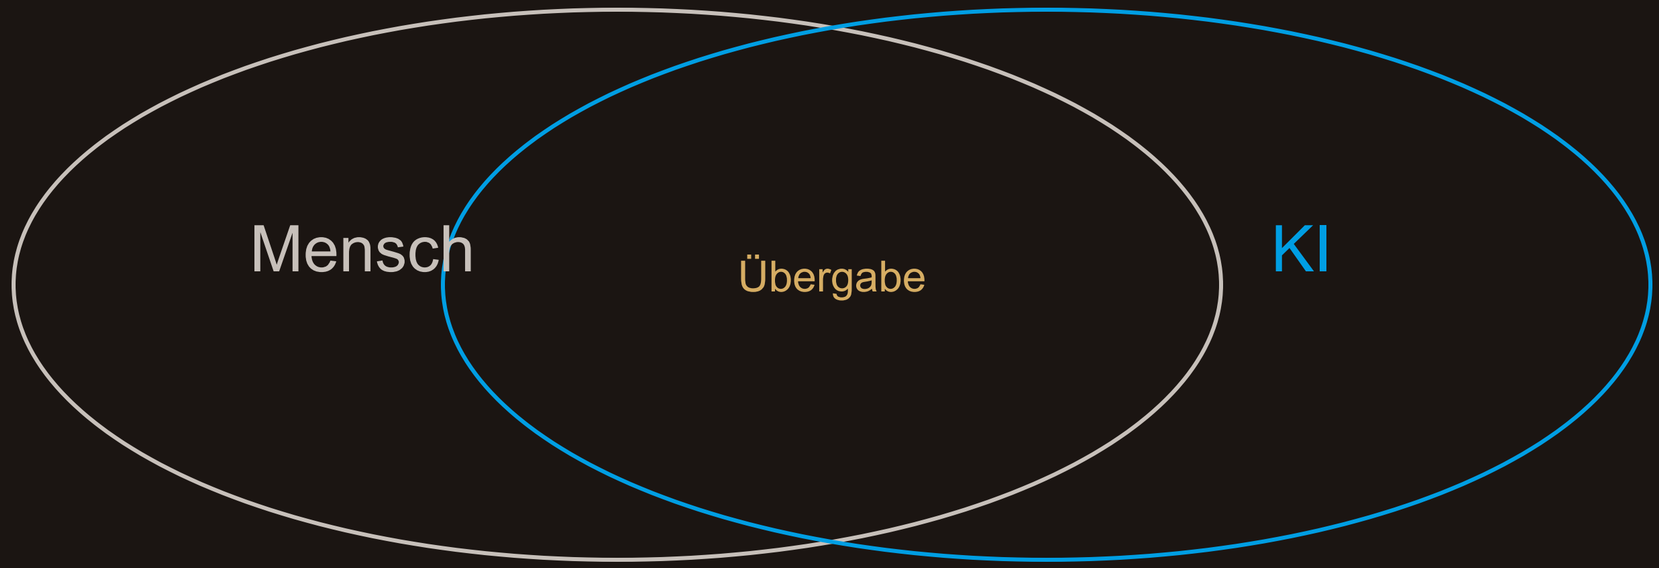
Wenn KI allein stärker war, verlor das Team im Mittel

Mensch + KI lag dann unter KI allein.



Befund aus untersuchten Experimenten · Vaccaro et al. (2024)

Ein Team gewinnt, wenn Beiträge und Übergaben zur Aufgabe passen.



Informations- und Fähigkeitsunterschiede sinnvoll nutzen

Unterschiedliche Informationen und Fähigkeiten schaffen Potenzial.

Wo können Mensch und KI jeweils beitragen?

KI kann helfen bei

Umfang · Tempo · Muster

viele Lieferdaten auswerten

gleiche Regeln konsistent anwenden

Menschen bringen ein

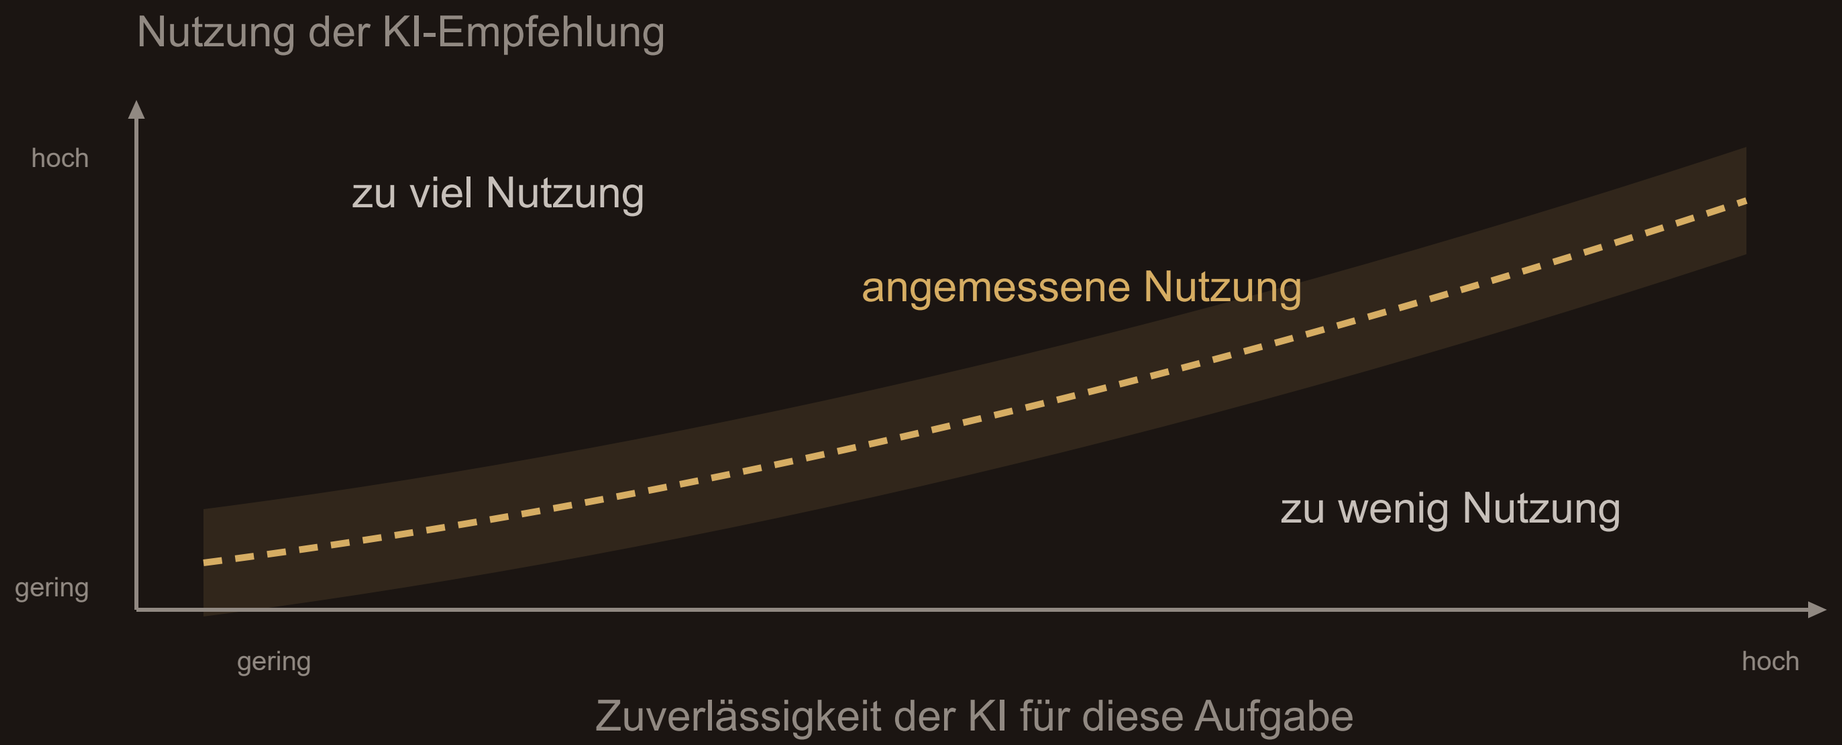
Ziele · Kontext · Verantwortung

Folgen gegeneinander abwägen

Ausnahmen und Betroffene einordnen

Mögliche Stärken – die konkrete Leistung muss geprüft werden.

Entscheidend ist, ob die Nutzung zur tatsächlichen Zuverlässigkeit passt.



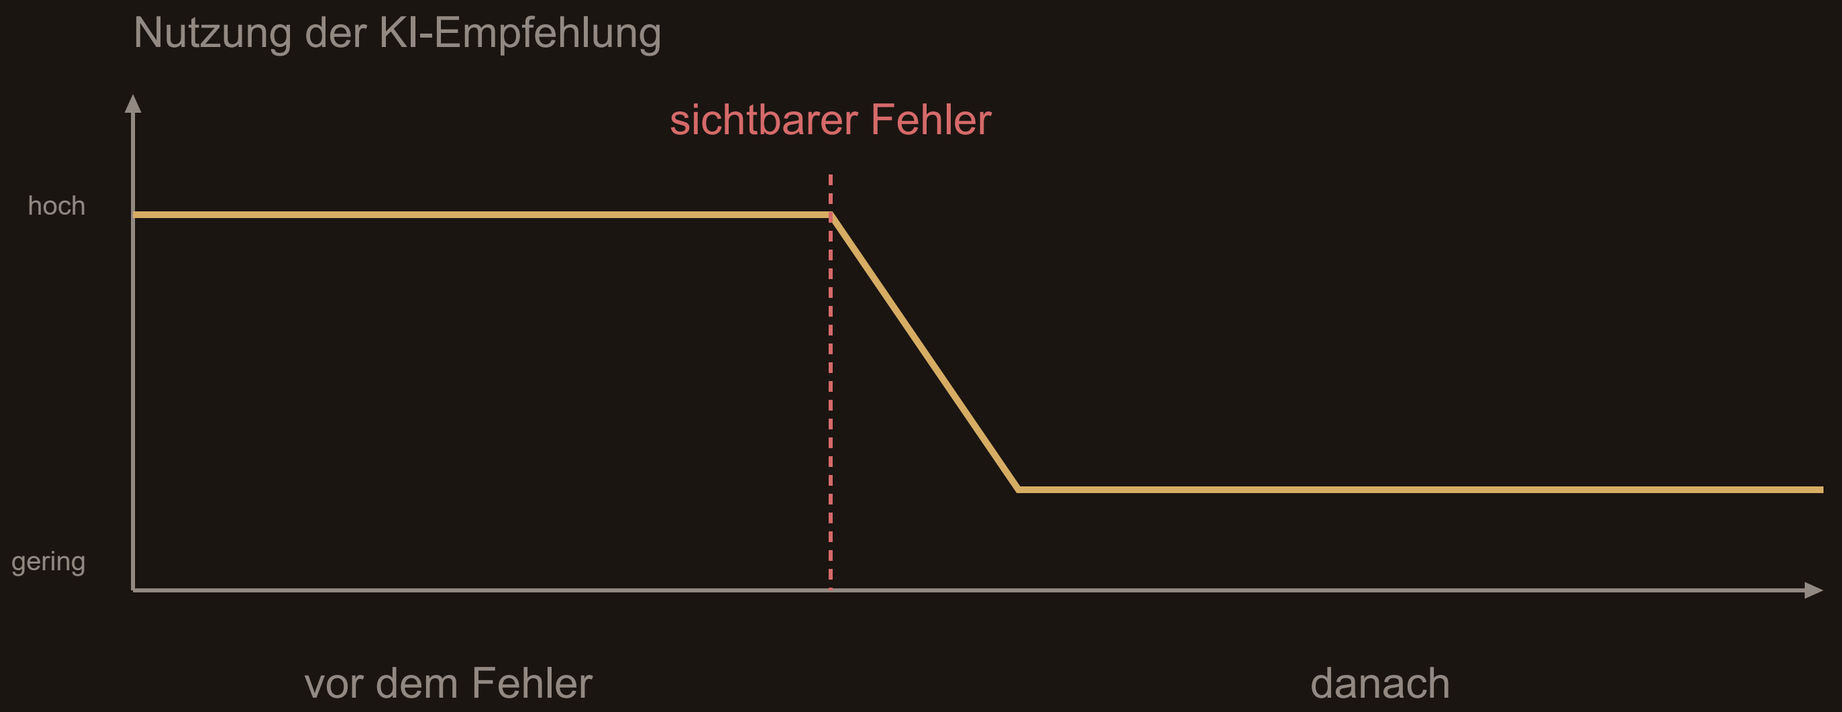
Schematisch: keine Messwerte und keine festen Schwellen.

Eine falsche Empfehlung kann zum Anker der Entscheidung werden.



Zeitdruck und überzeugende Darstellung können die Prüfung erschweren.

Ein sichtbarer Fehler kann die spätere Nutzung stark senken.



Schematischer Verlauf · Fachbegriff: Algorithm Aversion.

Auch das Gegenteil kann vorkommen.

Empfehlung
von einer Person

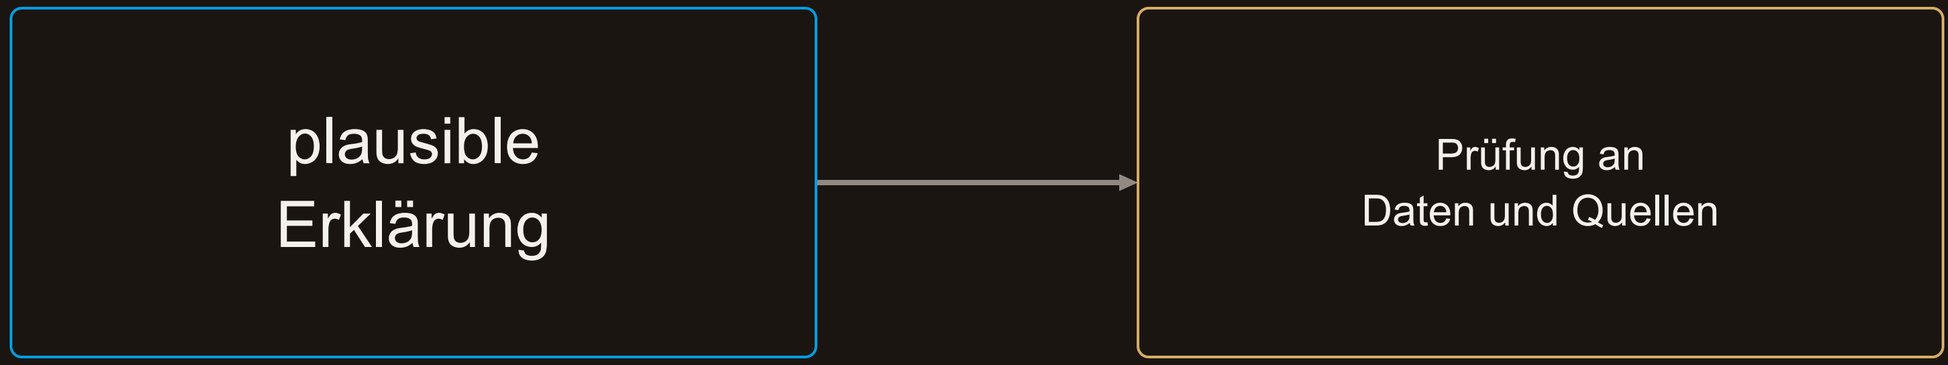
gleiche Empfehlung
von einem Algorithmus

Der wahrgenommene Absender kann die Gewichtung verändern.

Fachbegriff: Algorithm Appreciation.

Das Ziel ist angemessene Nutzung:
dort folgen, wo das System verlässlich ist –
und dort prüfen oder widersprechen,
wo es nötig ist.

Plausible Gründe machen eine Empfehlung noch nicht richtig.



Verstehen → noch nicht: bewiesen

Verstehen und Prüfen sind zwei verschiedene Schritte.

Die passende Erklärung hängt davon ab, was sie leisten soll.

Verstehen

Wie kam der Vorschlag zustande?

Fehler finden

Welche Annahme stimmt nicht?

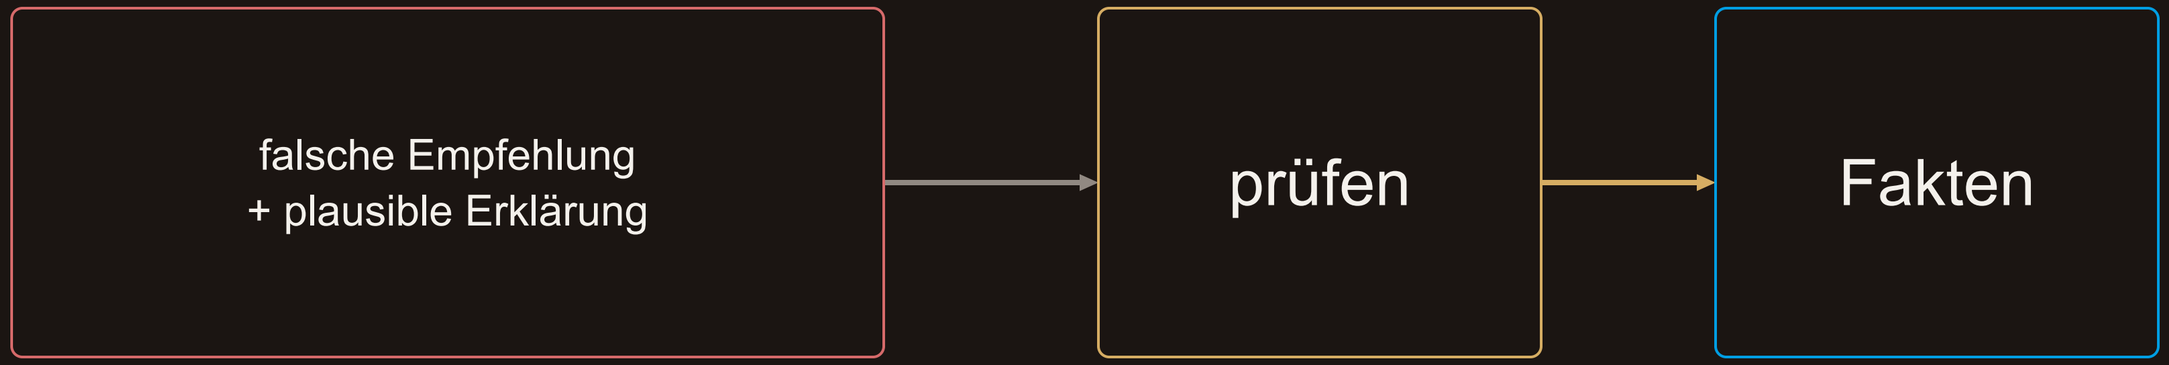
Lernen

Was lässt sich verbessern?

Rechenschaft

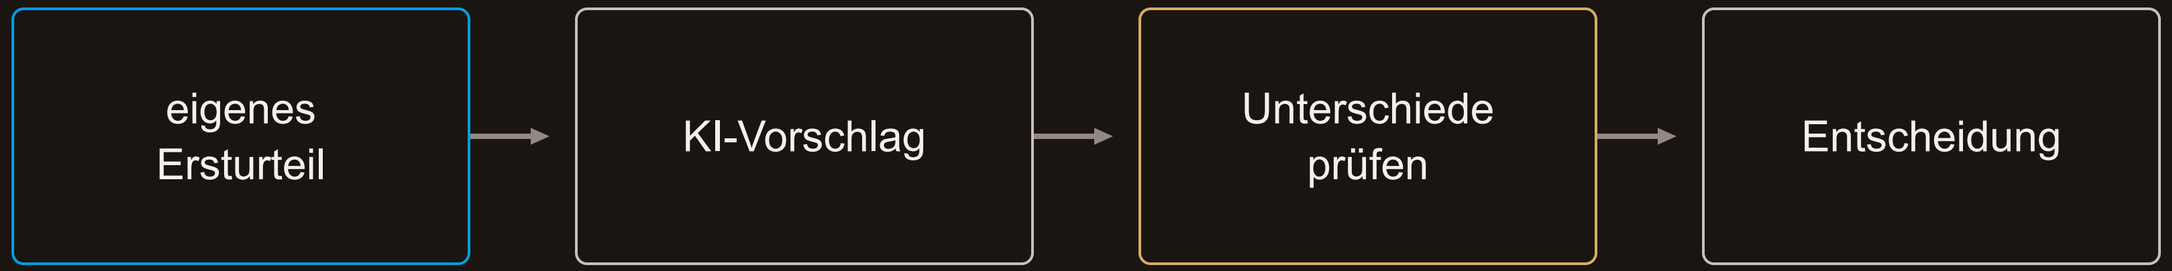
Wer kann den Schritt begründen?

Überzeugend formuliert ist nicht gleich gut begründet.



Eine Gegenprüfung braucht Zugang zu entscheidenden Fakten.

Ein eigenes Ersturteil macht Abweichungen sichtbar.



Eine mögliche Arbeitsregel für wichtige Fälle.

Welche Information würde diese Empfehlung kippen?



Ein erzeugtes Gegenargument ist selbst noch keine Verifikation.

Wer nur auf „Freigeben“ klickt, muss auch prüfen können.

Information fehlt

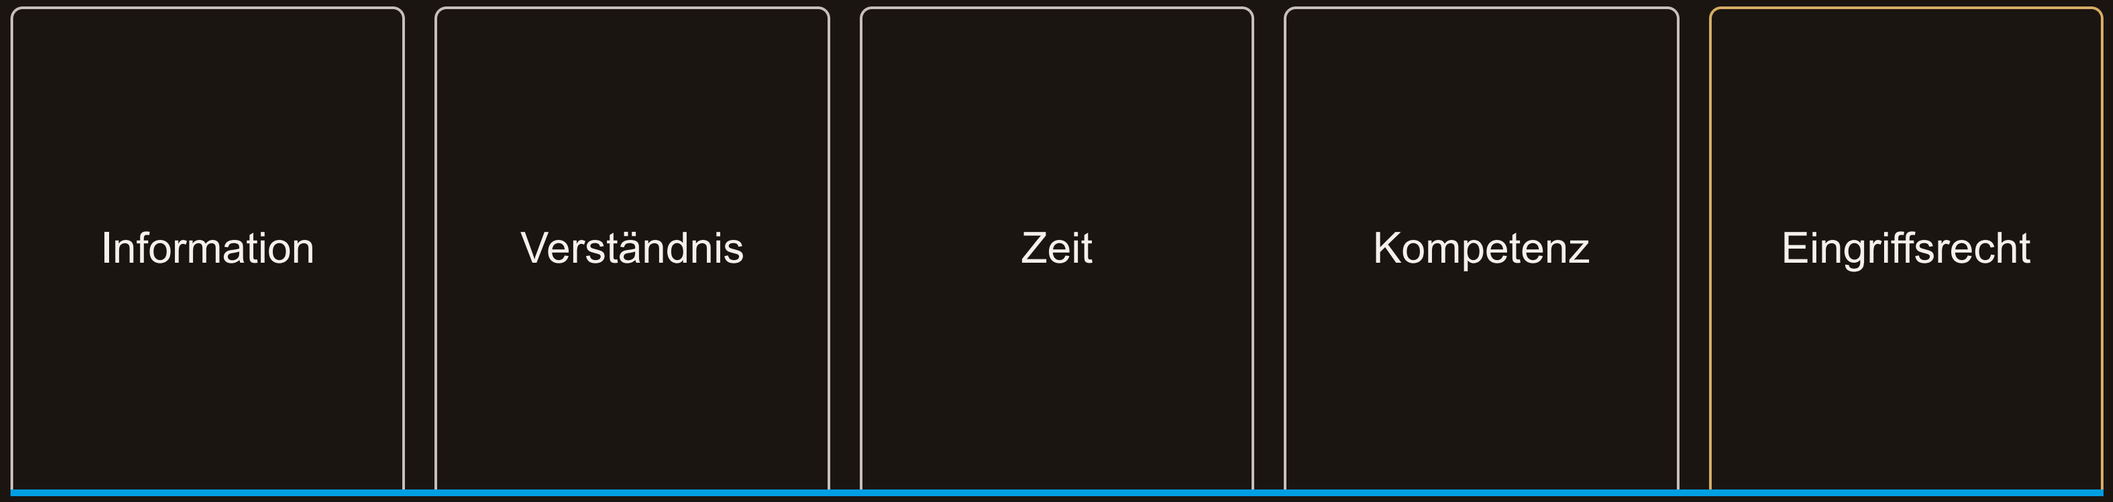
Zeit fehlt

Freigeben

Kein Eingriff ohne echte Alternative

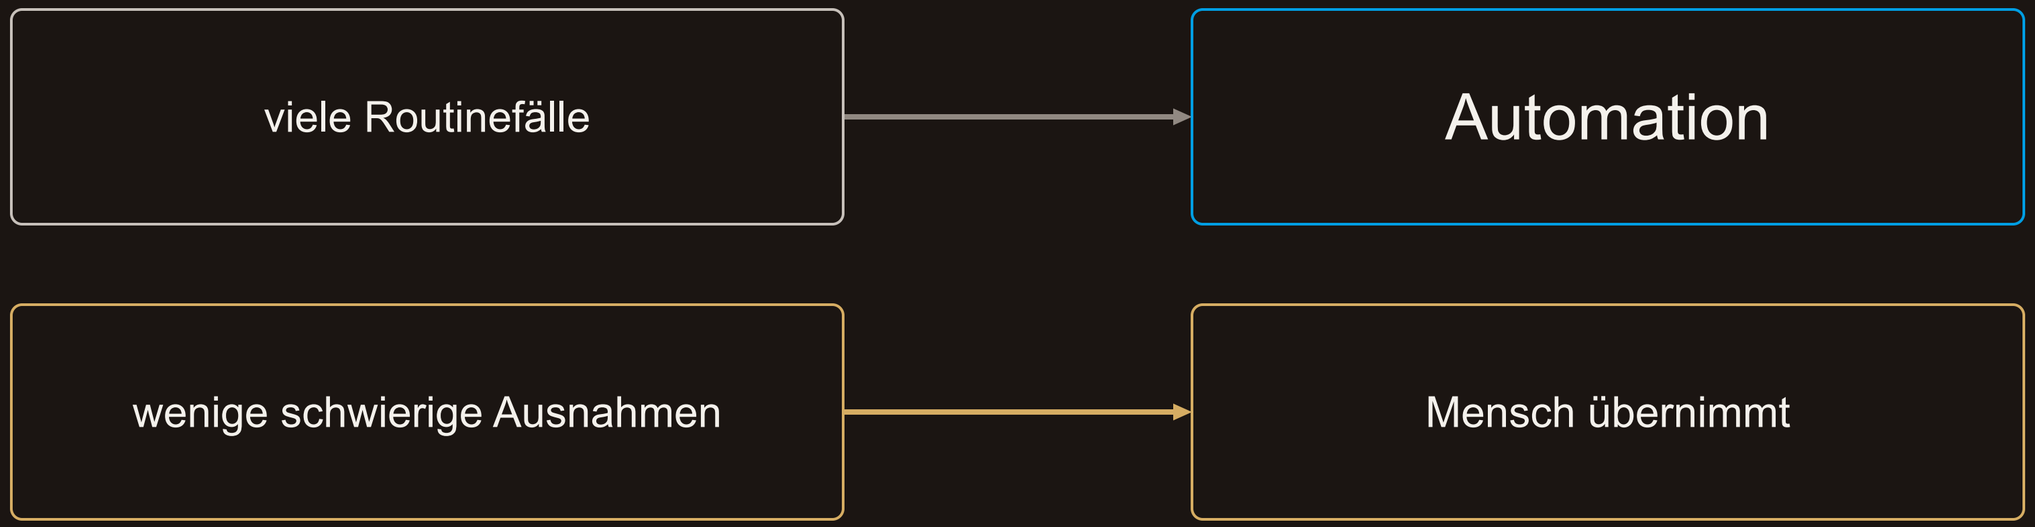
Information, Zeit und Handlungsspielraum entscheiden über wirksame Aufsicht.

Eine Person braucht Mittel, Zeit und Befugnisse zum Eingreifen.



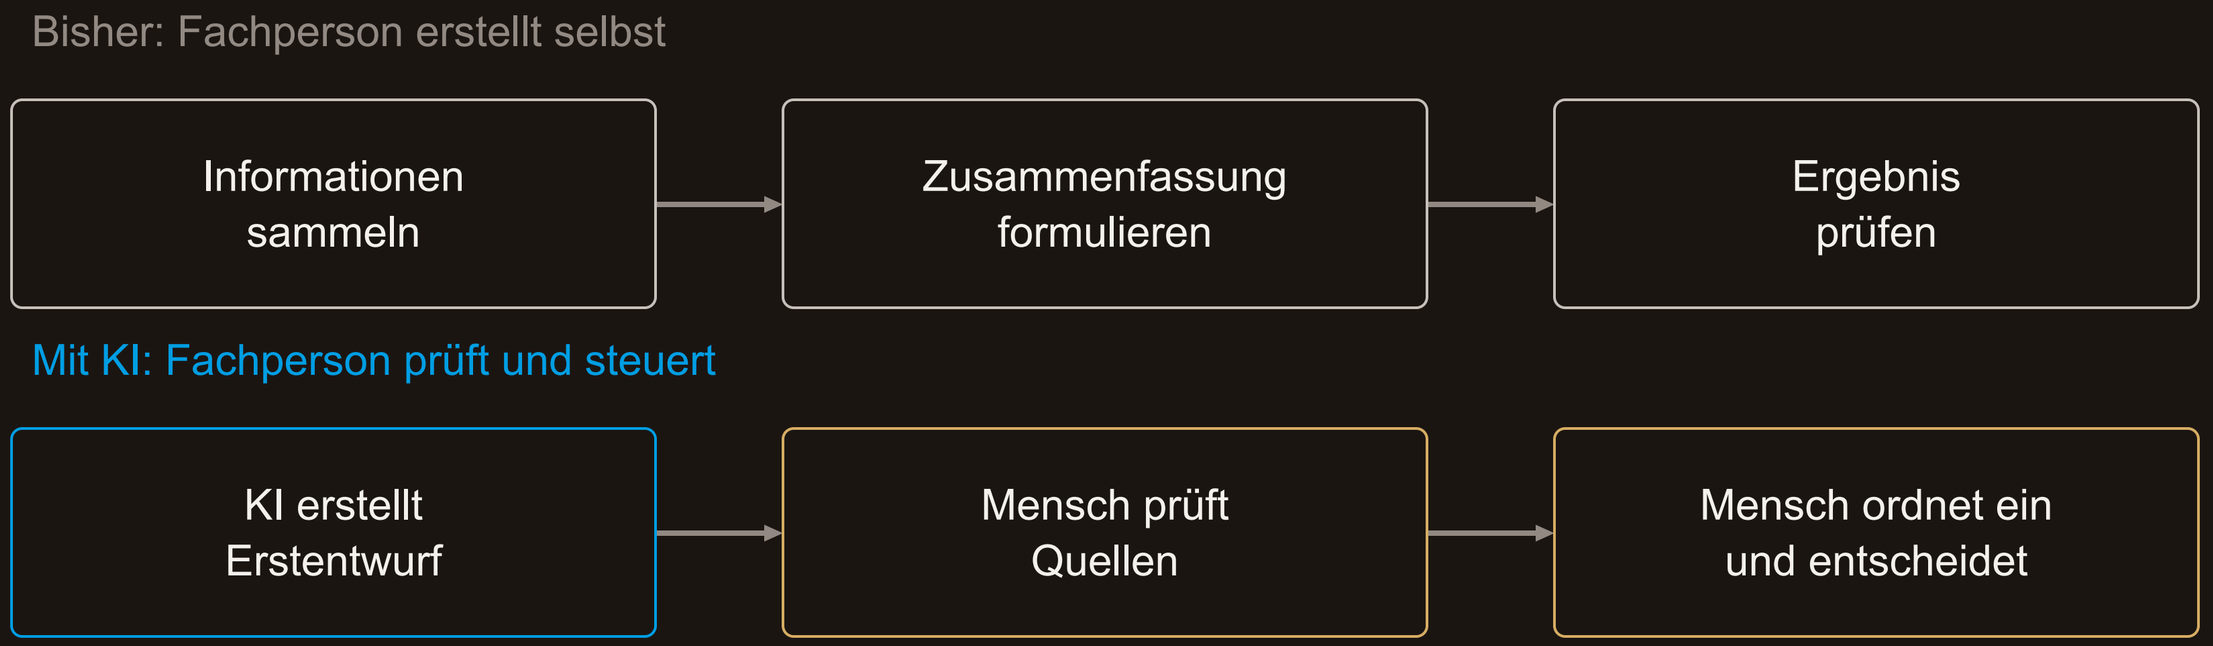
EU-KI-Verordnung, Art. 14: Anforderungen für Hochrisiko-KI-Systeme

Menschen übernehmen oft die seltenen, schwierigen Ausnahmefälle.



Routine verschwindet – Übung für Ausnahmen kann fehlen.

Weniger selbst erstellen. Mehr prüfen, einordnen und steuern.



Die menschliche Arbeit verändert sich; die Nettoentlastung ist offen.

Lee et al. (2025) · Befragung von 319 Wissensarbeitenden

Viele plausible Ergebnisse zu prüfen kostet Aufmerksamkeit.



Im Pilot auch Prüfzeit und übersehene Fehler messen.

Zhang et al. (2024) · Laborexperiment mit 34 Personen

Mögliche Folgen bestimmen den Prüfbedarf mit.

E-Mail-Entwurf vorlegen

zunächst intern

Bestellung auslösen

Wirkung nach außen

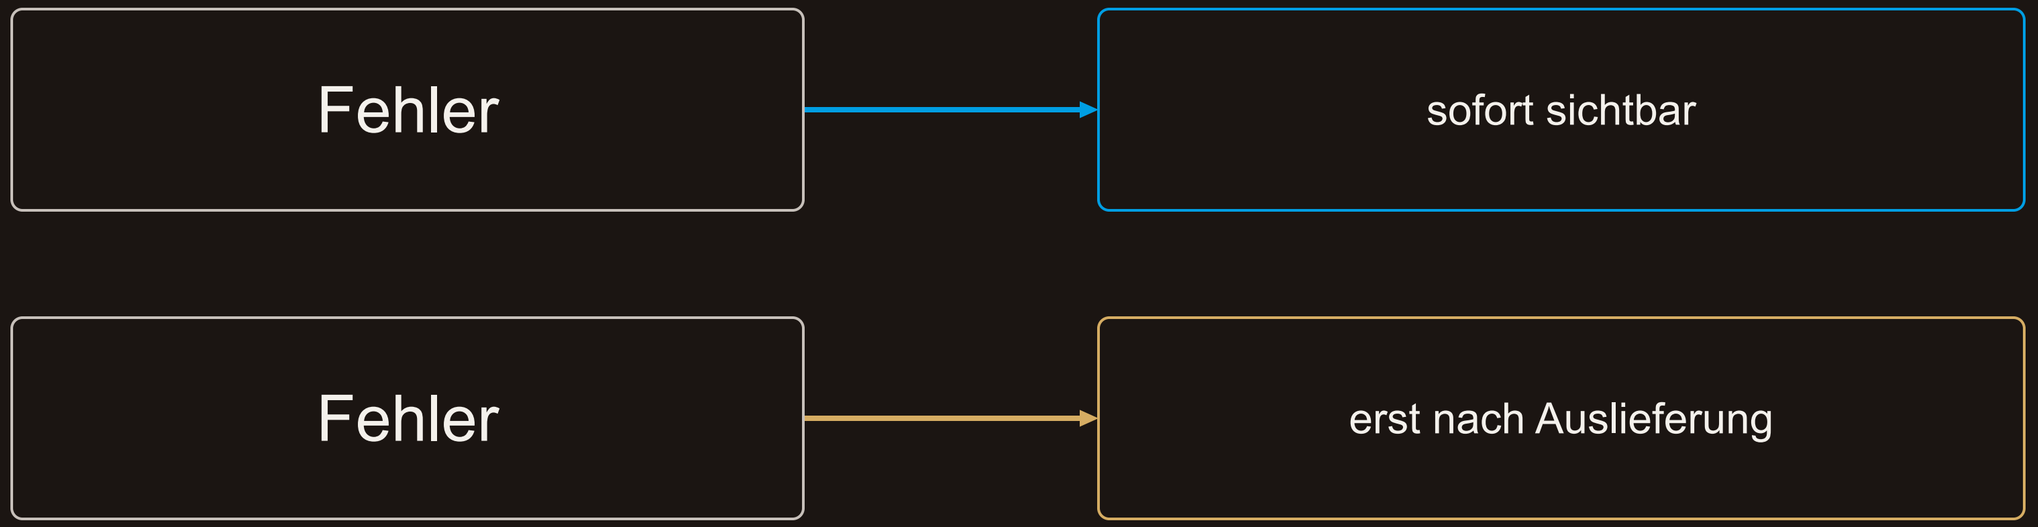
Ein E-Mail-Entwurf und eine Bestellung haben unterschiedliche Wirkungen.

Ein Entwurf ist leichter zu korrigieren als eine ausgelöste Bestellung.



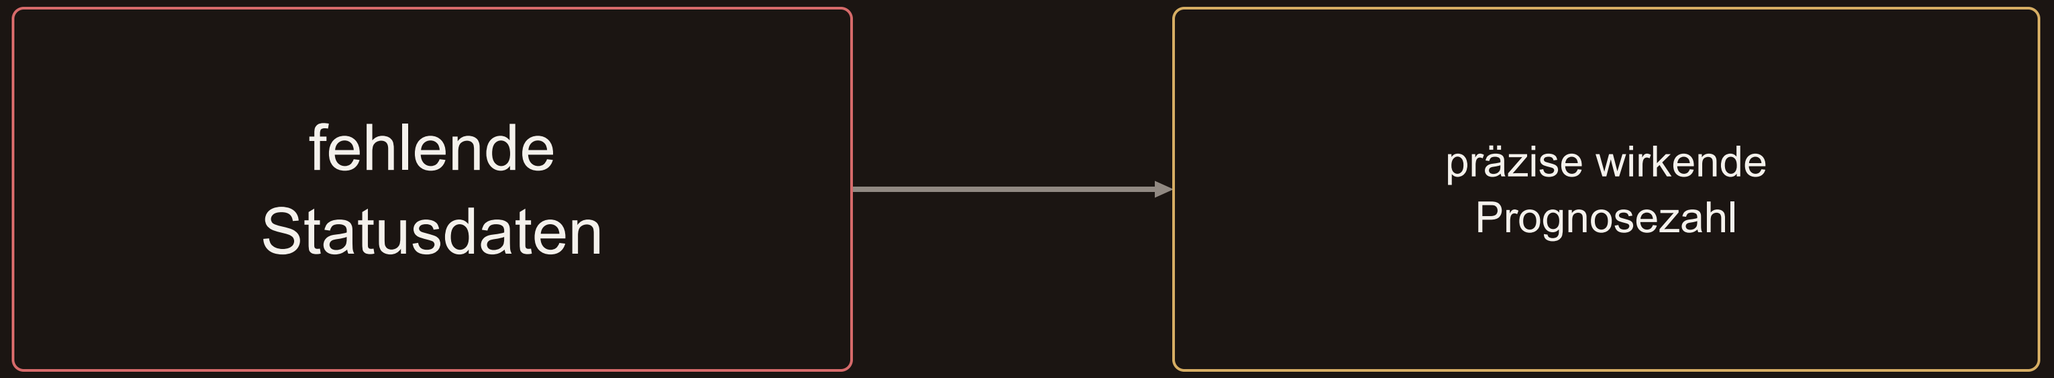
Umkehrbarkeit kann Kosten und Zeitfenster haben.

Spät erkannte Fehler brauchen frühere Prüfpunkte.



Nachträgliche Kontrolle hilft nur, wenn Folgen noch begrenzt werden können.

Eine präzise Zahl kann auf lückenhaften Daten beruhen.



Zahl und Datenqualität getrennt prüfen

Nach Datenqualität, Gültigkeitsbereich und Abweichung fragen.

Vier Fragen für den Kontrollbedarf

01 Schaden?

02 Umkehrbarkeit?

03 Erkennbarkeit?

04 Unsicherheit?

Gesprächsstruktur, keine automatische Risikobewertung.

Ziele, Daten, Systemwahl und Prozessregeln prägen spätere Entscheidungen.



Eine finale Freigabe repariert kein schlechtes Systemdesign.

Zuständigkeiten müssen vor dem Einsatz feststehen.

Fachbereich

Ziele und Folgen klären

Welche Entscheidung soll unterstützt werden?

Systemverantwortliche

Daten, Rechte, Grenzen festlegen

Was darf das System sehen und ausführen?

Entscheidende Person

Prüfen, freigeben, stoppen

Wann muss ein Mensch eingreifen?

Konkrete Rollen hängen von Organisation und Anwendung ab.

Wenn KI nachweislich besser entscheidet: Muss ein Mensch trotzdem freigeben?

Angenommen, der Entscheidungsbereich ist klar umrissen und die KI ist dort zuverlässiger als die Fachleute.

Positionslinie: Wo würdet ihr die Grenze ziehen?

Positioniert euch. Nennt eine Bedingung, die für euch entscheidend ist. Hört ein Gegenargument an – und entscheidet, ob ihr euch bewegt.

Welche Bedingung bestimmt eure Position?

KI darf selbst ausführen

Mensch gibt jedes Mal frei

20 Minuten

Was hat eure Position verändert?

Leistung

Wie gut ist das System wirklich?

Schaden

Was kostet ein Fehler?

Kontrolle

Wer kann eingreifen?

Verantwortung

Wer trägt die Folgen?

Der Forschungsbefund beantwortet eine Leistungsfrage.

Gute Mensch-KI-Zusammenarbeit
verteilt Aufgaben so, dass
Leistung, Kontrolle und Verantwortung
zusammenpassen.

Weiterlesen: Mensch und KI

Aufgabenteilung und Vertrauen

Parasuraman et al. (2000)
Funktionen der Automatisierung

Lee & See (2004)
Angemessene Nutzung

Vaccaro et al. (2024)
Metaanalyse Mensch + KI

Hemmer et al. (2024)
Komplementarität gestalten

Kontrolle und Verantwortung

Bainbridge (1983)
Ironie der Automatisierung

Buçinca et al. (2021)
Prüfung von KI-Empfehlungen

NIST AI RMF
Risikomanagement

EU-KI-Verordnung, Art. 14
Menschliche Aufsicht bei Hochrisiko-KI

Transfer-Challenge

Fünf Fragen für den Berufsalltag

01 Was ist hier eigentlich die Entscheidung?

02 Wobei kann KI konkret helfen?

03 Wo kann das System irren oder scheitern?

04 Was müssen Menschen beurteilen oder verantworten?

05 Welche Kontrolle liegt vor der realen Handlung?

Mein nächster Schritt

Ein Anwendungsfall,

den ich prüfen möchte

Eine Aufgabe,

die ich nicht vorschnell automatisiere

Eine Prüfroutine,

die ich künftig nutze

2 Minuten für eine persönliche Notiz

Gute Zusammenarbeit mit KI beginnt damit, die Entscheidung und ihre Verantwortung zu verstehen.



image: ai-generated (gpt-image-2.5-flare)